



Universidad Nacional Autónoma de México
Facultad de Ciencias





*Aplicación de Modelos de Lenguaje de
Gran Escala al Análisis de Bases de
Datos de Artículos Científicos*

Autora: Ana Valeria Deloya Andrade

Tutor: Dr. José Luis Jiménez Andrade


Introducción



Introducción

- **Cienciometría**

Indicadores bibliométricos



Representaciones visuales:

- ➔ **Gráficas**
 - ➔ **Diagramas**
 - ➔ **Mapas autoorganizados**
-

Introducción

- Representaciones visuales



La interpretación suele requerir tiempo considerable



Automatizar

Asistir

Introducción

Análisis e interpretación de representaciones visuales

Extraídas de bases de datos de artículos científicos



Introducción

➔ Evaluación de modelos
de lenguaje de gran
escala



➔ Implementación de
un sistema

- **Objetivo General:**

Aplicar modelos de lenguaje de gran escala al análisis de bases de datos de artículos científicos

- ❑ Conocer los **fundamentos teóricos** de los modelos de lenguaje de gran escala para **identificar su potencial** en la interpretación de visualizaciones científicas
 - ❑ Diseñar e implementar un **sistema** basado en modelos de lenguaje de gran escala que **permita procesar representaciones visuales** derivadas de **indicadores bibliométricos** presentes en **bases de datos de artículos científicos**
 - ❑ Generar **reportes** basados en indicadores bibliométricos a partir de la **generación de interpretaciones** de representaciones visuales **mediante modelos de lenguaje**
-

Modelos de Lenguaje de Gran Escala (LLMs)

Modelos de Lenguaje de Gran Escala (LLMs)


- **Machine Learning**

→ Tradicionalmente, cada problema requería el diseño y entrenamiento de un modelo independiente.




Modelos de Lenguaje de Gran Escala (LLMs)

- **Deep Learning:** modelos inspirados de manera abstracta en el funcionamiento del cerebro humano
- **Modelos Generativos:** producen contenido nuevo a partir de regularidades aprendidas



Modelos de Lenguaje de Gran Escala (LLMs)



- Redes neuronales profundas
- Generalmente basadas en la arquitectura Transformer
- Diseñadas para modelar secuencias lingüísticas y generar texto de manera autoregresiva
- Predicción probabilística de tokens sucesivos
- Entrenados con grandes corpus textuales

Modelos de Lenguaje de Gran Escala (LLMs)

LARGE

- Volumen de datos utilizados durante el entrenamiento
- Cantidad de parámetros que conforman el modelo


LANGUAGE MODEL

- Modelo de aprendizaje automático que asigna una distribución de probabilidad sobre las posibles palabras siguientes en una secuencia (Jurafsky, 2026)

Modelos de Lenguaje de Gran Escala (LLMs)


- **Multimodalidad**

- ➔ **Procesan múltiples tipos de información**
- ➔ **Permiten describir, interpretar y responder preguntas sobre contenido visual**



Modelos de Lenguaje de Gran Escala (LLMs)

- Multimodalidad



Estructura y Funcionamiento del Sistema

Tecnologías Utilizadas

- Primera versión



Páginas web interconectadas

- **HTML**
- **Scripts de Python**
- **Jupyter Notebook**
- **Sin LLMs**



Descripción General

Se recuperaron un total de 6153 documentos, publicados desde 1968 hasta el 2024. Todos los documentos fueron exportados a R haciendo uso del paquete Bibliometria. De este total, 66 no fueron recuperados desde InCites por corresponder a documentos publicados antes de 1980.

Una descripción general de los documentos se observa en la Fig. 1. La colección muestra una producción científica creciente (tasa anual de 8.88%) y altamente colaborativa, con una importante participación internacional (56%) y un nivel considerable de citación promedio por artículo (22.14). La alta cantidad de autores y referencias indica una red científica activa y extensa. Se publica en 707 fuentes diferentes.

Periodo	Autores	Referencias	Artículos
1968-2024	707	6153	8.88 %
1968-1999	138	1061	10.17 %
2000-2024	569	5092	8.71 %

Fig. 1. Producción científica del ICN en el Web of Science, 1968-2024

Periodo	Autores	Referencias	Artículos
1968-2024	654	3908	7.95 %
1968-1999	138	1061	10.17 %
2000-2024	516	2847	7.54 %

De los 6153 documentos 4695 están clasificados como artículos y 88 como reviews. Además, 1077 corresponden a publicaciones de grupos de autores según la clasificación del WoS o tienen más de 20 autores. En total la producción del ICN conformada por artículos o reviews que




Impacto
de la
Producción Científica

IR



Análisis
de la
Colaboración

IR



Caracterización
Temática de la
Producción Científica

IR



Contribución a los
Objetivos de Desarrollo
Sostenible (ODS)

IR

Tecnologías Utilizadas

**Organización
estructurada de la
información**

**Integración de
componentes de
inteligencia artificial**

**Navegación más
intuitiva**



Tecnologías Utilizadas

- **Framework de Desarrollo Web:**
Streamlit



- No se necesitan tecnologías adicionales
 - Arquitectura basada en pages o páginas
 - Actualización automática de la interfaz
-

Tecnologías Utilizadas

- **Lenguaje de Programación: Python**

Manejo de datos


Comunicación de
modelos de lenguaje de
gran escala

Visualización de
resultados

Sin depender de servicios
externos en la nube

Tecnologías Utilizadas

- **Lenguaje de Programación:** Python




Bibliotecas:

- **openai: system, user**
 - **lmstudio**
 - **httpx**
 - **base64**
-

Tecnologías Utilizadas

- Infraestructura de Cómputo: GPU

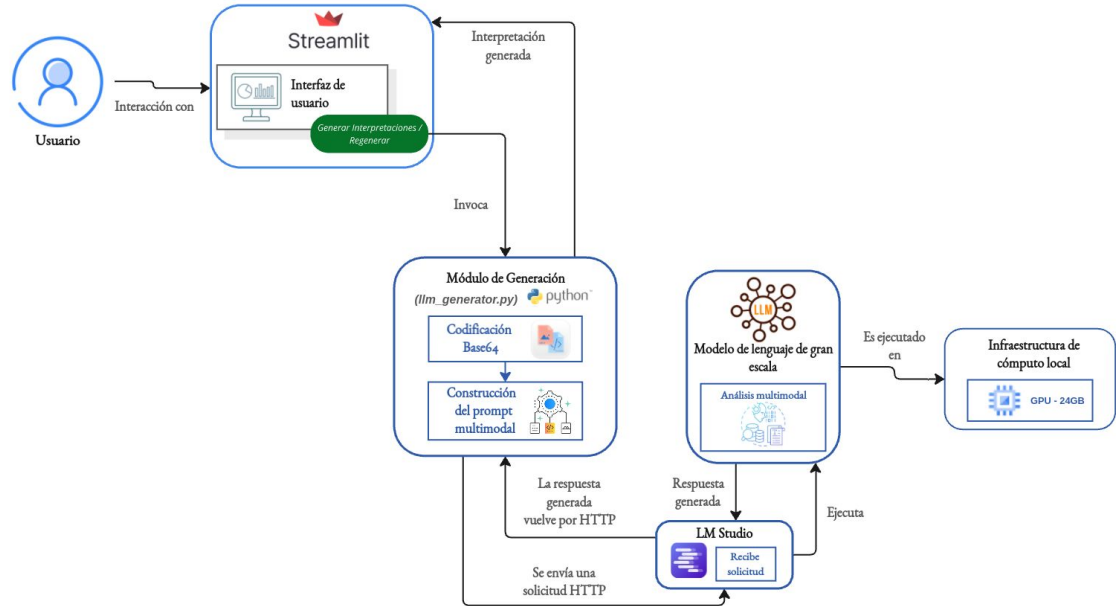
→ 24 GB de memoria



Arquitectura General

Interfaz de usuario

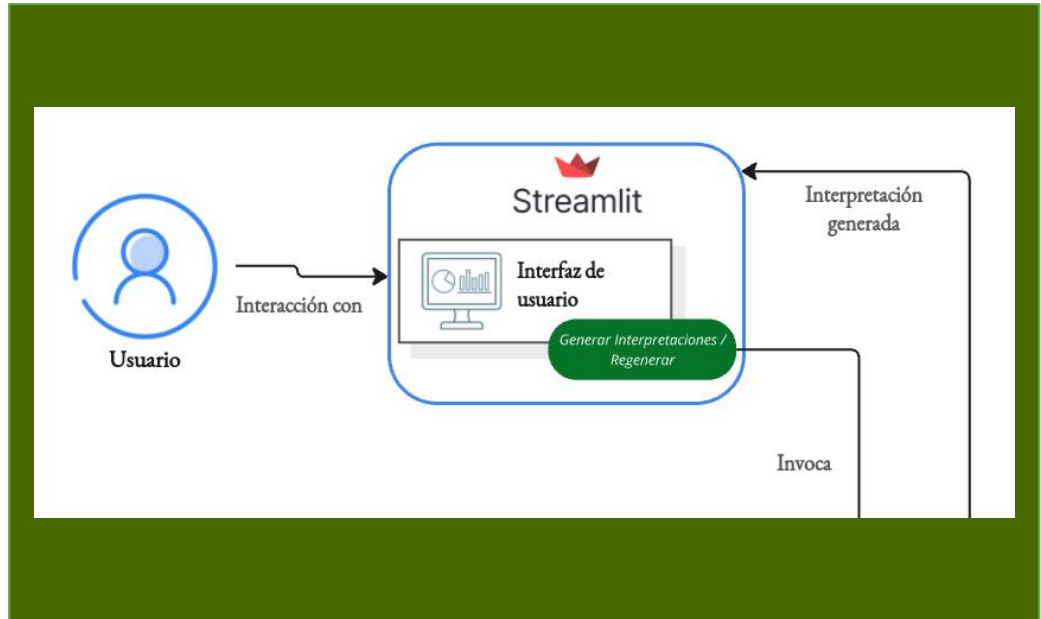
Módulo de
procesamiento de
representaciones
visuales



Arquitectura General

- Interfaz de usuario

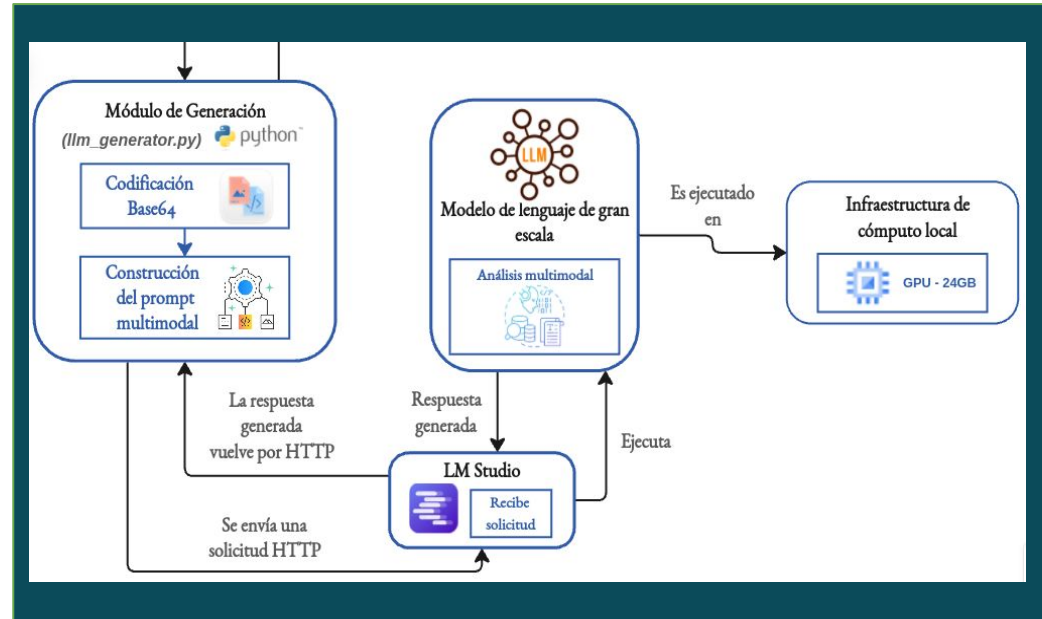
→ Interacción directa con el sistema y de la visualización de resultados



Arquitectura General

- **Módulo de procesamiento de representaciones visuales**

→ **Orientado a la generación de interpretaciones mediante un LLM**



Análisis Comparativo

- **Criterios de evaluación**

Cualitativa de carácter exploratorio:

Congruencia con la imagen

Identificación de patrones

Ausencia de alucinaciones

Seguimiento de instrucciones



Comparación de respuestas contra la representación visual original

Análisis Comparativo

- Modelos evaluados

Modelo	Parámetros	Ventana de contexto	Motivo de selección
<i>InternVL3.5-8B</i>	8,000 millones	32,768 tokens	Buen rendimiento en hardware limitado para el razonamiento visual.
<i>Pixtral-12b</i>	12,000 millones	128,000 tokens	Sobresaliente desempeño multimodal y en reconocimiento óptico de caracteres (OCR).
<i>InternVL3.5-30B-A3B</i>	30,000 millones	40,960 tokens	Capacidad para procesar información visual y transformarla en descripciones detalladas.
<i>Gemma-3-12b</i>	12,000 millones	128,000 tokens	Capacidad para extraer e interpretar información detallada.

Análisis Comparativo

- Evolución del prompt

Prompt 1: Eliminar respuestas conversacionales

Alta inclusión de datos no sustentados. Lectura de ejes incongruente y reconocimiento de años inexistentes.



Prompt 2: Aumentar fidelidad descriptiva

Mejora descriptiva pero persisten insistencias temporales (ej. asume intervalos falsos).



Prompt 3: Reducir inconsistencias

Prioriza fidelidad, mayor fidelidad descriptiva. Restricciones explícitas sobre inferencias. Disminuyeron inconsistencias pero no desaparecieron.



Temperatura reducida de 0.2 a 0.0 para disminuir variabilidad

Análisis Comparativo

- Hallazgos frente al estado del arte

→ El prompting mejora consistencia, pero no elimina completamente errores

→ Dificultades en:

- ◆ Lectura de ejes
- ◆ Asociaciones temporales
- ◆ Interpretación semántica



Análisis Comparativo

- Hallazgos frente al estado del arte

Alucinaciones intrínsecas

- Presentes cuando el modelo genera descripciones que contradicen las representaciones visuales

Alucinaciones extrínsecas

- Observadas en la incorporación rangos temporales no son visibles en la representación visual

Producto del *sesgo de conocimiento paramétrico*

Análisis Comparativo

- Hallazgos frente al estado del arte



El sistema logra una reducción del trabajo manual de analista:

- Estructura la información base
 - Propone narrativas
 - Herramienta de apoyo y no un mecanismo de automatización completamente autónomo
-


Análisis Comparativo

- Selección del modelo final: **Pixtral-12b**

- ★ Mejor fidelidad visual general
 - ★ Menor incorporación de información no verificable
 - ★ Mayor reconocimiento de limitaciones
-

Generación Automática del Reporte

- Incorporación de contexto mediante captions



Generación del Reporte Cienciométrico

- **Página de inicio**

Inicio

Evolución del Volumen de la Producci...

Impacto de la Producción Científica

Análisis de la Colaboración

Caracterización Temática de la Produ...

Contribución a los Objetivos de Desar...

 **La Investigación Científica en el Instituto de Ciencias Nucleares de la UNAM**

Son presentados los resultados de un estudio cienciométrico enfocado en el análisis de la producción científica con mayor visibilidad internacional generada por investigadores del Instituto de Ciencias Nucleares (ICN) de la Universidad Nacional Autónoma de México (UNAM), entendida como la producción indizada en Web of Science (WoS).

Con este análisis se busca ofrecer una **línea base objetiva para la planeación institucional** y la gestión proactiva de su visibilidad internacional, identificando oportunidades de colaboración y vacíos de evidencia en áreas estratégicas.

Sobre la Institución 

El ICN cuenta con una trayectoria académica de más de cinco décadas, evolucionando desde su fundación como Laboratorio Nuclear en 1967 hasta adoptar su nombre actual en 1988. Su quehacer científico abarca históricamente áreas fundamentales como **física nuclear, altas energías, gravitación, nanomateriales, astrofísica, óptica cuántica** y enfoques interdisciplinarios.

Objetivos y Metodología del Estudio

A partir de una combinación de **técnicas cienciométricas, análisis de redes complejas e inteligencia artificial**, el presente estudio caracteriza la trayectoria y el desempeño del ICN, con énfasis en:

- **Volumen y Crecimiento** de publicaciones.

Deploy

Generación del Reporte Cienciométrico

- Primer página



Generación del Reporte Cienciométrico

- Representación visual junto a su interpretación generada en la primer página



Generación del Reporte Cienciométrico


- Cambio de pestaña en la primer página



Conclusiones

Aportaciones y alcance

- Evaluación comparativa
- Identificación de limitaciones asociadas a la interpretación visual
- Integración de captions como contexto complementario
- Sistema funcional para asistencia en reportes



→ *No sustituye al especialista*

Cumplimiento de objetivos

- ✓ Se estudiaron los fundamentos teóricos de los modelos de lenguaje de gran escala
 - ✓ Se diseñó e implementó un sistema capaz de generar interpretaciones automáticas a partir de representaciones visuales bibliométricas
 - ✓ Se generaron reportes basados en interpretaciones producidas por modelos multimodales
 - ✓ Se identificaron capacidades y limitaciones de los LLMs para apoyar tareas de análisis científico
-

Trabajo a futuro

One-shot prompting

Transición hacia prompts que incluyan un ejemplo explícito (entrada + salida ideal)

Escalabilidad de modelos

Pruebas con modelos de mayor escala que también puedan ejecutarse localmente

Validación experta cuantitativa

Complementar la evaluación cualitativa realizada incorporando especialistas en bibliometría y cienciometría

Gracias por su atención
