



**Universidad Nacional Autónoma de México**  
**Facultad de Ciencias**



***Aplicación de Modelos de Lenguaje de  
Gran Escala al Análisis de Bases de  
Datos de Artículos Científicos***


**Autora: Ana Valeria Deloya Andrade**

**Tutor: Dr. José Luis Jiménez Andrade**

---

---

# Introducción




# Introducción

- **Cienciometría**

→ **Publicaciones científicas**

**Indicadores bibliométricos**



**Representaciones visuales:**

- **Gráficas de barras y líneas**
- **Diagramas**
- **Mapas autoorganizados**

---

# Introducción

- Problemática

 La interpretación suele requerir tiempo considerable

*Herramientas de apoyo:*

Automatizar

Asistir



---

- **Objetivo General:**  
Aplicar modelos de lenguaje de gran escala al análisis de bases de datos de artículos científicos

- ❑ Conocer los **fundamentos teóricos de los modelos de lenguaje de gran escala** para **identificar su potencial** en la interpretación de visualizaciones científicas
- ❑ Diseñar e implementar **un sistema basado en modelos de lenguaje de gran escala que permita procesar visualizaciones presentes en bases de datos de artículos científicos**
- ❑ **Generar reportes a partir de la generación de interpretaciones de representaciones visuales mediante modelos de lenguaje de gran escala**



---

# Modelos de Lenguaje de Gran Escala (LLMs)

---

---

# Machine Learning

- **Aprendizaje Automático**


→ Tradicionalmente, cada problema requería de un modelo independiente



---

# Deep Learning

- **Aprendizaje Profundo**




→ **Modelos inspirados de manera abstracta en el funcionamiento del cerebro humano**

- **Identificación de patrones complejos**



- 
- Capacidad computacional y disponibilidad masiva de los datos: *modelos más grandes*
- Modelos capaces de producir contenido nuevo con consistencia contextual



---

# Modelo de Lenguaje de Gran Escala

---


- **Modelo de aprendizaje automático que asigna una distribución de probabilidad sobre las posibles palabras siguientes en una secuencia**
- 

- **Volumen de datos utilizados durante el entrenamiento**
  - **Cantidad de parámetros que conforman el modelo**
-


---

# Multimodalidad

- ➔ Procesar distintos tipos de información
  - ◆ Interpretar, describir o responder preguntas sobre su contenido
    - *Información visual y textual*



# Multimodalidad



---


# Implementación y Funcionamiento del Sistema

---

---

# Framework de Desarrollo Web

- **Streamlit**



- **No se necesitan tecnologías web adicionales**
  - **Arquitectura basada en páginas**
  - **Actualización automática de la interfaz**
-

---

# Lenguaje de Programación

- Python

**base64**


Procesamiento de la  
representación visual

**openai**


Interacción con el  
modelo y estructurar  
mensaje

**httpx**

Envío de solicitudes  
HTTP



# Arquitectura General





---

# Análisis Comparativo

- Evaluación Cualitativa



Comparación humana de la respuesta contra la representación visual

Consistencia con la imagen

Identificación de patrones

Seguimiento de instrucciones



---

# Análisis Comparativo

- Modelos Evaluados


| Modelo                     | Parámetros      | Ventana de contexto | Motivo de selección                                                             |
|----------------------------|-----------------|---------------------|---------------------------------------------------------------------------------|
| <i>InternVL3.5-8B</i>      | 8,000 millones  | 32,768 tokens       | Buen rendimiento en hardware limitado para el razonamiento visual               |
| <i>Pixtral-12b</i>         | 12,000 millones | 128,000 tokens      | Sobresaliente desempeño multimodal en reconocimiento óptico de caracteres (OCR) |
| <i>InternVL3.5-30B-A3B</i> | 30,000 millones | 40,960 tokens       | Capacidad para procesar información visual y transformarla en descripciones     |
| <i>Gemma-3-12b</i>         | 12,000 millones | 128,000 tokens      | Capacidad para interpretar información visual                                   |

---

---

# Análisis Comparativo

- Evolución del Prompt



---

# Hallazgos Frente al Estado del Arte

- Fenómeno de Alucinación

Alucinaciones intrínsecas

→ Descripciones que **contradicen** las representaciones visuales

Alucinaciones extrínsecas

→ Incorporación rangos temporales **no son visibles** en la representación visual

*Sesgo de conocimiento paramétrico*

---

# Modelo del Sistema

- Pixtral-12b

- ★ Mejor equilibrio entre **descripciones detalladas** y **consistencia visual**


- **Observaciones acordes** con la representación visual
- Identificación de **patrones relevantes**: picos y fluctuaciones



---

# Contexto Adicional

- Captions en el prompt



# Generación del Reporte Cienciométrico

- **Página de Inicio**

Inicio

Evolución del Volumen de la Producci...

Impacto de la Producción Científica

Análisis de la Colaboración

Caracterización Temática de la Produ...

Contribución a los Objetivos de Desar...

 **La Investigación Científica en el Instituto de Ciencias Nucleares de la UNAM**

Son presentados los resultados de un estudio cienciométrico enfocado en el análisis de la producción científica con mayor visibilidad internacional generada por investigadores del Instituto de Ciencias Nucleares (ICN) de la Universidad Nacional Autónoma de México (UNAM), entendida como la producción indizada en Web of Science (WoS).

Con este análisis se busca ofrecer una **línea base objetiva para la planeación institucional** y la gestión proactiva de su visibilidad internacional, identificando oportunidades de colaboración y vacíos de evidencia en áreas estratégicas.

**Sobre la Institución** 

El ICN cuenta con una trayectoria académica de más de cinco décadas, evolucionando desde su fundación como Laboratorio Nuclear en 1967 hasta adoptar su nombre actual en 1988. Su quehacer científico abarca históricamente áreas fundamentales como **física nuclear, altas energías, gravitación, nanomateriales, astrofísica, óptica cuántica** y enfoques interdisciplinarios.

**Objetivos y Metodología del Estudio**

A partir de una combinación de **técnicas cienciométricas, análisis de redes complejas e inteligencia artificial**, el presente estudio caracteriza la trayectoria y el desempeño del ICN, con énfasis en:

- **Volumen y Crecimiento** de publicaciones.

Deploy

# Generación del Reporte Cienciométrico

- Primer Página





# Generación del Reporte Cienciométrico

- Representación Visual y su Interpretación



---

# Conclusiones

---

---

# Aportaciones y alcance



- ➔ No es un mecanismo de automatización completamente autónomo
  - ➔ *No sustituye al especialista*
  - ➔ Estructura la información base
  - ➔ Propone narrativas
-

---

# Cumplimiento de Objetivos

- ✓ Se identificaron capacidades y limitaciones de los LLMs en la interpretación de representaciones visuales
  - ✓ Se diseñó e implementó un sistema capaz procesar representaciones visuales
  - ✓ Se generaron reportes basados en interpretaciones producidas por un LLM
-

---

# Trabajo a Futuro

## One-shot Prompting

Transición hacia prompts que incluyan un ejemplo explícito (entrada + salida ideal)

## Escalabilidad de Modelos

Pruebas con modelos de mayor escala que también puedan ejecutarse localmente

## Validación Experta Cuantitativa

Complementar la evaluación cualitativa realizada incorporando especialistas en bibliometría y cienciometría

---


**Gracias por su atención**

---

---

# Mapas Autoorganizados o *Self-Organizing Maps*

- Es un método de aprendizaje automático no supervisados
- Asocia los datos de entrada con los nodos de una rejilla bidimensional
  - ◆ Relación entre distintos grupos de autores
    - Características compartidas



# Primera Versión



## Páginas web interconectadas

- HTML
- Scripts de Python
- Jupyter Notebook
- Sin LLM



### Descripción General

Se recuperaron un total de 6153 documentos, publicados desde 1968 hasta el 2024. Todos los documentos fueron exportados a R haciendo uso del paquete Bibliometria. De este total, 66 no fueron recuperados desde InCites por corresponder a documentos publicados antes de 1980.

Una descripción general de los documentos se observa en la Fig.1. La colección muestra una producción científica creciente (tasa anual de 8.88%) y altamente colaborativa, con una importante participación internacional (56%) y un nivel considerable de citación promedio por artículo (22.14). La alta cantidad de autores y referencias indica una red científica activa y extensa. Se publica en 707 fuentes diferentes.



Fig. 1. Producción científica del ICN en el Web of Science, 1968-2024



De los 6153 documentos 4605 están clasificados como artículos y 88 como reviews. Además, 1077 corresponden a publicaciones de grupos de autores según la clasificación del WoS o tienen más de 20 autores. En total la producción del ICN conformada por artículos o reviews que





---

# Base64

- La cadena en Base64 se envía en la petición HTTP
- LM Studio recibe la petición, detecta el campo correspondiente a una imagen
- Decodifica la Base64
- Recupera bytes originales y los envía al codificador visual


iVBORw0KGgoA  
AAANSUhEUgAA  
BLYAAAO+CAIAA  
AAAd2FoqAAAAA  
XNSR0IArs4c6Q  
AAAPplWEImD...



---

# Openai, LM Studio y LLM

- ➔ **openai:** se encarga de construir las solicitudes con el formato esperado para comunicarse con el LLM mediante una API compatible en estructura con OpenAI
  - ◆ Se estructuran las solicitudes utilizando mensajes con roles: **system**, **user**
- ➔ **LM Studio:** recibe esa solicitud y se la entrega al modelo
- ➔ **LLM:** interpreta el mensaje y genera la respuesta



---

# Elección Tipo de Análisis

- **Humano**

Dificultad en los métodos de **evaluación automática** para **detectar alucinaciones** en la generación de **lenguaje natural**

- “La evaluación humana se mantiene como uno de los enfoques más utilizados y confiables”



---

# Elección Tipo de Análisis

- Humano

→ Al contar con las representaciones visuales a analizar por el modelo y al no ser una especialista en cienciometría

- ◆ Enfoque de *comparación* o *comparing*

- Se **contrastan las salidas generadas** por los modelos **frente a las referencias de verdad o *ground-truth***



---

# Temperatura


- Se estableció entre 0.0 y 0.2 con el objetivo de **eliminar la variabilidad**
  - ◆ **Capacidad** del modelo y **no del azar**
- En la regeneración, se aumenta para permitir al usuario explorar variaciones de interpretaciones con una misma visualización

## LLM Temperature



# Ventana de Contexto

- ➔ Más amplia: Incrementa la **cantidad de información** que el modelo puede procesar



---

# ¿Por qué Pixtral-12b fue superior a un modelo con más parámetros?

- Un mayor número de parámetros incrementa la capacidad del modelo para representar relaciones complejas
- Sin embargo, el rendimiento real depende de la calidad y diversidad del volumen de datos de su entrenamiento
  - ◆ Un modelo más pequeño bien optimizado puede superar a uno más grande no tan bien entrenado

---

# Generación Interpretaciones

```
st.session_state.interpretaciones = {}
```

```
...
```

```
if st.button("Generar interpretaciones"):
    with st.spinner("Generando..."):
        st.session_state.interpretaciones["img1"] =
            generator(image_one_path, image_one_caption)
        st.session_state.interpretaciones["img2"] =
            generator(image_two_path, image_two_caption)...
```

---



---

# Regeneración Interpretaciones

```
display_interpretacion( img_key, img_path, img_caption=None ):
```

```
    if img_key in st.session_state.interpretaciones:
```

```
        st.markdown(st.session_state.interpretaciones[img_key])
```

```
    if st.button("Regenerar", key=f"regen_{img_key}"): 
```

```
        st.session_state.interpretaciones[img_key] = st.  
            empty()
```

```
        with st.spinner("Regenerando..."):
```

```
            st.session_state.interpretaciones[img_key] =  
                generator(img_path, img_caption)
```

```
        st.rerun()
```

---

# Otros enfoques usando LLMs

- ➔ Aplicaciones en la medicina
  - ◆ Diagnósticos
  - ◆ Reportes radiológicos
- En base el análisis de imágenes clínicas

*De igual forma, las alucinaciones impiden la automatización total*

## From Text to Multimodality: Exploring the Evolution and Impact of Large Language Models in Medical Practice

Qian Niu<sup>1</sup>, Keyu Chen<sup>2</sup>, Ming Li<sup>2</sup>, Pohsun Feng<sup>3</sup>, Ziqian Bi<sup>4</sup>, Lawrence KQ Yan<sup>5</sup>, Yichao Zhang<sup>6</sup>, Caitlyn Heqi Yin<sup>7</sup>, Cheng Fei<sup>8</sup>, Junyu Liu<sup>1</sup>, Tianyang Wang<sup>2</sup>, Yunze Wang<sup>10</sup>, Silin Chen<sup>11</sup>, Ming Liu<sup>12</sup>, Benji Peng<sup>2</sup>, Xinyuan Song<sup>13</sup>, Ziyuan Qin<sup>13</sup>, Riyang Bao<sup>13</sup>, Zekun Jiang<sup>14</sup>

<sup>1</sup>Kyoto University

<sup>2</sup>Georgia Institute of Technology

<sup>3</sup>National Taiwan Normal University

<sup>4</sup>Indiana University

<sup>5</sup>Hong Kong University of Science and Technology

<sup>6</sup>The University of Texas at Dallas

<sup>7</sup>University of Wisconsin-Madison

<sup>8</sup>Cornell University

<sup>9</sup>University of Liverpool

<sup>10</sup>University of Edinburgh

<sup>11</sup>Zhejiang University

<sup>12</sup>Purdue University

<sup>13</sup>Emory University, Atlanta, GA, USA

<sup>14</sup>West China Biomedical Big Data Center, West China Hospital, Sichuan University, Chengdu, China

\*Corresponding Email: zekun\_jiang@163.com