



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

FACULTAD DE CIENCIAS

APLICACIÓN DE MODELOS DE LENGUAJE DE GRAN
ESCALA AL ANÁLISIS DE BASES DE DATOS DE
ARTÍCULOS CIENTÍFICOS

T E S I S

QUE PARA OBTENER EL TÍTULO DE:

LICENCIADA EN CIENCIAS DE LA COMPUTACIÓN

P R E S E N T A:

ANA VALERIA DELOYA ANDRADE

TUTOR:

DR. JOSÉ LUIS JIMÉNEZ ANDRADE



CIUDAD UNIVERSITARIA, CDMX, 2026

«Mathematical science shows what is. It is the language of unseen relations between things. But to use and apply that language, we must be able to fully to appreciate, to feel, to seize the unseen, the unconscious.»

Ada Lovelace

Agradecimientos

Índice general

Agradecimientos	III
1. Introducción	1
1.1. Contexto de la investigación	1
1.2. Planteamiento del problema	2
1.3. Motivación y relevancia	2
2. Análisis y visualización de datos cienciométricos y LLMs	3
2.1. Conceptos básicos de la ciencimetría	3
2.2. Visualización de datos	4
2.3. Modelos de lenguaje de gran escala (LLMs)	6
3. Generación automática de reportes cienciométricos	7
3.1. Diseño de pipeline(s) o flujo(s) de trabajo	7
3.2. Diagrama(s) de secuencia	8
3.3. Arquitectura general	9
4. Implementación e integración	10
4.1. Tecnologías utilizadas	10
4.2. Descripción del sistema	11
5. Aplicación o estudio de caso	13
5.1. Análisis comparativo de modelos	13
5.1.1. Primer prompt	14
5.1.2. Segundo prompt	19
5.1.3. Tercer prompt	26
5.2. Generación automática de reportes cienciométricos del ICN y/o de la Facultad de Ciencias de la UNAM	28
6. Conclusiones y trabajo a futuro	29
6.1. Utilidad en la práctica profesional	29
6.2. Potencial para investigación y gestión científica	29
6.3. Limitaciones y retos futuros	29
Bibliografía	30

1 Introducción

1.1. Contexto de la investigación

En los últimos años, el desarrollo de la Inteligencia Artificial ha avanzado de manera acelerada, generando un impacto y transformando múltiples aspectos de la vida cotidiana. Con tecnologías como los asistentes inteligentes, por ejemplo Alexa de Amazon, que comenzaron por ofrecer a los usuarios control por voz básico para reproducir música y hacer consultas para gestionar tareas domésticas; a controlar dispositivos inteligentes, ofrecer recomendaciones personalizadas e incluso responder sin acceso a internet. Este tipo de herramientas ilustran cómo la IA se ha integrado de manera natural en actividades diarias y a su vez ha modificado la forma en que nos relacionamos con la tecnología.

Al mismo tiempo, en el ámbito científico la Inteligencia Artificial ha impulsado innovaciones de gran alcance. Surgiendo entre estos avances los modelos de lenguaje de gran escala LLMs, cuyo crecimiento en sus capacidades ha permitido que dejen de ser herramientas que únicamente se limitaban al procesamiento de texto para convertirse en sistemas multimodales o visuales, capaces de analizar y generar información a partir de distintos tipos de datos.

Actualmente, este tipo de modelos de lenguaje pueden procesar una amplia variedad de representaciones visuales, desde las gráficas de barras y de líneas hasta contenido más complejo como los mapas generados con redes neuronales SOM, y generar interpretaciones precisas, o incluso son capaces de responder preguntas detalladas sobre el contenido visual. Dando paso con esto a nuevas posibilidades para la automatización de tareas analíticas, en especial en campos en los que las visualizaciones de datos son fundamentales como lo es la cienciometría.

En esta investigación se abordarán los modelos de lenguaje de gran escala LLMs y cómo es que pueden ser aprovechados en la automatización de la generación de texto a partir de representaciones visuales, obtenidas de un reporte cienciométrico para su análisis. En consecuencia se llevó a cabo la implementación de un sistema que presenta, con un formato visualmente ordenado, explicaciones textuales generadas automáticamente acerca de la investigación científica en el Instituto de Ciencias Nucleares de la UNAM.

1.2. Planteamiento del problema

Durante la producción científica son producidos grandes volúmenes de datos que deben ser interpretados de forma clara, precisa y eficiente. En este contexto, las gráficas, tablas, mapas e indicadores cuantitativos representan herramientas esenciales para comprender aspectos como la evolución de la productividad científica, los patrones de colaboración entre instituciones e investigadores y las dinámicas de publicación del conocimiento. Sin embargo, la interpretación de estos elementos suele requerir bastante tiempo pues se requiere una atención especializada y experiencia analítica, especialmente cuando se trabaja con reportes extensos o con una gran cantidad de representaciones visuales.

Ante esta problemática, la incorporación de modelos de lenguaje de gran escala LLMs ofrece una oportunidad significativa particularmente en sus versiones multimodales o visuales. Se explorará qué tan capaces son estas herramientas para analizar representaciones visuales y generar descripciones textuales coherentes, precisas, detalladas y ajustadas al contenido de cada gráfica o tabla. Permitiendo así automatizar procesos como la redacción de reportes, la interpretación de visualizaciones y la elaboración de análisis descriptivos. Buscando agilizar el trabajo de quienes producen reportes cuantitativos, además de contribuir a mejorar la accesibilidad y la comunicación de resultados.

1.3. Motivación y relevancia

La motivación principal de esta investigación radica en aprovechar las capacidades de los modelos de lenguaje de gran escala LLMs para automatizar la generación de textos cuantitativos, con el propósito de evaluar sus limitaciones en tareas que requieren la comprensión de gráficas, tablas e indicadores científicos; permitiendo que se lleve a cabo una discusión crítica sobre su confiabilidad en entornos de investigación.

Los resultados obtenidos podrían sentar las bases para futuros desarrollos en la automatización de reportes científicos, contribuyendo a la reducción del tiempo dedicado a tareas de redacción e interpretación de visualizaciones, y facilitando el trabajo de los investigadores responsables de elaborar de ese tipo de textos. Asimismo, el desarrollo de sistemas como el propuesto contribuye a mejorar la comunicación y accesibilidad de la información científica al facilitar la divulgación de resultados hacia audiencias no especializadas en temas cuantitativos, fortaleciendo así su impacto y comprensión.

Por otro lado, para la formación profesional en Ciencias de la Computación esta investigación resulta especialmente relevante pues integra el uso de tecnologías emergentes relacionadas con la Inteligencia Artificial, la ciencia de datos y el análisis de información científica. Este enfoque contribuye a fortalecer aptitudes relacionadas con el procesamiento de datos, así como el diseño e implementación de soluciones tecnológicas apoyadas por la Inteligencia Artificial.

2 Análisis y visualización de datos cientiométricos y LLMs

2.1. Conceptos básicos de la cienciometría

La ciencia desempeña un papel central en nuestra sociedad actualmente, influye en varios aspectos de nuestra vida como lo es la economía, tecnología, salud, educación y en prácticamente todos los ámbitos de la vida moderna. Siendo precisamente esa relevancia lo que hace que sea importante la existencia de espacios que permitan comprender y analizar cómo es que la ciencia interactúa con otros componentes sociales, además de su evolución como sistema de producción de conocimiento. No buscando abordar descubrimientos científicos particulares o conocer sobre la historia de ciertos científicos, sino siguiendo el propósito de aplicar las herramientas de la ciencia para estudiar a la ciencia misma, examinando a la actividad científica como un objeto susceptible de medición, observación y modelado. Puede verse a la ciencia como una entidad que puede cuantificarse, integrada por comunidades de investigadores, flujos de publicaciones, redes de colaboración y dinámicas de crecimiento por parte de instituciones.

La cienciometría se dedica justamente a todo lo mencionado previamente, es el estudio del funcionamiento de la ciencia como institución social, analizando su estructura, sus patrones de producción, sus canales de comunicación y sus procesos de difusión. A través de métodos cuantitativos, permite caracterizar la evolución de la literatura científica, evaluar el impacto de la investigación, identificar tendencias emergentes y comprender cómo se organizan las comunidades académicas a nivel nacional e internacional.

2.2. Visualización de datos

La visualización de datos es una herramienta fundamental para el análisis científico, pues permite transformar información compleja en representaciones gráficas que facilitan su entendimiento, interpretación y comunicación; ayudando en la identificación de patrones, tendencias, relaciones y anomalías que podrían pasar desapercibidas si la información sólo fuera transmitida mediante formatos textuales.

En el análisis cuantitativo se trabaja con grandes volúmenes de información, incluyendo información bibliográfica, indicadores de producción, colaboraciones entre investigadores e instituciones. Siendo así que en este contexto la visualización adquiere un papel esencial para identificar y comprender mejor tendencias, comportamientos y dinámicas estructurales que serían difíciles de detectar de otra forma.

Entre las herramientas más utilizadas en la visualización de datos se encuentran las gráficas de barras, que nos permiten comparar grupos de datos de forma directa; y las gráficas de líneas, útiles para analizar tendencias temporales para la detección de periodos de crecimiento, estabilidad o cambios abruptos.




Figura 2.1: Ejemplo de gráfica de barras y líneas

También están los gráficos de dispersión, que facilitan el estudio de relaciones entre dos variables, permitiendo observar correlaciones, agrupamientos o comportamientos atípicos. Por su parte, los diagramas de caja (box plots) son utilizados para obtener una representación estadística del comportamiento de una variable, mostrando su mediana, dispersión y valores extremos; lo que los convierte en una herramienta importante en el análisis exploratorio. Asimismo, para representar múltiples dimensiones de manera simultánea es que se emplean los gráficos de radar, que permiten comparar características entre diferentes entidades en función de varios indicadores.

En escenarios donde el análisis involucra alta dimensionalidad, métodos más avanzados como los mapas generados con redes neuronales SOM (Self-Organizing Maps) posibilitan la proyección de datos de muchos atributos en una malla bidimensional, esto permite visualizar patrones complejos como agrupamientos temáticos, similitu-

des entre autores o proximidades entre áreas de investigación.




Figura 2.2: Ejemplo de Self-Organizing Maps

2.3. Modelos de lenguaje de gran escala (LLMs)

3 Generación automática de reportes cienciométricos

3.1. Diseño de pipeline(s) o flujo(s) de trabajo

3.2. Diagrama(s) de secuencia

3.3. Arquitectura general

4 Implementación e integración

4.1. Tecnologías utilizadas

Dado que el sistema necesitaba integrar tanto componentes visuales como sus interpretaciones generadas por modelos de lenguaje multimodales, se optó por trabajar con herramientas que permitieran una comunicación fluida entre estos elementos. Buscando, además, una forma de tener una implementación modular que facilitara así futuras extensiones en el sistema.

Siendo así que se optó por utilizar Streamlit como el framework del sistema, aprovechando su arquitectura basada en pages para organizar el contenido en una pantalla de inicio y cinco páginas adicionales, cada una correspondiendo a una sección del reporte cienciométrico.

4.2. Descripción del sistema

Como se ha mencionado anteriormente, este sistema fue desarrollado con el propósito automatizar la generación de interpretaciones cuantitativas a partir de representaciones visuales. Su diseño, implementado utilizando Streamlit, se integra por dos componentes principales: la interfaz de usuario, que permite una interacción directa con el sistema, y el procesamiento de las representaciones visuales para la generación automática de sus interpretaciones mediante modelos de lenguaje de gran escala LLMs.

El sistema cuenta con una pantalla de inicio que le presenta al usuario, a modo de introducción, el contexto general acerca de la producción de la investigación científica en el Instituto de Ciencias Nucleares de la UNAM, del cual se extrajeron todas las representaciones visuales presentadas.




Figura 4.1: Pantalla de inicio

Además el sistema cuenta con cinco páginas o secciones que funcionan como módulos independientes. Cada una de ellas carga un conjunto específico de imágenes, ya sea tablas o gráficas, y genera sus interpretaciones utilizando un modelo de lenguaje de gran escala LLM que procesa estas entradas visuales.

La navegación entre estas secciones se realiza a través de un menú lateral, permitiendo al usuario explorar de forma estructurada los distintos componentes del estudio pues cada página se enfoca en un conjunto particular de datos cuantitativos; como lo son la colaboración, citación, productividad, entre otros.

Asimismo, se sigue una misma estructura visual para las cinco páginas, por ejemplo, la primera sección tiene por título *Evolución del Volumen de la Producción Científica* y su interfaz está estructurada de forma que se pueda acceder a tres pestañas temáticas entre las cuales se divide la información: (1) análisis general de la colección,

(2) evolución anual de la productividad, y (3) producción en revistas con factor de impacto.



Figura 4.2: Módulo 1 (imagen provisional en lo que termina de desarrollarse la implementación final)

El contenido en estas pestañas se encuentra organizado mediante columnas, combinando el texto interpretativo generado junto con sus representaciones visuales. Además, en la parte superior de la página justo por debajo del título y antes del menú de las pestañas, se incluye una sección con un “Resumen Ejecutivo” en la que se resalta la información más relevante entre la presentada en conjunto en la página, mostrándose esta sección en pantalla sin importar en cuál de las tres pestañas se encuentre el usuario.

Se eligió este diseño para la implementación del sistema debido a que facilita su expansión y evolución futura, permitiendo sustituir de manera sencilla el modelo de lenguaje de gran escala LLM empleado, ampliar el conjunto de imágenes analizadas o integrar nuevos tipos de análisis cuantitativos mediante la incorporación de módulos adicionales.

5 Aplicación o estudio de caso

5.1. Análisis comparativo de modelos

Se realizó una evaluación de la capacidad de interpretación de imágenes en distintos modelos con el objetivo de seleccionar el modelo de lenguaje de gran escala LLM que generará las descripciones automatizadas dentro del sistema. Para garantizar una comparación justa se utilizó la misma configuración de temperatura en todos los modelos y se empleó un mismo prompt, siguiendo estrictamente un formato de salida en JSON. Las imágenes utilizadas en las pruebas provienen del reporte cienciométrico, lo que permitió comparar el desempeño de los distintos modelos y seleccionar aquel que mostró mayor precisión en sus respuestas.

Como sabemos, los modelos de lenguaje de gran escala LLMs son entrenados con grandes cantidades de datos textuales, lo que les permite aprender patrones estadísticos del lenguaje y generar texto mediante la predicción del siguiente token en una secuencia. La temperatura es un parámetro que controla la forma en la que se distribuye la probabilidad utilizada durante las predicciones para la generación del texto. Un aumento en la temperatura hace que la distribución se vuelva más uniforme, incrementando la probabilidad de seleccionar tokens menos probables, produciendo respuestas más variadas y creativas pero menos coherentes. Por el contrario, una temperatura baja hace que el modelo favorezca los tokens con mayor probabilidad generando respuestas deterministas. Siendo esta última la que utilizaremos en nuestro caso, con un rango entre 0.0 y 0.2.

En el análisis de los resultados se tomó en cuenta la coherencia y precisión en la interpretación de la imagen, en especial en relación a datos que no son mencionados en su descripción humana original en el reporte; si existe información inventada por el modelo que no podía deducirse de la imagen; y su capacidad en la identificación de los componentes relevantes en la imagen.

Asimismo, para la selección de los LLMs a evaluar se buscó que fueran modelos multimodales de código abierto capaces de ejecutarse localmente, ya que el proyecto se desarrolla en un entorno con una GPU de 24 GB de memoria, por lo que fue indispensable seleccionar modelos compatibles con estas restricciones de hardware.

5.1.1. Primer prompt

El objetivo principal en la elaboración del primer prompt fue evitar que las respuestas generadas adoptaran un formato característico de los asistentes de Inteligencia Artificial, eliminando introducciones innecesarias como *“Claro, aquí tienes la descripción de la imagen”* y conclusiones generales. Asimismo, se buscó que los modelos produjeran descripciones basadas únicamente en la información que puede inferirse directamente de la imagen, sin añadir contenido inventado y no fundamentado. Buscando favorecer este comportamiento, se solicitó que las respuestas fueran concisas.

Primer Prompt de Prueba

```
1 messages=[
2     {"role": "system",
3       "content": "Eres un científico de datos experto en
4                 cienciometría y en la interpretación de gráficos e
5                 imágenes científicas."},
6     {"role": "user", "content": [
7       {"type": "text",
8         "text": "Describe y analiza únicamente la
9               información visible en la imagen proporcionada.
10              No incluyas introducciones ni conclusiones
11              generales, entrega solo la información técnica
12              y relevante. Si un dato en la imagen no es
13              legible o no está presente, no lo inventes. No
14              inventes valores, fechas o unidades. Si es una
15              gráfica, identifica el tipo de gráfica, ejes y
16              qué representan, tendencias principales, picos
17              o valles relevantes, y cualquier anotación o
18              valor claramente legible. Mantén respuestas
19              concisas."},
20       {"type": "image_url",
21         "image_url": {"url": image_uri}}
22     ]}
23 ]
```

Para la primer imagen de prueba se buscó una gráfica que nos permitiera evaluar la capacidad de los modelos en su interpretación de tendencias y patrones generales en los datos, variaciones anuales y cualquier información extra que puedan proporcionar a la descripción de la imagen.

La gráfica seleccionada representa el total de artículos publicados por investigador sin incluir trabajos derivados de grandes colaboraciones abarcando un periodo entre 1996 y 2024.




Figura 5.1: Tabla del total de artículos publicados por investigador, 1996-2024

Además, en el análisis de las respuestas generadas se consideró la descripción original de la imagen, extraída del reporte correspondiente.

A continuación se presenta la descripción para la gráfica:

El número de académicos a tiempo completo asociado al ICN ha aumentado desde su fundación como entidad académica hasta la actualidad. En los últimos años, este número ha mostrado cierta estabilidad. Se muestra la producción ajustada por el número de investigadores asociados a la institución en el periodo de 1996-2024 (...). Se observa una tendencia al crecimiento. Este crecimiento pudiera asociarse no solo al crecimiento de la actividad institucional, sino también a la propia cobertura de las bases de datos, dado el aumento de la cobertura del WoS durante los últimos años.

Las respuestas generadas, con sus respectivos análisis, son las siguientes:

Modelo A

Internvl3_5-30b-a3b

El gráfico es un histograma con una línea de tendencia superpuesta.

- ****Eje X (horizontal)****: Representa el "Año" desde 1950 hasta 2006.
- ****Eje Y (vertical izquierdo)****: Mide la frecuencia acumulada en porcentaje (%), que va **del 0% al 250%**.
- ****Eje Y (vertical derecho)****: No está etiquetado claramente, pero parece representar otra variable relacionada con el tiempo.

****Tendencias principales****:

- La línea de tendencia muestra un aumento gradual en la frecuencia acumulada hasta aproximadamente el año 1980.

- Después de este punto, hay una fluctuación con picos notables alrededor de los años 1995 y 2000.
- A partir **del** año 2000, la línea muestra una disminución gradual.

****Anotaciones claramente legibles**:**

- En el eje Y izquierdo, se pueden ver valores en porcentajes: 0%, 50%, 100%, 150%, y 200%.
- La línea de tendencia tiene un punto marcado con una flecha alrededor **del** año 2006.

****Valores relevantes**:**

- Alrededor **del** año 1980, la frecuencia acumulada alcanza un valor cercano al 150%.
- Los años 1995 y 2000 muestran picos significativos en la línea de tendencia.

El modelo no presenta el nivel esperado de precisión en su interpretación de la gráfica. En primer lugar, identifica incorrectamente el rango temporal del eje X, señalando que abarca de 1950 a 2006, cuando el rango real corresponde de 1996 a 2024. De manera similar, la información proporcionada sobre el eje Y es incorrecta, ya que el modelo no logra identificar el texto que describe qué representan los valores de los ejes verticales, tanto izquierdo como derecho.

En el apartado de tendencias principales, el modelo menciona años como 1980 y 1995, los cuales no aparecen en la gráfica, lo que evidencia que no pudo leer correctamente los años en la imagen. Asimismo, afirma que existe una disminución gradual a partir del año 2000, cuando en realidad se observa un incremento. En conjunto, estas imprecisiones reflejan la invención de valores y eventos que no están presentes en la imagen analizada.

No obstante, el formato de la respuesta sí es conciso. Este se encuentra estructurado en secciones, lo que facilita su lectura aunque esto no compensa la falta de fidelidad a la representación visual.

Modelo B

Pixtral-12b

El gráfico es una línea con barras superpuestas que representa datos de frecuencia acumulada sobre el tiempo .

- ****Eje X (horizontal)****: Representa el tiempo en formato "dd/mm/aa" desde el 31/05 hasta el 28/06.
- ****Eje Y (vertical)****: Muestra la frecuencia acumulada en valores que van de 0 a 250.

La línea principal muestra una tendencia ascendente general con algunos picos y valles. Los picos más notables ocurren alrededor **del** 14/06 y el 28/06, mientras que los valles se observan alrededor **del** 31/05 y el 07/06.

Las barras superpuestas representan frecuencias acumuladas en intervalos específicos de tiempo. Cada barra muestra un aumento en la frecuencia acumulada a medida que avanza el tiempo, con picos alineados aproximadamente con los picos de la línea principal.

La nota "www.sitio.com" está presente en la esquina inferior derecha **del** gráfico.

El modelo presenta múltiples imprecisiones en la interpretación de la imagen. En primer lugar, inventa información al describir el eje X, asignándole un formato temporal de fechas específicas que no aparecen en la gráfica. En cuanto al eje Y, si bien menciona correctamente los valores del eje izquierdo, omite por completo la identificación y descripción del eje derecho, a diferencia del modelo anterior.

Asimismo, en su análisis de las tendencias, el modelo hace referencia a fechas como 14/06 y 28/06, las cuales no son visibles ni legibles en la imagen, lo que indica nuevamente la invención de datos. Adicionalmente, menciona la presencia de un sitio web en la esquina inferior derecha del gráfico, información que no puede corroborarse visualmente.

En comparación con el modelo A, su capacidad para identificar correctamente los componentes relevantes de la gráfica es menor, particularmente en lo que respecta a la detección y descripción del eje Y derecho.

Modelo C

InternVL3_5-8B-GGUF

El gráfico es un histograma superpuesto con una línea de[Trend en caracteres asiáticos].

- ****Eje X (horizontal)****: Representa el "Ano", que va desde

- aproximadamente 1950 hasta alrededor de 2016.
- ****Eje Y (vertical izquierdo)**:** Mide la frecuencia acumulada en porcentaje, con valores que van **del** 0% al 250%.
 - ****Eje Y (vertical derecho)**:** No está claramente etiquetado, pero parece representar otra variable relacionada con el tiempo.
- **Tendencias principales**:**
- La línea de[Trend en caracteres asiáticos] muestra un aumento gradual en la frecuencia acumulada hasta aproximadamente el año 2005.
 - Después de este punto, hay una ligera disminución seguida de un pequeño aumento y luego estabilización.
- **Picos y valles relevantes**:**
- Se observan varios picos a lo largo **del** tiempo, con los m ás notables alrededor de los años 1980, 2000 y especialmente entre 2005 y 2010.
 - Los valleys corresponden a las caídas en la frecuencia acumulada justo después de estos picos.
- **Anotaciones o valores claramente legibles**:**
- No hay anotaciones adicionales o valores específicos legibles dentro **del** gráfico.

Este modelo incluye en su descripción de la gráfica caracteres correspondientes a escritura asiática, los cuales no pudieron ser correctamente renderizados para mostrarse en esta tesina redactada en LaTeX. Dichos caracteres corresponden al término trend o tendencia, lo que sugiere que el modelo detectó parcialmente el texto presente en la imagen pero sin lograr una redacción consistente en idioma.

En cuanto a la interpretación de los ejes, el modelo identifica valores numéricos en el eje Y, sin embargo la explicación de lo que dichos valores representan no es correcta. En general los modelos parecen no poder leer ese texto en la imagen. Respecto al eje X, asigna rangos temporales que no existen en la imagen, mencionando años inexistentes en la gráfica como 1950 lo que evidencia nuevamente la invención de información.

El análisis de las tendencias presenta inconsistencias pues el modelo afirma que existe un aumento hasta el año 2005 cuando en realidad se observa una disminución, y posteriormente describe una ligera disminución donde visualmente se puede apreciar un incremento. De igual forma, identifica picos en cuatro momentos distintos, de los cuales únicamente dos corresponden a picos reales visibles en la gráfica, alrededor

de los años 2000 y 2010. Los otros picos mencionados no están presentes en la imagen.

Aunque el modelo presenta un formato estructurado y logró describir correctamente ciertos elementos de la gráfica en aproximadamente dos de cada cuatro ocasiones, su interpretación en general presenta múltiples errores y valores inventados, lo que limita su confiabilidad para la descripción automática de este tipo de visualizaciones.

Observaciones

En síntesis, los tres modelos presentan limitaciones significativas para generar una interpretación fiel de la representación visual que se les proporcionó, principalmente en la identificación correcta de rangos temporales y tendencias, y en la lectura del texto que se encuentra a los costados de la gráfica.

El modelo A destacó por el formato de su estructura pero cuenta con mucha información inventada en su interpretación, el modelo C contó con una precisión parcial pero sólo en ciertos elementos específicos, y el modelo B es el menos confiable debido a su alta propensión a inventar información no visible.

Con este primer prompt se obtuvo el formato solicitado en la estructura de la respuesta, caracterizado por la ausencia de expresiones propias de asistentes de Inteligencia Artificial, y por descripciones estructuradas y concisas. Sin embargo, su confiabilidad para la interpretación automática de gráficas cuantitativas es limitada pues las respuestas generadas presentan información inventada con un bajo nivel en detalle y narrativa. A partir de estas observaciones, se concluyó que era necesario aprovechar de mejor manera las capacidades de los modelos de lenguaje de gran escala LLMs, por lo que se diseñó otro prompt con más especificaciones y se ajustó el parámetro de temperatura a 0.0 con el objetivo de reducir la generación de información no fundamentada.

5.1.2. Segundo prompt

Este prompt se diseñó con el objetivo de mejorar la calidad interpretativa y narrativa de las descripciones generadas, pues además de mantener la restricción de no inventar información, se especificó explícitamente el formato y el nivel de detalle deseado en las respuestas, buscando la construcción de una narrativa más extensa, detallada y precisa.

Segundo Prompt de Prueba

```
1 messages=[
2     {"role": "system",
3       "content": "Eres un científico de datos experto en
                    cuantitativa y en la interpretación de gráficos y
                    representaciones visuales científicas."},
```

```

4      {"role": "user", "content": [
5        {"type": "text",
6          "text": "Describe y analiza únicamente la
                    información visible en la imagen proporcionada.
                    No incluyas introducciones ni conclusiones
                    generales. Agrega información que puedas
                    deducir de la imagen para construir una
                    narrativa extensa, detallada y precisa para un
                    reporte cuantitativo. Si un dato en la imagen
                    no es legible o no está presente, no lo
                    inventes. No inventes valores, fechas o
                    unidades. Identifica el tipo de representación
                    visual (gráfica, tabla, etc.), ejes y qué
                    representan, tendencias principales, picos o
                    valles relevantes, y cualquier anotación o
                    valor claramente legible. Que la respuesta que
                    generes solo tenga palabras en español."},
7        {"type": "image_url",
8          "image_url": {"url": image_uri}}
9      ]}
10 ]

```

Inicialmente, se le pasó a los tres modelos la gráfica utilizada anteriormente con el fin de comparar directamente los resultados obtenidos bajo ambas configuraciones.

Los resultados acerca de la gráfica de prueba fueron los siguientes:

Modelo A

Internvl3_5-30b-a3b

La imagen muestra un gráfico de barras superpuesto con una línea de tendencia. El eje horizontal representa el tiempo, dividido en intervalos de años desde 1980 hasta 2016. El eje vertical izquierdo mide la frecuencia de citas por artículo, que va desde 0 hasta 250. La línea de trend es amarilla y muestra una tendencia general ascendente con algunos picos notables alrededor de los años 1998, 2004, 2007, 2010 y 2013. Las barras superpuestas en color azul representan la cantidad de artículos publicados cada año. Se observa un aumento gradual en el número de artículos a lo largo **del** tiempo, con picos alrededor de los años 1985, 1994, 2003 y 2016. La línea amarilla intersecta con las barras azules

en varios puntos, indicando años donde el número de citas por artículo fue particularmente alto en comparación con la cantidad de artículos publicados.

A pesar de que con este segundo prompt se buscaba alejarse de respuestas concisas para obtener una interpretación con una narrativa más extensa y detallada, el modelo generó una respuesta breve. Incluso, se aleja del formato estructurado en secciones que había presentado con el primer prompt, el cual había sido uno de sus principales aciertos.

Al igual que en la respuesta generada con el primer prompt, el modelo continúa identificando incorrectamente el rango temporal del eje X. En esta ocasión señala que el periodo abarca de 1980 a 2016, mientras que previamente había indicado un rango de 1950 a 2006; sin embargo, el rango correcto de la gráfica corresponde de 1996 a 2024. Evidenciando así que el modelo no logra leer correctamente los valores temporales de la imagen. Asimismo, el modelo sigue sin identificar correctamente el texto ubicado a los costados de la gráfica, el cual es importante para la interpretación del eje Y. Dicho texto indica Producción científica y número de investigadores de tiempo completo; mientras que el modelo lo interpreta erróneamente como frecuencia de citas por artículo. Aunque logra reconocer correctamente el rango numérico del eje Y (de 0 a 250), falla en su comprensión respecto a lo que éste significa.

A diferencia de su respuesta anterior, el modelo agrega detalle a la descripción de la línea de tendencia mencionando su color. Sin embargo, al describir los picos notables menciona años que no corresponden a los picos más relevantes de la gráfica. En particular, señala el año 2007 como un pico, cuando en dicho año no se observa un incremento significativo. Si bien el resto de los años mencionados presentan aumentos, estos no corresponden a los máximos. Lo que indica que no identifica los aspectos más destacables de la gráfica.

De manera similar, el modelo identifica correctamente el color azul de las barras y asocia estas con la cantidad de artículos publicados. Sin embargo, omite por completo la mención del segundo conjunto de barras representadas con un tono de azul más oscuro, las cuales corresponden al número de investigadores; limitando la interpretación al hacer esta omisión. En su análisis de las barras azules, el modelo menciona picos en años que no aparecen en la gráfica por lo que continúa inventando información. Además, señala la existencia de intersecciones entre la línea amarilla y las barras azules en varios puntos, situación que no se observa en la imagen.

No entiende de qué trata la gráfica pues piensa que se indica *el número de citas por artículo en comparación con la cantidad de artículos publicados*, cuando en realidad se trata de la producción científica y el número de investigadores de tiempo completo; y pese a las mejoras introducidas en el segundo prompt, el modelo continúa presentando

limitaciones para generar una interpretación correcta.

Modelo B

Pixtral-12b

La imagen muestra un gráfico de barras superpuesto a una línea de tendencia. El eje horizontal representa el tiempo en años, desde 1980 hasta 2016, con intervalos de aproximadamente dos años. El eje vertical izquierdo mide la frecuencia de citas por artículo, que va desde 0 hasta 250. La línea de tendencia es de color amarillo y parece representar el promedio o una línea de ajuste suave sobre los datos de las barras.

Las barras azules representan la cantidad de artículos publicados cada dos años. Se observa un aumento gradual en la producción de artículos a lo largo **del** tiempo, con un pico notable alrededor **del** año 2014-2016. La línea amarilla muestra una tendencia ascendente que alcanza su máximo cerca **del** final **del** período representado.

En el eje vertical derecho, se puede ver una escala que va desde 0 hasta 350, aunque no está claramente etiquetada para qué representa. Sin embargo, podría estar relacionada con otra métrica relevante como la frecuencia de descargas o accesos a los artículos.

La línea amarilla intersecta con las barras azules en varios puntos, indicando momentos donde el número de citas por artículo coincide con el promedio general de producción. Este tipo de gráfico es útil para analizar cómo la frecuencia de publicación y las citas varían con el tiempo, permitiendo identificar periodos de alta actividad o impacto científico.

La imagen también incluye una nota en la esquina inferior derecha que menciona "www.mendeley.com", sugiriendo que los datos podrían provenir de la plataforma Mendeley, conocida por su función de seguimiento de citas y producción científica.

Tal como se solicitó en el segundo prompt, este modelo se aleja de las respuestas breves y concisas, generando una interpretación más extensa y buscando agregar más detalle. No obstante, siguen los errores en la identificación de los componentes de la

gráfica. En particular, continúa fallando en reconocer correctamente el rango temporal del eje X, afirmando que entre cada barra existen intervalos de dos años, cuando en realidad cada barra corresponde a un año individual.

En relación con el eje Y, el modelo identifica correctamente el rango numérico del lado izquierdo 0 a 250, sin embargo interpreta erróneamente su significado. En esta ocasión y a diferencia de otros modelos, sí logra detectar la existencia de un eje Y en el lado derecho, aunque falla en la identificación de su rango de valores indicando que va de 0 a 350 cuando el rango real es de 0 a 3. Sin embargo, el modelo reconoce explícitamente que no logra distinguir el significado de dicho eje, lo cual constituye un aspecto positivo, ya que se apega a la instrucción de no inventar información no legible y sugiere que en realidad cuando se equivoca no es que invente información sino que no interpreta correctamente ciertos componentes de la imagen, particularmente los valores temporales del eje X, aunque cree que los está identificando con claridad.

Además, el modelo incorpora correctamente detalles visuales como el color de la línea de tendencia y de las barras, acertando al identificar estas últimas como representaciones de los artículos publicados pero sin detectar el otro conjunto de barras azules de tono oscuro. Asimismo, señala intersecciones que no se observan en la gráfica entre la línea de tendencia y las barras.

Finalmente, el modelo continúa mencionando la presencia de sitios web que no son visibles en la imagen. Si bien su capacidad para detectar los componentes en la imagen mejoró, destacando su identificación del eje y derecho que no logró con el primer prompt, su interpretación en general sigue siendo imprecisa y poco confiable.

Modelo C

InternVL3_5-8B-GGUF

La imagen muestra un gráfico de barras superpuesto con una línea de[Trend en caracteres asiáticos] que representa la evolución **del** número de citas por año para el artículo "A new method for determining the number of scientific citations" en el período de tiempo desde 1980 hasta 2016.

Detalles del Gráfico:

- ****Eje X (horizontal)**:** Representa los años, numerados desde 1980 hasta 2016.
- ****Eje Y (vertical)**:** Muestra el número de citas, que va desde 0 hasta 250.

Características Principales:

1. ****Gráfico de Barras****:

- Cada barra representa el número total de citations recibidas en ese año específico.
- Las barras aumentan y disminuyen a lo largo **del** tiempo, mostrando variaciones anuales en la cantidad de citas.

2. ****Línea de Tendencia****:

- La línea amarilla superpuesta sobre las barras indica una tendencia general en el número de citations.
- Se observa un aumento gradual en el número de citas a lo largo **del** tiempo, con algunos picos notables.

3. ****Picos y Valles Relevantes****:

- ****Pico Notable****: Año 2014 muestra un pico considerable en el número de citas, alcanzando uno de los valores más altos.
- ****Valle Notable****: Años tempranos como 1980 y 1985 muestran valores bajos en comparación con años posteriores.

Anotaciones:

- En la esquina superior derecha, hay una anotación que dice "2", posiblemente indicando un valor relevante o una nota adicional sobre el gráfico.
- La fuente de los datos se menciona como "Web of Science".

Narrativa Detallada:

El gráfico ilustra cómo el artículo ha sido citado a lo largo de más de tres décadas. Desde 1980, donde las citas iniciales son relativamente bajas, se observa un aumento gradual en la cantidad de citations. Este incremento sugiere que el artículo ha ganado mayor relevancia y atención con el tiempo.

Los años tempranos muestran una tendencia estable con variaciones menores, pero a partir de 1990, las citas comienzan a aumentar más rápidamente. Este aumento acelerado continúa hasta alcanzar un pico significativo en 2014, donde el artículo parece haber experimentado un incremento notable en su impacto académico.

Posteriormente, aunque hay una ligera disminución después

del pico de 2014, las citas permanecen relativamente altas, lo que indica que el artículo sigue siendo relevante y citado en la comunidad científica. La línea de tendencia refuerza esta observación mostrando una evolución general ascendente.

Este análisis sugiere que el artículo ha mantenido su relevancia a lo largo **del** tiempo, con un momento particularmente activo de citations alrededor de 2014.

Este modelo se alejó de las respuestas concisas generando una interpretación amplia y estructurada, tal como se le pidió. Sin embargo, volvió a incluir caracteres correspondientes a escritura asiática para referirse a la línea de tendencia a pesar de que se indicó explícitamente que la respuesta debía contener únicamente palabras en español.

En su sección dedicada a los detalles de la gráfica, el modelo nuevamente tiene errores en la identificación del eje X, mencionando años que no aparecen en la imagen. En cuanto al eje Y izquierdo, identifica correctamente el rango numérico pero interpreta de forma incorrecta su significado asociándolo al número de citas, cuando esto no corresponde al contenido de la gráfica. Adicionalmente el modelo no logra identificar adecuadamente el eje Y derecho aunque detecta un valor 2 en la esquina superior derecha pero no reconoce que dicho valor forma parte del rango de este eje, el cual se abarca de 0 a 3. Siendo el único modelo que identifica de manera consistente la existencia de un eje Y derecho.

En su interpretación de las características principales, el modelo distingue correctamente que cada barra representa un año individual, a diferencia del modelo B el cual no logró realizar esta distinción correctamente. Al identificar picos relevantes de la línea de tendencia, el modelo señala el año 2014 como el valor más alto, cuando en realidad en ese periodo se observa un decremento. Cabe destacar que el modelo indica erróneamente que la gráfica finaliza en 2016 y que el valor máximo se encontraría hacia el final de la serie en 2014; por lo que, si hubiera detectado correctamente los años, su interpretación del comportamiento general podría haber sido correcta.

Finalmente, el modelo realiza una narrativa detallada que, al ser analizada sin considerar los años específicos y con la gráfica a la mano como referencia, resulta mayormente coherente. Esto sugiere que el modelo no está inventando información de manera arbitraria, sino que presenta dificultades para detectar con precisión los valores temporales del eje X y el significado semántico de la gráfica pues la interpreta como una representación de citas por artículo. Este comportamiento refuerza la hipótesis de que no se está ignorando la instrucción en el prompt de no inventar valores, sino que principalmente los errores observados se originan cuando el modelo cree que está identificando los elementos en la gráfica con claridad.

Observaciones

En conjunto los tres modelos comparten una limitación para llevar a cabo la lectura precisa del eje X, siendo esto lo que principalmente los lleva a generar interpretaciones erróneas; aunque difieren en cómo gestionan esa limitación. Además que no logran realizar una interpretación semántica correcta del contenido de la gráfica.

El modelo A es el menos preciso tanto estructural como semánticamente, no solo mantiene errores previos sino que introduce nuevas inconsistencias, convirtiéndolo en el menos confiable de los tres. Un aspecto relevante es que inventa elementos que no están presentes, como intersecciones entre la línea de tendencia con las barras. El modelo B muestra una mejora respecto al modelo A, aunque sigue presentando errores su comportamiento es menos inventivo. Su principal avance es que esta vez detectó la existencia del eje Y derecho; y si bien se equivoca en el rango de valores, reconoce explícitamente que no puede identificar su significado. Esto sugiere no ignora la instrucción de no inventar información no legible, sino que cuando se equivoca es porque no está detectando correctamente ciertos componentes de la imagen aunque cree que los está identificando con claridad.

El modelo C es el que presenta el mayor nivel de precisión, aunque no está exento de errores. Cumple adecuadamente con la instrucción de generar una respuesta extensa y estructurada, y a diferencia del modelo B identifica correctamente que cada barra corresponde a un año individual, lo que representa una mejora en la lectura de la gráfica. Asimismo, destaca por su reconocimiento del eje Y derecho, algo que los otros modelos no lograron identificar de manera consistente; este modelo lo detecta con ambos prompts e incluso logra reconocer parcialmente uno de sus valores. Un aspecto clave de su interpretación es que el comportamiento general de la gráfica resulta coherente si se abstraen los años específicos, lo que sugiere que el modelo es capaz de captar patrones visuales aunque presenta dificultades en la asociación precisa entre etiquetas, valores y su significado semántico.

Sin embargo, este nivel de desempeño no es suficiente para el tipo de generación automática de interpretaciones que se busca, ya que el objetivo es alcanzar un mayor grado de precisión y detalle. Por ello, además de diseñar un nuevo prompt con nuevas especificaciones.

5.1.3. Tercer prompt

Se realizaron pruebas con los modelos anteriores, a excepción del modelo A, y agregando además otro par de LLMs para evaluar si es posible mejorar la exactitud y confiabilidad en los resultados.

Tercer Prompt de Prueba

```
1 messages=[
2     {"role": "system",
```

```
3      "content": "Eres un científico de datos experto en
      cienciometría y en la interpretación de gráficos y
      representaciones visuales científicas. Debes
      priorizar la precisión y evitar cualquier suposición
      no respaldada visualmente."},
4  {"role": "user", "content": [
5    {"type": "text",
6      "text": "Analiza únicamente la información visible
      en la imagen proporcionada. No incluyas
      introducciones ni conclusiones generales.
      Estructura tu respuesta obligatoriamente en las
      siguientes secciones: 1) Elementos explícitamente legibles en la imagen. 2) Componentes
      visuales identificables (tipo de gráfica, ejes
      , colores, símbolos). 3) Patrones visuales
      generales observables (tendencias, aumentos o
      disminuciones). 4) Inferencias permitidas,
      claramente marcadas como inferencias. 5)
      Elementos no legibles, ambiguos o no
      identificables. No menciones años específicos,
      valores exactos, rangos temporales,
      intersecciones o significados de ejes a menos
      que estén claramente indicados y sean legibles
      en la imagen. Si un dato no puede leerse con
      claridad, indícalo explícitamente como no
      legible o no identificable. No inventes valores
      , fechas, unidades ni significados semánticos.
      La respuesta debe estar escrita únicamente en
      español y mantener un tono técnico."},
7    {"type": "image_url",
8      "image_url": {"url": image_uri}}
9  ]}
10 ]
```

5.2. Generación automática de reportes cienciométricos del ICN y/o de la Facultad de Ciencias de la UNAM

6 Conclusiones y trabajo a futuro

- 6.1. Utilidad en la práctica profesional
- 6.2. Potencial para investigación y gestión científica
- 6.3. Limitaciones y retos futuros

Bibliografía

- [1] Price, D de S. 1963. Little Science, Big Science. Columbia University, New York 119: 119.
- [2] Edward R. Tufte. The Visual Display of Quantitative Information. 1983 / 2nd Edition 2001. Graphics Press.
- [3] Omiye JA, Gui H, Rezaei SJ, Zou J, Daneshjou R. Large Language Models in Medicine: The Potentials and Pitfalls : A Narrative Review. Ann Intern Med. 2024 Feb;177(2):210-220. doi: 10.7326/M23-2772. Epub 2024 Jan 30. PMID: 38285984.
- [4] Alammar, J., & Grootendorst, M. (2024). Hands-on large language models. O'Reilly.
- [5] José Luis Jiménez-Andrade, Ricardo Arencibia-Jorge, Miguel Robles-Pérez, Julia Tagüeña, Tzipe Govezensky, Humberto Carrillo-Calvet, Rafael A Barrio, Kimmo Kaski, Organizational changes and research performance: A multidimensional assessment, Research Evaluation, Volume 33, 2024, rva005, <https://doi.org/10.1093/reseval/rva005>
- [6] Jiménez Andrade, José Luis. Métodos y aplicaciones de la red neuronal SOM para el análisis temporal de datos multidimensionales. Tesis de doctorado, INFOTEC 2003. <https://infotec.repositorioinstitucional.mx/jspui/handle/1027/643>