



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

FACULTAD DE CIENCIAS

APLICACIÓN DE MODELOS DE LENGUAJE DE GRAN
ESCALA AL ANÁLISIS DE BASES DE DATOS DE
ARTÍCULOS CIENTÍFICOS

T E S I S

QUE PARA OBTENER EL TÍTULO DE:

LICENCIADA EN CIENCIAS DE LA COMPUTACIÓN

P R E S E N T A:

ANA VALERIA DELOYA ANDRADE

TUTOR:

DR. JOSÉ LUIS JIMÉNEZ ANDRADE



CIUDAD UNIVERSITARIA, CDMX, 2026

«Mathematical science shows what is. It is the language of unseen relations between things. But to use and apply that language, we must be able to fully to appreciate, to feel, to seize the unseen, the unconscious.»

Ada Lovelace

Agradecimientos

Siendo este mi proyecto de titulación, me gustaría comenzar agradeciendo a mis padres por su apoyo en cada etapa de mi vida académica. Habría sido mucho más difícil llegar hasta aquí sin ustedes.

A mi hermana, por escucharme innumerables veces hablar sobre el desarrollo de este y de todos los proyectos que realicé a lo largo de la carrera.

A mi novio, por todas las veces que me dio ánimos, ya fuera antes de exposiciones, exámenes o proyectos, y especialmente durante la realización de este trabajo; gracias también por creer en mí en cada momento.

A mi gatito, por sus ronroneos y porque, aunque podía dormir cómodamente en su casita, insistía en hacerse bolita en una silla a mi lado para acompañarme durante las madrugadas de desvelo.

Finalmente, a mi tutor, por enseñarme estas herramientas y por brindarme los recursos necesarios para llevar a cabo este proyecto.

Índice general

Agradecimientos	III
1. Introducción	1
1.1. Contexto de la investigación	1
1.2. Motivación y relevancia	2
1.3. Planteamiento del problema	3
2. Análisis y visualización de datos cienciométricos y LLMs	4
2.1. Conceptos básicos de la ciencimetría	4
2.2. Visualización de datos	7
2.3. Modelos de lenguaje de gran escala (LLMs)	14
3. Generación automática de reportes cienciométricos	32
3.1. Arquitectura general	32
3.2. Diagrama(s) de secuencia	34
4. Implementación e integración	36
4.1. Descripción del sistema	36
4.2. Tecnologías utilizadas	39
5. Aplicación o estudio de caso	43
5.1. Análisis comparativo de modelos	43
5.2. Generación automática de reportes cienciométricos del ICN y/o de la Facultad de Ciencias de la UNAM	68
6. Conclusiones y trabajo a futuro	75
6.1. Utilidad en la práctica profesional	75
6.2. Potencial para investigación y gestión científica	76
6.3. Limitaciones y retos futuros	76

1 Introducción

1.1. Contexto de la investigación

En los últimos años, el desarrollo de la *Inteligencia Artificial* (IA) ha experimentado un crecimiento acelerado, generando un gran impacto y transformando múltiples ámbitos de la vida cotidiana. Como resultado, la IA se ha integrado progresivamente en diversas aplicaciones tecnológicas que forman parte del entorno digital contemporáneo, modificando la forma en que los usuarios acceden a la información y automatizan distintas actividades. Esta integración puede observarse en los sistemas inteligentes presentes en dispositivos cotidianos. Por ejemplo, los asistentes de voz, empleados inicialmente para gestionar tareas domésticas y realizar consultas, permiten actualmente controlar dispositivos inteligentes, ofrecer recomendaciones personalizadas e incluso responder a ciertas solicitudes sin necesidad de conexión a internet.

Asimismo, han surgido avances más complejos derivados del desarrollo de modelos de aprendizaje profundo o *deep learning*. Entre ellos destacan los modelos de lenguaje de gran escala, conocidos como *Large Language Models* (LLMs), cuyo crecimiento en capacidad ha permitido ampliar significativamente las tareas que pueden realizar. Inicialmente diseñados para el procesamiento y generación de texto, estos modelos han evolucionado hacia sistemas multimodales capaces de analizar e interpretar distintos tipos de datos. En particular, muchos de estos modelos pueden procesar información visual además de texto, lo que les permite analizar diversas visualizaciones de datos, como gráficas de barras, gráficas de líneas o mapas generados mediante técnicas de análisis como las redes neuronales *Self-Organizing Maps* (SOM).

Estas capacidades abren nuevas posibilidades para la automatización del análisis de información, especialmente en campos en los que la interpretación de visualizaciones de datos constituye una parte fundamental del trabajo analítico.

En este contexto, entran disciplinas como la *cienciometría*, encargada de estudiar la actividad científica a través del análisis cuantitativo de distintos indicadores, genera una gran cantidad de representaciones visuales destinadas a facilitar la comprensión de patrones presentes en la producción científica. Sin embargo, la interpretación de estas visualizaciones suele requerir de un análisis especializado, lo que plantea la posibilidad de utilizar herramientas de inteligencia artificial para asistir en la generación automática de descripciones e interpretaciones de los datos representados.

A partir de estas consideraciones, el presente proyecto explora el uso de modelos de lenguaje de gran escala para la automatización de la generación de texto interpretativo a partir de representaciones visuales obtenidas de un reporte *cienciométrico*.

Como parte de este proyecto se desarrolló un sistema capaz de generar explicaciones textuales sobre visualizaciones relacionadas con la producción científica del Instituto de Ciencias Nucleares de la Universidad Nacional Autónoma de México (UNAM), presentando dicha información en un formato ordenado y estructurado.

1.2. Motivación y relevancia

El desarrollo reciente de los modelos de lenguaje de gran escala ha abierto nuevas posibilidades para la automatización de tareas relacionadas con el análisis y la generación de información textual. Gracias a su capacidad para procesar distintas modalidades de datos y producir respuestas coherentes en lenguaje natural, estos modelos han comenzado a utilizarse en diversos contextos académicos y profesionales como herramientas de apoyo para la interpretación y síntesis de información.

Sin embargo, a pesar de sus avances, aún persisten interrogantes sobre el alcance real de sus capacidades, especialmente en tareas que involucran representaciones visuales complejas. Evaluar el desempeño de estos modelos en este tipo de contextos es fundamental para comprender sus limitaciones y determinar en qué medida pueden ser utilizados de forma confiable en entornos de investigación.

En el caso particular de la cienciometría, el análisis de la actividad científica suele representarse mediante diversas visualizaciones de datos destinadas a facilitar la identificación de patrones en la producción científica. La interpretación de estas visualizaciones requiere, en muchos casos, la elaboración de textos explicativos que describan tendencias, relaciones o comportamientos presentes en los datos. En este sentido, el uso de modelos de lenguaje de gran escala plantea una oportunidad interesante para explorar nuevas formas de asistencia en la elaboración de reportes científicos. Sistemas de este tipo podrían contribuir a reducir el tiempo dedicado a tareas de interpretación y redacción, además de facilitar la comunicación de resultados hacia audiencias no especializadas en el ámbito cienciométrico.

Asimismo, desde la perspectiva de la formación profesional en Ciencias de la Computación, el desarrollo de un sistema que integre este tipo de herramientas resulta relevante al involucrar conocimientos relacionados con tecnologías emergentes como la inteligencia artificial, así como con la ciencia de datos y el análisis de información científica aplicados a problemas reales vinculados con la producción y comunicación del conocimiento científico.

1.3. Planteamiento del problema

El estudio de la ciencia, conocido como *science of science*, busca comprender los procesos que determinan el desarrollo y la organización de la actividad científica. Dentro de este campo, la cienciometría constituye una disciplina instrumental orientada a cuantificar dicho desarrollo mediante indicadores bibliométricos y herramientas de análisis basadas en publicaciones científicas, cuyos resultados se comunican habitualmente a través de representaciones visuales como gráficas, tablas y mapas para facilitar la comprensión en la evolución de la productividad científica, los patrones de colaboración entre instituciones e investigadores y las dinámicas de publicación del conocimiento.

Sin embargo, la interpretación de estas representaciones visuales suele requerir un tiempo considerable, ya que demanda atención especializada y experiencia analítica, en especial cuando se trabaja con reportes extensos o con una gran cantidad de visualizaciones. Esta situación plantea la necesidad de explorar herramientas que permitan asistir o automatizar parte de este proceso.

En este contexto, los modelos de lenguaje de gran escala LLMs, particularmente en sus versiones multimodales, ofrecen una oportunidad relevante. En este proyecto se explora en qué medida estas herramientas son capaces de automatizar tareas de análisis al generar interpretaciones cienciométricas coherentes y precisas a partir del análisis de representaciones visuales, con el objetivo de agilizar el trabajo de quienes producen reportes cienciométricos así como contribuir a mejorar la accesibilidad y comunicación de sus resultados.

2 Análisis y visualización de datos cientiométricos y LLMs

2.1. Conceptos básicos de la cienciometría

Para comprender el origen de la cienciometría es necesario partir de una idea que en su momento resultó poco habitual: la ciencia puede medirse. Esta perspectiva fue desarrollada por Derek J. de Solla Price en su obra *Little Science, Big Science*, donde plantea que la actividad científica no solo debe analizarse por el contenido de sus descubrimientos sino también por su dinámica de crecimiento. Price señala que, al analizar distintos indicadores de la actividad científica, se observa que el modo normal de crecimiento es exponencial, es decir, que la ciencia tiende a duplicar su tamaño, en términos de publicaciones, instituciones e investigadores, durante periodos relativamente cortos De Solla Price (1963). Sugiriendo mediante este comportamiento que la actividad científica se expande de manera acumulativa, donde el aumento en el número de investigadores y resultados genera a su vez nuevas investigaciones y publicaciones.

Este crecimiento puede comprenderse mejor a través de la transición que Price denomina de la *Little Science* a la *Big Science*. La primera suele asociarse con la imagen del investigador que trabaja de forma individual y con recursos limitados, mientras que la segunda describe una ciencia organizada en instituciones, financiada a gran escala y desarrollada por equipos numerosos en contextos nacionales e internacionales. Esta transformación no ocurrió de manera repentina ni puede explicarse únicamente a partir de descubrimientos particulares como el desarrollo de la energía nuclear o la carrera espacial. Se trata, más bien, de un proceso gradual en el que la actividad científica fue aumentando progresivamente su tamaño, su complejidad organizativa y su presencia dentro de la sociedad.

La evidencia más concreta de este crecimiento puede observarse en la evolución de la comunicación científica. A partir de 1660, con la creación de las primeras sociedades científicas modernas y la aparición de las primeras revistas especializadas, los científicos comenzaron a difundir sus resultados principalmente a través de artículos en lugar de libros. Desde entonces, el número de publicaciones ha aumentado de manera sostenida. En la actualidad existen más de 50,000 revistas científicas en todo el mundo que han producido unos seis millones de artículos científicos, con un incremento aproximado de al menos medio millón de nuevos trabajos publicados cada año.

Además de servir como medio de difusión del conocimiento, los artículos científicos llegaron a cumplir una función social dentro de la comunidad académica, permitiendo a los investigadores establecer la prioridad sobre sus descubrimientos y reclamar la autoría de nuevas ideas o resultados. Cada nueva investigación se apoya en trabajos previos y, al mismo tiempo, se convierte en punto de partida para estudios posteriores. Esta relación se manifiesta a través de las referencias y citaciones bibliográficas, que conectan las publicaciones entre sí y permiten seguir el desarrollo de un campo de investigación. A partir del siglo XIX comenzó a consolidarse el uso sistemático de referencias bibliográficas dentro de los artículos científicos, haciendo posible identificar los trabajos previos sobre los que se construye una investigación, así como también visibilizando la estructura acumulativa del conocimiento científico.

Por otro lado, el crecimiento también puede observarse en la composición de la comunidad científica. Mientras que a mediados del siglo XVII los científicos constituían un grupo tan reducido que podía identificarse individualmente, hoy en día tan solo en Estados Unidos existe al menos un millón de personas dedicadas a la investigación, distribuidas en universidades, centros de investigación e industrias tecnológicas. Se estima, además, que entre el 80 y el 90 % de todos los científicos que han existido se encuentran vivos en la actualidad (De Solla Price, 1963), lo que ilustra la magnitud de la expansión en la actividad científica.

Analizando en conjunto estos indicadores, es decir, el número de publicaciones, revistas especializadas y crecimiento del número de investigadores, Price señala que la ciencia tiende a duplicarse aproximadamente cada diez o quince años. Esto significa que el volumen total de la producción científica aumenta rápidamente con el paso del tiempo, generando cantidades cada vez mayores de información, producción académica e infraestructura institucional. El reconocimiento de estos patrones tiene una consecuencia fundamental: si la ciencia presenta regularidades medibles, entonces es posible analizarla mediante métodos cuantitativos. A partir de esta idea surge la *cienciometría*, entendida como el estudio de la actividad científica a través de indicadores estadísticos que permiten describir su producción, evolución, impacto y organización.

Estos indicadores, contruidos a partir del análisis de publicaciones científicas y de las relaciones que se establecen entre ellas, particularmente a través de las citaciones, no constituyen medidas absolutas de calidad sino herramientas que hacen posible comparar y contextualizar la producción científica dentro de un período específico. Entre los más utilizados se encuentran el número de publicaciones, que permite medir la productividad científica, y el número de citas recibidas, que suele emplearse como indicador de la influencia o impacto que un autor o trabajo tiene sobre investigaciones posteriores. También existen métricas más complejas, como el factor de impacto de las revistas científicas o el índice h , propuesto por Jorge E. Hirsch en 2005 (Hirsch, 2005). Este indicador busca combinar en una sola medida la productividad y el impacto de un investigador al identificar el número h de trabajos de un autor que han recibido al menos h citas cada uno.

La utilidad de estos indicadores, sin embargo, no depende únicamente de su capacidad para cuantificar la actividad científica sino también de la forma en que se comunican sus resultados. Cuando los volúmenes de datos son grandes y las relaciones entre variables son complejas, la interpretación de cifras en formatos textuales resulta limitada. Es en este contexto donde la visualización de datos cobra relevancia como una herramienta complementaria al análisis cuantitativo, permitiendo transformar grandes conjuntos de información en representaciones gráficas que facilitan su comprensión, comparación y comunicación.

2.2. Visualización de datos

En la visualización o representación visual de datos, los elementos gráficos no cumplen únicamente una función estética sino que constituyen el medio mediante el cual la información es representada y comunicada. Cuando el diseño está bien elaborado, es posible representar información compleja de manera clara, aprovechando de forma eficiente el espacio disponible y reduciendo ambigüedades en la interpretación, trascendiendo así su papel como simples soportes de los datos para convertirse en instrumentos de análisis.

Desde las primeras visualizaciones utilizadas en el ámbito científico hasta las actuales, puede observarse una evolución orientada a incrementar la cantidad de información mostrada sin perder el foco en el fenómeno que se busca representar. De modo que no solo permiten presentar datos sino que facilitan al lector la identificación de patrones, relaciones y tendencias que no resultarían evidentes en formatos textuales.

Cada elemento visual debe contribuir a la comunicación de la información. Un ejemplo que ilustra esta idea es el diagrama de tallo y hoja o *stem-and-leaf plot* (Figura 2.1), cuya estructura facilita el análisis de los conjuntos de datos, ya que los propios valores numéricos conforman directamente los elementos que representan su distribución.




Figura 2.1: Ejemplo de diagrama de tallo y hoja representando alturas de volcanes

Este tipo de visualizaciones no actúan únicamente como un contenedor de información sino que los datos mismos construyen la forma visual, permitiendo visualizar simultáneamente la forma de la distribución y conservar los valores originales.

Una misma visualización puede cumplir varias funciones al mismo tiempo: mostrar valores, indicar magnitudes, revelar estructuras y aportar significado al conjunto de la representación.

Gracias a ello es posible comunicar distintas dimensiones de los datos en una sola figura. Sin embargo, para que esta riqueza informativa sea comprensible, la visualización debe mantener claro el contexto del fenómeno que busca comunicar. La interpretación de los datos no depende únicamente de los elementos visuales que aparecen sino de que el lector pueda entender qué se está representando y con respecto a qué se está comparando (Figura 2.2). Cuando los datos se presentan de forma aislada o sin ese marco de referencia, la lectura de la gráfica se vuelve incompleta y puede dar lugar a interpretaciones parciales o erróneas.



Figura 2.2: Ejemplo de gráfica de líneas sobre muertes por accidentes de tránsito

De igual forma, la visualización de datos también se relaciona con el concepto de densidad informativa, que plantea la posibilidad de concentrar una gran cantidad de información en un espacio reducido sin perder claridad, siempre que el diseño sea adecuado. Esto permite realizar comparaciones más completas al contar con una mayor cantidad de datos, reconociendo así relaciones relevantes y ofreciendo un contexto más amplio para la interpretación de la figura.

Lo que se busca es mostrar la mayor cantidad de información posible manteniendo la legibilidad y la interpretación correcta de los datos sin sobrecargar la visualización. Para ello se emplean elementos gráficos básicos como las barras, puntos, líneas o áreas; que no solo representan valores sino que también pueden comunicar información adicional mediante atributos visuales como el color, la intensidad o la forma.

Esta capacidad de transmitir varias dimensiones de los datos en una sola representación amplía su potencial analítico pero al mismo tiempo plantea un reto de diseño. Cuando las codificaciones visuales se utilizan de manera excesiva o poco clara, la gráfica puede volverse difícil de leer. En particular, la incorporación innecesaria de elementos y patrones visuales puede generar efectos perceptuales sobrecargados y no deseados pues distraen la atención del lector y dificultan la identificación de la información realmente relevante (Figura 2.3).




Figura 2.3: Ejemplo de gráficas sobre la producción de tejidos de algodón

Para evitar estas distorsiones y asegurar que la representación visual sea fiel a los datos, es necesario considerar los principios de integridad gráfica Tufte (2001). Estos establecen que los elementos visuales deben ser proporcionales a las magnitudes que representan, contar con un etiquetado claro y suficiente, mostrar la variación real de los datos y mantener siempre su contexto de referencia. Asimismo, el número de dimensiones visualizadas no debe exceder las dimensiones presentes en los datos y, en el caso de las series temporales, es recomendable utilizar unidades comparables que permitan interpretaciones correctas.

El cumplimiento de estos criterios no solo mejora la claridad de la visualización sino que también fortalece su validez analítica, ya que evita interpretaciones erróneas y garantiza que la visualización comunique la información de manera precisa y transparente.

Este equilibrio entre riqueza informativa y claridad gráfica es fundamental en las visualizaciones utilizadas en el ámbito de la cienciometría, donde es necesario representar un mismo fenómeno a partir de múltiples variables. En este contexto, es común integrar en una sola figura aspectos como la producción científica, el impacto, las redes de colaboración y su evolución temporal. A continuación, se describen y ejemplifican algunas de las visualizaciones más utilizadas para la transmisión de datos cienciométricos.

Las *gráficas de barras* son una de las formas más empleadas para la representación de este tipo de datos. La longitud de cada barra es proporcional al valor que representa, lo que hace posible comparar magnitudes entre diferentes categorías de manera clara, identificar tendencias generales y reconocer concentraciones de la producción científica. La Figura 2.4 muestra un ejemplo de este tipo de representación, en el que las variaciones en la altura de las barras permiten distinguir de forma inmediata las diferencias entre los datos. Asimismo, se puede observar la incorporación adecuada de patrones visuales, donde cada uno cumple la función de diferenciar las categorías sin sobrecargar la visualización.




Figura 2.4: Ejemplo de gráfica de barras

Por su parte, las *gráficas de líneas* se emplean principalmente para representar la evolución de una variable a lo largo del tiempo. Mediante la conexión de puntos consecutivos, este tipo de visualización permite identificar tendencias, cambios en el crecimiento, periodos de estabilidad o decrementos en indicadores como el número de artículos publicados en distintos intervalos temporales. Su estructura facilita la lectura continua de los datos y la detección de patrones que difícilmente podrían reconocerse en tablas. La Figura 2.5 presenta un ejemplo en el que es posible observar con claridad el comportamiento temporal del fenómeno representado.



Figura 2.5: Ejemplo de gráfica de líneas

Los *gráficos de dispersión* (Figura 2.6) constituyen otra forma de visualización en la que cada punto representa una observación definida por dos variables. Esto hace posible reconocer relaciones, agrupamientos o comportamientos atípicos dentro del conjunto de datos, favoreciendo una lectura comparativa dentro del mismo campo visual. Desde la perspectiva del diseño de visualizaciones, este tipo de gráfico destaca por su alta densidad informativa, ya que permite representar un número considerable de observaciones sin recurrir a elementos innecesarios.




Figura 2.6: Ejemplo de gráfico de dispersión

La Figura 2.7 ilustra un diagrama de caja o *box plot*. En este tipo de visualización se representan la mediana, los cuartiles y los valores extremos de la distribución, así como los posibles valores atípicos, a partir de los datos ordenados. Esto posibilita identificar de manera rápida la dispersión, el grado de simetría y la presencia de observaciones alejadas del comportamiento general. A diferencia de otras gráficas centradas en frecuencias o tendencias temporales, el diagrama de caja resulta útil para comparar múltiples conjuntos de datos y observar sus diferencias en términos de distribución y posición central. En el ámbito cuantitativo, estas representaciones facilitan la detección de publicaciones o investigadores con un número excepcionalmente alto de citas, que se apartan del patrón predominante del conjunto de datos analizado.




Figura 2.7: Ejemplo de diagrama de caja

Para finalizar, tenemos los mapas autoorganizados o *Self-Organizing Maps* (Figura 2.8), un método de aprendizaje automático no supervisado orientado al agrupamiento y la exploración de datos (Kohonen, 2013). Su funcionamiento consiste en asociar los datos de entrada con los nodos de una rejilla bidimensional, de tal manera que los elementos con características similares se ubican en regiones cercanas, mientras que los menos similares se sitúan a mayor distancia.

Aunque su propósito no es la visualización en sí misma, esta organización topográfica facilita la proyección de información multidimensional en un espacio bidimensional, preservando relaciones de similitud entre los datos. Como resultado, los SOM pueden emplearse como una herramienta de representación visual que permite identificar agrupamientos y patrones en conjuntos de datos complejos.




Figura 2.8: Ejemplo de mapas autoorganizados

En el ámbito de la cienciometría, los mapas autoorganizados se han consolidado como un método idóneo para la minería de datos informétricos orientada al descubrimiento de conocimiento (Sotolongo-Aguilar et al., 2001). Estos modelos permiten explorar la información sin necesidad de definir previamente su estructura, favoreciendo la identificación de patrones y la obtención de características cualitativas a partir de los datos. Su uso pone de manifiesto cómo la visualización de datos se vincula con métodos computacionales capaces de procesar grandes volúmenes de información y revelar estructuras complejas que no serían accesibles mediante enfoques tradicionales, al mismo tiempo que facilita una exploración visual que contribuye a una mejor comprensión de las relaciones subyacentes en los datos.

No obstante, aunque su interpretación general suele ser relativamente intuitiva, el proceso subyacente de entrenamiento es computacionalmente intensivo y el análisis detallado de la superficie resultante puede requerir un tiempo considerable, debido a la gran cantidad de información que se sintetiza en una sola representación.

En consecuencia, surge la necesidad de herramientas que permitan asistir en la interpretación de estas representaciones complejas, así como en la generación automática de descripciones y análisis a partir de información visual. Esta necesidad motiva el estudio de modelos más avanzados para el análisis e interpretación conjunta de información visual y textual, como es el caso de los modelos de lenguaje de gran escala LLMs, los cuales serán abordados a continuación.

2.3. Modelos de lenguaje de gran escala (LLMs)

Antes de abordar de manera específica el concepto de los modelos de lenguaje de gran escala, es conveniente contextualizarlos dentro de un marco más amplio como lo es el aprendizaje automático o *machine learning*, una disciplina que forma parte del campo de la Inteligencia Artificial.

Tradicionalmente, algunos algoritmos informáticos son programados explícitamente por un desarrollador con el objetivo de ejecutar una tarea determinada siguiendo una secuencia lógica predefinida. Sin embargo, en el aprendizaje automático el enfoque es distinto, en lugar de codificar paso a paso la solución, el sistema aprende patrones a partir de grandes volúmenes de datos de entrenamiento. En este escenario, el papel del programador se desplaza de la escritura directa del algoritmo hacia el diseño del proceso de entrenamiento que permitirá al modelo aprender a partir de ejemplos.

Durante décadas, gran parte de la investigación en aprendizaje automático se orientó al desarrollo de modelos predictivos, diseñados para estimar resultados futuros o clasificar información en tareas específicas, como la predicción meteorológica, la detección de fraudes o la optimización de rutas logísticas. Como se ilustra en la Figura 2.9, el enfoque tradicional del aprendizaje automático se caracterizaba por entrenar un modelo para una tarea concreta a partir de datos estructurados, siguiendo un esquema en el que cada problema requería el diseño y entrenamiento de un modelo independiente.



Figura 2.9: Aprendizaje automático tradicional

Dentro del aprendizaje automático, una de las subáreas que ha tenido mayor impacto en los últimos años es el aprendizaje profundo o deep learning. Este enfoque se basa en el uso de redes neuronales artificiales, modelos inspirados de manera abstracta en el funcionamiento del cerebro humano y compuestos por múltiples capas de unidades interconectadas o neuronas artificiales que transforman progresivamente los datos de entrada para identificar patrones complejos.

El desarrollo del deep learning, junto con el incremento en la capacidad computacional y la disponibilidad masiva de datos, permitió entrenar modelos de mayor escala. En este contexto surgieron los denominados modelos generativos, cuyo objetivo no es únicamente predecir o clasificar información, sino producir nuevo contenido a partir de las regularidades aprendidas durante el entrenamiento.

En este marco emergen los modelos de lenguaje de gran escala (*Large Language Models*, LLMs), los cuales constituyen una aplicación específica del deep learning al procesamiento del lenguaje natural. Estos modelos son redes neuronales profundas, generalmente basadas en la arquitectura Transformer, diseñadas para modelar secuencias lingüísticas y generar texto de manera autoregresiva mediante la predicción probabilística de tokens sucesivos. Al ser entrenados con grandes corpus textuales, adquieren la capacidad de capturar relaciones sintácticas y semánticas complejas, lo que les permite producir texto coherente y contextualmente adecuado.

El término *large* (gran escala) hace referencia tanto al volumen de datos utilizados durante el entrenamiento como a la cantidad de parámetros que conforman el modelo. Estos parámetros son valores numéricos que determinan el peso de las conexiones internas dentro de la red neuronal y regulan la contribución de cada unidad de procesamiento o neurona artificial en la generación de la salida. En modelos contemporáneos, esta cantidad puede alcanzar miles de millones de parámetros, lo que les permite capturar regularidades del lenguaje y modelar patrones complejos. Por ejemplo, el modelo GPT-3 de OpenAI contiene 175 millones de parámetros, los cuales fueron aprendidos a partir del entrenamiento con aproximadamente 45 terabytes de datos textuales (Oshin, 2024).

Por su parte, el término *language model* (modelo de lenguaje) se refiere a un modelo de aprendizaje automático que asigna una distribución de probabilidad sobre las posibles palabras siguientes en una secuencia (Jurafsky, 2026), lo que le permite, dado un texto de entrada, predecir cuál es la continuación más probable.

Los modelos de lenguaje de gran escala se entrenan precisamente bajo este principio, aprendiendo a predecir la siguiente palabra a partir de las anteriores. A partir de esta tarea, el modelo adquiere conocimiento sobre estructuras gramaticales, relaciones semánticas y patrones discursivos, permitiéndole así la generación de texto coherente además de adaptarse a distintas tareas sin requerir arquitecturas específicas para cada una. Para aprovechar esta capacidad, el usuario interactúa con el modelo mediante un texto de entrada que orienta la predicción. A dicho texto de entrada se le conoce como *prompt*, y su formulación influye significativamente en la calidad de la respuesta generada.




Figura 2.10: LLM recibiendo un prompt y generando una respuesta

Funcionamiento interno

Desde una perspectiva funcional, el comportamiento de estos modelos puede entenderse como una forma avanzada de autocompletado en la que se estima la palabra o secuencia más probable dada una entrada previa. Para llevar a cabo este proceso, el texto de entrada no se procesa directamente como palabras completas, sino que previamente atraviesa una etapa de tokenización.

En esta etapa, el texto se segmenta en unidades mínimas denominadas tokens, que pueden corresponder a palabras completas, subpalabras o caracteres, dependiendo del método utilizado. La definición de estas unidades depende de un vocabulario previamente construido durante la fase de entrenamiento del tokenizador a partir de un corpus textual (Figura 2.11).




Figura 2.11: Entrenamiento del tokenizador

Una vez aprendido, este vocabulario permanece fijo y es utilizado para transformar cualquier nuevo texto de entrada en una secuencia de identificadores numéricos únicos. De este modo, los modelos de lenguaje no operan directamente sobre el texto en sentido literal sino sobre secuencias de valores numéricos que representan dichas unidades lingüísticas (Figura 2.12). A partir de esta representación, el modelo calcula una distribución de probabilidad sobre los elementos del vocabulario y selecciona el token más probable según el contexto. Este procedimiento se realiza de manera auto-regresiva, de manera que cada token generado se incorpora a la secuencia de entrada y pasa a formar parte del contexto utilizado para realizar la siguiente predicción.




Figura 2.12: Tokenización: codificación

La manera en que un tokenizador descompone el texto está determinada tanto por el método de tokenización empleado como por los parámetros definidos durante su inicialización. Estos factores condicionan la forma en que el texto es segmentado y, en consecuencia, la estructura del vocabulario resultante.

Existen diversos métodos de tokenización, cada uno de los cuales define un algoritmo para seleccionar un conjunto adecuado de tokens que represente de manera eficiente un corpus textual. Entre los más utilizados se encuentra *byte pair encoding (BPE)* Alammr (2024), un algoritmo basado en subpalabras que construye el vocabulario a partir de un conjunto inicial de unidades básicas como caracteres o bytes, y aprende de manera iterativa a fusionar los pares más frecuentes. Este procedimiento permite generar vocabularios compactos y al mismo tiempo representar de forma eficiente tanto palabras frecuentes como términos poco comunes mediante su descomposición en subunidades.




Figura 2.13: Ejemplo del algoritmo BPE

Por su parte, la elección de los parámetros del tokenizador determina la configuración final del vocabulario. Entre ellos destaca su tamaño, es decir la cantidad de tokens que lo componen, lo que implica un equilibrio entre granularidad y eficiencia; vocabularios más amplios permiten representar con mayor frecuencia palabras completas, mientras que vocabularios más reducidos favorecen la segmentación en subunidades y una mejor generalización ante términos poco frecuentes. Asimismo, se definen los denominados tokens especiales, que cumplen funciones estructurales dentro del modelo como indicar el inicio y el final de una secuencia o representar elementos desconocidos.

También se establece el tratamiento de las mayúsculas y minúsculas, el cual influye en el aprovechamiento del espacio del vocabulario. La distinción entre ambas provoca que una misma palabra pueda aparecer en múltiples variantes, incrementando el número de tokens necesarios, pero permitiendo conservar información semántica como la identificación de nombres propios, acrónimos o entidades específicas. Por el contrario, la normalización a minúsculas reduce el tamaño del vocabulario y mejora la eficiencia del modelo, aunque implica la pérdida de dichas distinciones.

No obstante, el comportamiento de un tokenizador no depende únicamente del método y de los parámetros seleccionados, sino que también varía en función del corpus con el que ha sido entrenado, ya que es este el que determina las unidades lingüísticas que serán representadas en el vocabulario y la forma en que el texto será segmentado. Este proceso se realiza de manera previa e independiente del entrenamiento del modelo de lenguaje, pero condiciona la forma en que tanto los datos de entrenamiento como los textos de entrada son interpretados posteriormente por el modelo.

Cabe señalar que los tokenizadores no solo se emplean para procesar el texto de entrada que se introduce en el modelo, sino también para transformar su salida. En esta etapa, los identificadores numéricos correspondientes a los tokens generados son convertidos nuevamente en sus representaciones lingüísticas, permitiendo de esta forma obtener el texto final en un formato comprensible (Figura 2.14).




Figura 2.14: Tokenizador: decodificación

Una vez definido el proceso de tokenización y establecido el vocabulario correspondiente, el modelo de lenguaje no trabaja directamente sobre los identificadores numéricos de los tokens. En su lugar, a cada token se le asocia una representación numérica en forma de vector, denominada *embedding*. Estos vectores constituyen el punto de partida para el procesamiento interno del modelo.

Dado que el tokenizador se entrena previamente y queda vinculado al modelo, este último incorpora el conjunto de todas estas representaciones organizándolas en una estructura denominada *matriz de embeddings*, en la que cada token del vocabulario posee su propio vector asociado (Figura 2.15). Durante el entrenamiento del modelo, estos vectores se ajustan junto con el resto de los parámetros, de modo que terminan capturando regularidades sintácticas y semánticas presentes en el corpus textual.




Figura 2.15: Relación entre el tokenizador y la matriz de embeddings del modelo

Una vez obtenidas estas representaciones vectoriales, el modelo las procesa mediante una serie de bloques o capas neuronales que conforman la arquitectura *Transformer*.

De modo que, el tokenizador proporciona el conjunto de tokens y sus identificadores numéricos, mientras que el modelo de lenguaje contiene los embeddings asociados a cada uno de ellos y los procesa a través de una pila de bloques Transformer (Figura 2.16).




Figura 2.16: Arquitectura de un LLM basado en Transformer

Estos bloques constituyen el núcleo del modelo de lenguaje y están formados por dos componentes sucesivos. El primero es una capa de autoatención o *self-attention* cuya función es construir, para cada token, una representación contextual que incorpore información relevante de los tokens anteriores de la secuencia, permitiendo al modelo determinar a qué elementos del contexto debe prestar mayor atención durante el procesamiento (Figura 2.17). El modelo lo hace basándose en los patrones observados y aprendidos del corpus textual de entrenamiento.

Por ejemplo, con una secuencia como *El perro persiguió a la ardilla porque ella...*, para predecir el término siguiente es necesario establecer a qué hace referencia el pronombre

ella. La autoatención hace posible establecer esta dependencia, incorporando en la representación del pronombre la información proveniente del token correspondiente a *ardilla*, que semánticamente es el referente en este contexto. De este forma el modelo no procesa cada palabra de forma aislada sino en relación con el resto de la secuencia.




Figura 2.17: Self-attention incorpora información relevante de tokens anteriores

La capacidad del mecanismo de autoatención para relacionar cada token con el resto de la secuencia está limitada por un parámetro denominado *ventana de contexto*, el cual corresponde al número máximo de tokens que el modelo puede procesar simultáneamente en una entrada. Este límite determina cuánta información del texto disponible en ese momento como el prompt y los tokens ya generados puede utilizarse para producir nuevas predicciones (Figura 2.18).

De este modo, una ventana más amplia permite incorporar fragmentos de texto más extensos, como párrafos o documentos completos, mientras que una ventana de contexto reducida restringe la cantidad de información que puede ser considerada durante la predicción. Durante la generación autoregresiva, la longitud del contexto actual aumentará a medida que se generen nuevos tokens hasta alcanzar el tamaño máximo permitido por la arquitectura del modelo.




Figura 2.18: Ventana de contexto

Asimismo, el segundo componente de cada bloque Transformer es una *red neuronal feedforward*.

Mientras que la autoatención permite que cada token mire el resto del contexto de la secuencia, esta red opera de manera independiente sobre cada posición y se encarga de transformar la representación obtenida en una versión más rica y expresiva. Gran parte de la capacidad del modelo para reconocer asociaciones lingüísticas, como anticipar la palabra *Rings* después de la secuencia *The Lord Of The*, reside en estas capas, ya que en ellas se ajustan los parámetros que capturan regularidades presentes en el corpus textual. De este modo, la red feedforward no solo contribuye a refinar las representaciones generadas por la autoatención sino que también constituye el principal mecanismo mediante el cual el modelo generaliza a partir de los datos y produce predicciones coherentes ante secuencias que no ha visto previamente.




Figura 2.19: Elementos de cada bloque: self-attention y feedforward

El flujo de la información sigue una dirección secuencial a través de la pila de bloques Transformer. Para cada token generado, las representaciones atraviesan sucesivamente cada uno de estos bloques hasta alcanzar la capa de salida denominada *LM head*, la cual proyecta dichas representaciones en una distribución de probabilidad sobre todo el vocabulario. A partir de esta distribución se selecciona el siguiente token más probable, repitiéndose este procedimiento de manera iterativa durante el proceso de generación del texto (Figura 2.20).




Figura 2.20: Representación del cálculo de probabilidades para cada token del vocabulario

Esta selección de un único token a partir de la distribución se conoce como estrategia de decodificación. El enfoque más simple consiste en elegir siempre el token con mayor probabilidad. Sin embargo, esta estrategia suele generar resultados poco variados. Por ello, otro enfoque es añadir algo de aleatoriedad y elegir el segundo o tercer token con mayor probabilidad. Este comportamiento puede controlarse mediante el parámetro de temperatura, que regula el nivel de diversidad en el texto generado. Dicho parámetro se retomará más adelante en el capítulo 5.

Entrenamiento

El funcionamiento descrito previamente es posible gracias a un proceso de entrenamiento en el que se ajustan los parámetros del modelo de lenguaje de gran escala. Como se mencionó al inicio del capítulo, éstos son los valores numéricos que determinan el comportamiento de la red neuronal. En el caso de un LLMs, esta red está constituida por el conjunto de bloques que conforman la arquitectura Transformer incluyendo los mecanismos de autoatención, las redes feedforward y la matriz de embeddings, cuyos pesos internos se optimizan durante el aprendizaje. La magnitud y configuración de estos parámetros entrenables condicionan la capacidad del modelo para almacenar información y representar patrones complejos del lenguaje.

El entrenamiento de los modelos se organiza, de manera general, en dos etapas principales (Figura 2.21).

La primera, denominada preentrenamiento o *pretraining*, concentra la mayor parte del costo computacional y del tiempo total de entrenamiento. En esta etapa el modelo se expone a grandes volúmenes de texto de propósito general, procedentes, por ejemplo, de la web, libros, artículos, foros y otras fuentes de acceso público, con el objetivo de aprender patrones gramaticales, relaciones contextuales y conocimiento factual. Este último incluye información básica como fechas, cifras, acontecimientos, etapas históricas, lugares y capitales. Dicho aprendizaje se lleva a cabo mediante un objetivo de modelado de lenguaje autorregresivo.

Este proceso se realiza normalmente sin supervisión humana directa, a partir de datos no etiquetados, y no está orientado todavía a tareas específicas ni al seguimiento de instrucciones. El modelo resultante se denomina comúnmente modelo base o foundation model, ya que constituye el punto de partida para etapas posteriores de especialización.

A partir de este modelo base se lleva a cabo una etapa de ajuste fino o *fine-tuning*, en la que el entrenamiento continúa sobre conjuntos de datos más específicos y de menor tamaño, orientados a una tarea, dominio o comportamiento particular. Esto que permite que el modelo aprenda a interpretar y seguir indicaciones expresadas en lenguaje natural en lugar de limitarse a continuar secuencias de texto, sin necesidad de repetir el costoso proceso de preentrenamiento, reduciendo así los recursos computacionales requeridos. El resultado sigue considerándose un modelo preentrenado, ya

que parte de los parámetros aprendidos en la etapa anterior, pero con un comportamiento especializado acorde con los nuevos datos de entrenamiento.




Figura 2.21: Proceso de entrenamiento de un LLM

Dentro de esta etapa general de ajuste fino, una de las estrategias que ha resultado fundamental para el uso práctico de los LLM es el denominado *instruction tuning*. En esta el modelo se entrena adicionalmente con conjuntos de datos compuestos por pares de instrucciones y respuestas elaboradas por humanos, los cuales proporcionan ejemplos explícitos del tipo de comportamiento esperado ante las consultas de los usuarios. Por ejemplo, el conjunto de datos podría contener el siguiente par: *P: ¿Cuál es la capital de Inglaterra? R: La capital de Inglaterra es Londres.*

En los modelos orientados para interacciones conversacionales, esta capacidad de seguir instrucciones se amplía mediante una etapa denominada *dialogue tuning*. En este caso, los conjuntos de datos utilizados para el entrenamiento incorporan ejemplos de diálogos de múltiples turnos, es decir, secuencias de intervenciones entre usuario y modelo que permiten aprender la coherencia contextual a lo largo de una conversación y no únicamente la generación de respuestas aisladas.

De forma complementaria, la entrada y la salida del modelo se estructuran mediante un formato que asigna explícitamente un rol a cada fragmento de texto, distinguiendo, por ejemplo, entre instrucciones del sistema, mensajes del usuario y respuestas del modelo. Este enfoque permite definir el contexto general de la tarea mediante el mensaje del sistema, diferenciarlo de las consultas realizadas por el usuario y mantener la coherencia de las respuestas generadas por el modelo a lo largo del diálogo. Un ejemplo simplificado es el siguiente: *system: Eres un asistente especializado en el análisis de información científica. user: Describe los elementos visibles en la figura. assistant: La figura muestra una red de coautoría con tres comunidades principales...*

La incorporación de datos conversacionales en este formato estructurado es la base del comportamiento interactivo de los modelos actuales, haciendo posible su uso en interfaces de tipo chat y en aplicaciones que requieren seguimiento de instrucciones a lo largo de múltiples turnos de interacción.

Finalmente, estas fases de ajuste fino supervisado suelen complementarse con técnicas de aprendizaje por refuerzo a partir de retroalimentación humana o *reinforcement learning from human feedback* RLHF. A diferencia de las etapas anteriores que enseñan qué tipo de respuesta producir, éste actúa principalmente como un mecanismo de alineación en el que las distintas salidas generadas por el modelo son evaluadas por humanos que establecen preferencias entre ellas, optimizando su comportamiento hacia respuestas más útiles, coherentes y alineadas con criterios de seguridad y adecuación al contexto. Este proceso es el que posibilita que los modelos actuales interactúen de forma conversacional y respondan a instrucciones formuladas directamente por el usuario, ampliando su aplicación en distintos contextos.

Prompting

Una vez completado el proceso de entrenamiento, el modelo no continúa aprendiendo de manera activa en cada interacción sino que su comportamiento en cada interacción depende de la información que reciba como entrada.

Como se mencionó previamente, dicha entrada se denomina *prompt*, y es el medio mediante el cual se especifica la tarea que el modelo debe realizar. La formulación del prompt o *prompting*, toma entonces un papel central, ya que guía la generación de la respuesta a partir de las capacidades adquiridas durante las etapas de preentrenamiento y ajuste fino.




Figura 2.22: Etapas de entrenamiento y uso de un LLM

El prompting puede adoptar diversas formas, desde interacciones abiertas de carácter conversacional hasta la formulación precisa de tareas específicas. En la práctica, uno de los enfoques más relevantes es el denominado *instruction-based prompting*, en el que el modelo recibe una instrucción explícita que define tanto la actividad a realizar como las características de la respuesta esperada. Esto permite que un mismo modelo pueda ser empleado en múltiples escenarios mediante la reformulación de la entrada (Figura 2.23), orientando su proceso de generación hacia un objetivo y un formato específicos. Así, una solicitud orientada a la generación de resúmenes produce un comportamiento distinto al requerido para tareas como la clasificación o el reconocimiento de entidades.




Figura 2.23: Estructuras que pueden adoptar un prompt para realizar distintas tareas

Aunque cada tarea requiere una formulación distinta del prompt, comparten muchas de las estrategias empleadas para mejorar la calidad de la salida. Entre ellas destaca, la especificidad de la instrucción, es decir escribir con precisión las especificaciones de la tarea a realizar, el formato de la respuesta y el tono de redacción, buscando acotar el espacio de generación del modelo y reducir la producción de contenido irrelevante.

Otro aspecto a considerar es el control de las denominadas alucinaciones o invenciones, un fenómeno por el cual los modelos pueden generar información incorrecta con un alto nivel de confianza. Una estrategia habitual para mitigar este comportamiento y favorecer la generación respuestas más fieles al contenido disponible, consiste en indicar explícitamente que el modelo debe abstenerse de responder cuando no disponga de información suficiente.

Por su parte, el orden en que se presentan las instrucciones dentro del prompt influye en el resultado generado. Esto debido a que los modelos tienden a prestar mayor atención a la información ubicada al inicio o al final de la entrada, fenómeno asociado a los efectos, incluso en conversaciones humanas, de primacía y recencia. En consecuencia, situar las indicaciones principales en estas posiciones contribuye a que sean consideradas con mayor peso durante la generación de la respuesta.

El diseño del prompt puede entenderse como la combinación de distintos componentes funcionales que en conjunto delimitan el comportamiento del modelo (Figura 2.24).

Entre los más relevantes se encuentran la definición de un rol o persona para el sistema, siendo esta una práctica conocida como *role prompting*, mediante la cual se define de forma textual una identidad o perfil profesional que condiciona el tipo de lenguaje empleado, el nivel de formalidad, los criterios de análisis y estructura de la respuesta generada. Por ejemplo, al indicarle que actúe como un médico, se favorece la generación de respuestas con un enfoque clínico acordes con los objetivos propios de dicho dominio, como el diagnóstico.

Asimismo, otros componentes a considerar son la instrucción que especifica la tarea, el contexto en el que se desarrolla, el formato esperado, la audiencia a la que se dirige el texto y el tono de redacción.

El prompt puede construirse incorporando uno o varios de estos componentes y evaluando el efecto de sus modificaciones, que no se limitan a su inclusión o eliminación pues el orden en que aparecen también influye en el resultado, como se mencionó con los efectos de primacía y recencia. En este sentido, la experimentación resulta fundamental para identificar la formulación más adecuada para cada caso de uso.

De esta forma, se reduce la amplitud del espacio de generación y se orienta la respuesta hacia objetivos definidos. El prompt de ser una instrucción aislada para convertirse en una estructura que organiza la interacción con el modelo y condiciona la calidad del texto generado.




Figura 2.24: Componentes que pueden integrarse en un prompt

Hasta este punto se ha considerado el prompting como la formulación explícita de instrucciones que guían el comportamiento del modelo. Sin embargo, es posible ir un paso más allá, en lugar de describir únicamente la tarea, proporcionar ejemplos directos del tipo de resultado esperado. Este enfoque se conoce como *in-context learning*, ya que el modelo ajusta su generación a partir de la información contenida en el prompt, sin que exista un proceso adicional de entrenamiento.

Dependiendo del número de ejemplos incluidos, existen tres modalidades principales. En el *zero-shot prompting* no se proporciona ningún ejemplo y el modelo debe resolver la tarea únicamente a partir de la instrucción y del conocimiento adquirido durante el entrenamiento. En el *one-shot prompting* se incorpora un único ejemplo que ilustra el formato y el tipo de respuesta esperada. Por su parte, el *few-shot prompting* incluye dos o más ejemplos, lo que permite mostrar de manera más precisa el patrón que debe seguir la salida generada.

La inclusión de ejemplos funciona como una demostración explícita de la tarea y reduce la ambigüedad de la instrucción, ya que el modelo no solo recibe una descripción de lo que debe hacer sino también una referencia concreta de cómo debe hacerlo. Así, los ejemplos actúan como una forma de supervisión contextual que orienta la generación sin modificar los parámetros internos del modelo. La elección entre estas modalidades depende del problema a resolver y del grado de control requerido sobre la salida.




Figura 2.25: Representaciones de zero-shot, one-shot y few-shot

Multimodal

Hasta este punto se ha descrito cómo, una vez finalizado el entrenamiento, el comportamiento del modelo puede orientarse mediante el diseño del prompt y la estructuración de la interacción en lenguaje natural. Sin embargo, las aplicaciones actuales de los modelos de lenguaje no se limitan al procesamiento de texto. En diversos contextos resulta necesario analizar de manera conjunta distintos tipos de datos, por

ejemplo, interpretar una imagen para generar una descripción o responder preguntas sobre su contenido. Siendo esta necesidad la que ha dado lugar al desarrollo de los denominados modelos multimodales (Figura 2.26).




Figura 2.26: Representación de modelo multimodal procesando distintos tipos de datos

Desde el punto de vista arquitectónico, la extensión al ámbito multimodal se basa en una adaptación de la arquitectura Transformer, dando origen al denominado *Vision Transformer* (Figura 2.27), que permite representar distintos tipos de datos en un mismo espacio de procesamiento.

Mientras que en los modelos de lenguaje la entrada textual se tokeniza para obtener una secuencia de vectores, en el caso de las imágenes la información visual debe transformarse de manera análoga en una secuencia de valores numéricos. Este procedimiento hace posible que los datos visuales y textuales sean compatibles entre sí y puedan procesarse de forma conjunta dentro de una misma arquitectura.




Figura 2.27: Ejemplificación de Transformer y Vision Transformer

En lugar de palabras o subpalabras, una imagen se divide en regiones de tamaño fijo comúnmente denominadas *patches*, cada una de 16×16 píxeles, que funcionan de manera análoga a los tokens del procesamiento de texto (Figura 2.28). Cada uno de estos patches conserva inicialmente una estructura bidimensional asociada a la distribución espacial de los píxeles y a sus canales de color. Sin embargo, para que puedan ser procesados por la arquitectura Vision Transformer, sus valores se reorganizan en un único vector mediante una operación de aplanamiento o *flattening*. Este procedimiento no altera la información visual contenida en el bloque sino únicamente su disposición, transformándola en una secuencia unidimensional de valores numéricos.



Figura 2.28: Tokenización de una imagen como entrada

Dado que el contenido visual varía entre imágenes y no existe un vocabulario discreto como en el texto, no es posible asignar a cada fragmento un identificador fijo. Por ello, cada patch aplanado es transformado mediante una proyección lineal en un embedding que captura sus características visuales más relevantes. Esta proyección se realiza multiplicando el vector de píxeles por una matriz de pesos entrenables, cuyos valores se ajustan durante el entrenamiento para aprender patrones visuales significativos. En modelos concebidos como multimodales desde su diseño inicial, este aprendizaje ocurre durante el preentrenamiento; en cambio, cuando la capacidad visual se incorpora posteriormente a un modelo de lenguaje previamente entrenado, dicha matriz se optimiza en una fase específica de entrenamiento multimodal y puede refinarse nuevamente durante el ajuste fino orientado a tareas específicas.

Una vez obtenidas estas representaciones, la secuencia de embeddings de los patches se introduce en el codificador del Transformer de manera análoga a una secuencia de tokens textuales (Figura 2.29). Previamente, se añade al inicio de la secuencia un embedding adicional denominado token de clasificación o [CLASS], el cual no está asociado a ninguna región específica de la imagen sino que corresponde a un vector entrenable cuyo propósito es concentrar la información global del contenido visual.

Durante el procesamiento en el codificador, el mecanismo de autoatención permite que este token interactúe con todos los embeddings de los patches, integrando progresivamente la información proveniente de las distintas regiones de la imagen en una representación contextualizada. De este modo, el embedding asociado al token de clasificación actúa como un descriptor global que resume las características visuales más relevantes. Al finalizar la codificación, dicho vector contiene un resumen de alto nivel del contenido visual que puede emplearse como base para realizar tareas posteriores.




Figura 2.29: Proceso de transformación de una imagen en una secuencia de embeddings

Una vez que el contenido visual ha sido transformado en forma de embeddings, el tratamiento posterior de dicha representación pasa a depender del propósito con el que haya sido diseñada la arquitectura multimodal. En algunos casos, el objetivo consiste en obtener representaciones conjuntas que permitan comparar información visual y textual dentro de un mismo espacio semántico; en otros, se busca que la información visual actúe como contexto directo para la generación de lenguaje natural.

Un ejemplo del primer enfoque lo constituyen modelos como CLIP, en los que las modalidades visual y textual son procesadas por codificadores independientes (Figura 2.30) que proyectan sus respectivas salidas en un espacio vectorial compartido con el fin de medir su similitud semántica.




Figura 2.30: Creación de embeddings en CLIP para un texto y una imagen

De este modo, la relación entre una imagen y un texto se establece a partir de la proximidad entre sus embeddings (Figura 2.31), lo que permite realizar tareas como la recuperación de imágenes a partir de una consulta en lenguaje natural o la agrupación de conjuntos mixtos de texto e imágenes según su similitud semántica. En este tipo de arquitecturas no existe una fusión directa de las secuencias ni un proceso generativo de texto sino una correspondencia entre representaciones.




Figura 2.31: Representación de un espacio vectorial compartido entre embeddings visuales y textuales situados próximos entre sí por su significado semántico similar

En contraste, los modelos multimodales generativos integran los tokens visuales dentro de la misma secuencia que los tokens textuales y los procesan conjuntamente mediante un decodificador Transformer multimodal encargado de la generación autoregresiva. Bajo este esquema, la información visual no se limita a ser comparable con el texto sino que condiciona directamente la producción de la salida en lenguaje natural. Para ello, el modelo recibe como contexto una secuencia que combina los tokens textuales de entrada con los tokens visuales producidos por el codificador, y a partir de esta integración predice sucesivamente cada token de la respuesta, lo que le permite generar descripciones, explicaciones o respuestas coherentes con el contenido de la imagen y con el prompt proporcionado.

En conjunto, la evolución desde los modelos de lenguaje puramente textuales hacia arquitecturas multimodales refleja una ampliación progresiva de las capacidades de representación y razonamiento de los sistemas basados en Transformer. La posibilidad de integrar distintas modalidades de información dentro de un mismo espacio de procesamiento no solo amplía el alcance funcional de los modelos sino que constituye la base sobre la que se apoyan los desarrollos actuales en sistemas inteligentes capaces de interpretar, relacionar y generar contenido a partir de múltiples fuentes de información.

Sobre este marco conceptual se sustenta el sistema desarrollado en el presente proyecto, cuya arquitectura y proceso de implementación se describen en los capítulos siguientes.

3 Generación automática de reportes cienciométricos

3.1. Arquitectura general

La arquitectura del sistema implementado (Figura 3.1) se estructuró en torno a dos componentes principales, por un lado, la interfaz de usuario, responsable de la interacción directa con el sistema y de la visualización de resultados; y por otro, el módulo de procesamiento de representaciones visuales, orientado a la generación automática de interpretaciones mediante un modelo de lenguaje de gran escala LLM.




Figura 3.1: Arquitectura del sistema

Comienza la interacción con el usuario, quien accede al sistema desarrollado en Streamlit, desde donde puede explorar las distintas secciones del estudio cienciométrico y sus las representaciones visuales asociadas. Para evitar llamadas innecesarias al modelo de lenguaje de gran escala LLM, la generación de interpretaciones se activa únicamente para la sección donde se encuentre el usuario en el momento en que éste presione el botón correspondiente. En ese momento, la interfaz invoca un módulo de generación encargado de preparar el prompt multimodal, como parte de ese proceso las representaciones visuales son codificadas en formato Base64 para su integración junto con las instrucciones textuales dentro de una misma solicitud.

Asimismo, el módulo de generación permite la comunicación mediante solicitudes HTTP con un servidor local implementado a través de LM Studio, el cual expone el modelo de lenguaje de gran escala mediante una interfaz compatible con la API de OpenAI. Es importante señalar que dicha compatibilidad se refiere únicamente a la estructura de las solicitudes y respuestas definida por la API de OpenAI, lo que permite estandarizar la comunicación con el modelo.

De esta manera, el sistema funciona completamente en un entorno local, donde tanto la interfaz como el procesamiento del modelo se ejecutan sin depender de servicios externos, utilizando el modelo Pixtral-12B.

El servidor local ejecuta el modelo aprovechando la infraestructura de cómputo disponible, específicamente un equipo con una unidad de procesamiento gráfico (GPU) con 24 GB de memoria. El modelo procesa la información visual y textual y genera una respuesta en lenguaje natural, la cual es almacenada en el estado de sesión del sistema y presentada al usuario junto con su representación visual correspondiente.

3.2. Diagrama(s) de secuencia

El siguiente diagrama ilustra el flujo de interacción entre los componentes del sistema durante el proceso de generación de interpretaciones, mostrando el orden temporal de las acciones que se desencadenan al momento en que el usuario solicita las interpretaciones al interactuar con la interfaz de alguna de las secciones o páginas, desde la llamada al módulo de generación, pasando por la preparación de la entrada multimodal y el envío de la solicitud al servidor local que ejecuta al modelo de lenguaje de gran escala LLM, hasta la recepción de la respuesta y su almacenamiento en el estado de sesión para su posterior visualización.




Figura 3.2: Generación de interpretaciones

Es importante aclarar que las interpretaciones generadas al presionar el botón son únicamente para la página en que se encuentra el usuario.

Una vez que estas interpretaciones han sido generadas, se habilita el proceso de regeneración al presentar al usuario un botón de asociado a cada interpretación mostrada. Para ilustrar el flujo de interacción correspondiente se diseñó un segundo diagrama de secuencia (Figura 3.3).




Figura 3.3: Regeneración de una interpretación

Al presionar dicho botón de regeneración, el sistema elimina la interpretación previamente almacenada en el estado de sesión para la imagen o representación visual correspondiente. Posteriormente, el módulo de generación nuevamente codifica esta representación visual y prepara la entrada multimodal para enviar una nueva solicitud al servidor local que ejecuta al LLM. Regresa una nueva respuesta textual, la cual es almacenada en el estado de sesión y presentada en la interfaz sustituyendo a la interpretación anterior.

4 Implementación e integración

4.1. Descripción del sistema

Como se mencionó en el capítulo anterior, el diseño e implementación del sistema se estructuran en torno a la interfaz de usuario y el procesamiento de las representaciones visuales para la generación automática de interpretaciones. A continuación se mostrará el funcionamiento y apariencia de este primer componente.

Al ejecutarlo, el sistema muestra una pantalla de inicio (Figura 4.1) cuya función es introducir al usuario en el contexto general del estudio cientiométrico, así como sus objetivos y enfoque metodológico. Se presenta una descripción acerca de la producción científica del Instituto de Ciencias Nucleares de la UNAM, enfocando el análisis en términos de visibilidad internacional, áreas de investigación y trayectoria institucional. Asimismo, menciona de manera general las secciones o ejes principales del estudio, tales como el volumen de publicaciones, el impacto y la visibilidad científica, los patrones de colaboración y evolución temática.




Figura 4.1: Página de inicio

A partir de esta página introductoria, el usuario puede explorar de manera estructurada los componentes del estudio accediendo mediante un menú lateral de navegación a las cinco páginas que conforman las distintas secciones del sistema.

Se optó por este diseño para el sistema debido a que favorece su escalabilidad a futuro. En particular, permite sustituir de manera sencilla el modelo de lenguaje de gran escala LLM utilizado, ampliar el conjunto de representaciones visuales analizadas o

incorporar nuevos tipos de análisis cuantitativos mediante la incorporación de módulos adicionales, sin requerir modificaciones complejas en la arquitectura general del sistema.

Las cinco páginas siguen una misma estructura visual en las que presentan un conjunto específico de representaciones visuales, tales como tablas y gráficas, asociadas a los diferentes indicadores cuantitativos. La primera sección, titulada *Evolución del Volumen de la Producción Científica* presenta una interfaz organizada en tres pestañas temáticas que dividen la información de acuerdo con distintos enfoques como lo son la descripción general de la colección, la evolución anual de la productividad y la producción en revistas con factor de impacto.



Figura 4.2: Primer página

El contenido de cada pestaña se estructura mediante columnas que integran las representaciones visuales con el texto interpretativo generado automáticamente al momento en que el usuario presiona el botón *Generar Interpretaciones*, ubicado a la derecha, debajo del título de la página.

En la Figura 4.2 se observa que, al iniciar el sistema, las imágenes se presentan sin ningún texto interpretativo acompañándolas. Sin embargo, al momento en que el usuario acciona el botón correspondiente, se generan automáticamente las interpretaciones (Figura 4.3), no solo para la imagen visible en ese momento sino para todas de las representaciones visuales distribuidas a lo largo de las tres pestañas que conforman esa página.

Además, junto con cada uno de los textos generados aparece un botón adicional de *Regeneración*, ubicado inmediatamente debajo del contenido interpretativo, que permite al usuario generar nuevamente, de manera individual, una nueva interpretación para cada imagen.



Figura 4.3: Representación visual junto a su interpretación generada en la primer página

Otro elemento de la página a destacar se encuentra en la parte superior de la interfaz, inmediatamente después del título de la sección y antes del menú de pestañas, se presenta el apartado *Información Destacada*, el cual muestra indicadores relevantes de la sección. Este apartado permanece visible independientemente de la pestaña seleccionada por el usuario (Figura 4.4).



Figura 4.4: Cambio de pestaña en la primer página

4.2. Tecnologías utilizadas

Para implementar el sistema cumpliendo el objetivo de integrar dentro de un mismo entorno representaciones visuales y sus interpretaciones generadas automáticamente, se necesitaba seleccionar un conjunto de tecnologías que permitieran integrar la presentación de la información, el procesamiento de las representaciones visuales y la generación de texto en lenguaje natural. Estas tecnologías empleadas fueron elegidas no solo por su compatibilidad entre sí sino también por su capacidad para facilitar una implementación modular, flexible y extensible. Siendo así que se priorizaron herramientas que permitieran desarrollar la interfaz de usuario, gestionar la visualización de gráficas y tablas, ejecutar modelos de lenguaje de gran escala de forma local y coordinar la comunicación entre estos componentes.

Framework de desarrollo web: Streamlit

El desarrollo del sistema inició a partir de una primera versión implementada como un conjunto de páginas web interconectadas, generadas mediante código HTML integrado en scripts de Python y ejecutadas dentro de entornos *Jupyter Notebook*. Si bien esta aproximación permitió una validación inicial de los contenidos y de las representaciones visuales, resultó limitada en términos de modularidad, escalabilidad y navegación interactiva. Con el objetivo de contar con una implementación que facilitara la presentación estructurada de información visual y textual, la incorporación de componentes de Inteligencia Artificial y que permitiera una navegación intuitiva entre las distintas secciones del estudio; se optó por migrar el sistema a un framework especializado en aplicaciones interactivas. En este contexto, se seleccionó *Streamlit* como framework principal para la implementación del sistema, dado que permite el desarrollo de aplicaciones web interactivas directamente en Python resultando conveniente para la migración de la implementación anterior.

El uso de esta herramienta eliminó la necesidad de recurrir a tecnologías web adicionales, ya que el desarrollo con frameworks web tradicionales suele implicar una separación explícita entre el frontend y el backend. En contraste, Streamlit abstrae esta complejidad arquitectónica, lo que permitió centrar el desarrollo en los datos y en el contenido del sistema, siendo estos aspectos fundamentales para el cumplimiento del objetivo planteado para este proyecto.

Se aprovechó la arquitectura de Streamlit basada en pages o páginas para organizar el contenido del sistema en una pantalla de inicio y cinco páginas adicionales, cada una correspondiente a una sección específica del reporte cuantitativo; esta estructura en módulos permite tener una presentación ordenada de los elementos del sistema y facilita que puedan ser incorporadas nuevas secciones sin afectar el funcionamiento global de la aplicación. Asimismo, su capacidad para actualizar automáticamente la interfaz en respuesta a cambios en los datos simplificó la evaluación comparativa de modelos durante la evaluación comparativa de modelos.

Integración de representaciones visuales

Las representaciones visuales empleadas en el sistema tales como gráficas y tablas, se recuperaron directamente del reporte cuantitativo por lo que ya habían sido generadas mediante herramientas especializadas de análisis científico y almacenadas como archivos de imagen. El sistema desarrollado no se encarga de la generación de estos elementos sino de su presentación, por ello se utilizaron las capacidades de Streamlit para cargar imágenes desde el sistema de archivos y organizarlas de manera estructurada en secciones, pestañas y columnas combinando cada representación visual con su correspondiente interpretación generada automáticamente.

Lenguaje de programación

El sistema fue implementado en *Python*, un lenguaje de programación que resultó muy útil para el proyecto pues cuenta con una amplia variedad de bibliotecas que permiten integrar el manejo de los datos, la ejecución de modelos de lenguaje de gran escala LLMs y la visualización de resultados dentro de un mismo entorno de desarrollo.

Para la comunicación con los modelos de lenguaje de gran escala LLMs se utilizaron bibliotecas que permitieron realizar solicitudes de inferencia de manera local, es decir sin depender de servicios externos en la nube. En lugar de acceder a modelos remotos, los LLMs utilizados en este sistema se ejecutan directamente en la infraestructura de cómputo disponible, lo que ofrece un mayor control sobre los datos empleados y el desempeño del sistema.

En particular, se utilizó la biblioteca *openai* para interactuar con modelos de lenguaje tipo chat. Proporciona un esquema de comunicación basado en roles (*system*, *user* y *assistant*), lo cual facilitó la definición de prompts de manera estructurada combinando instrucciones textuales con representaciones visuales, permitiendo que el modelo genere interpretaciones de manera controlada. Por su parte, la biblioteca *lmstudio* se empleó para la carga y ejecución de los modelos de gran tamaño utilizados en el proyecto, actuando como un entorno de ejecución local para los LLMs gestionando su inicialización y aprovechando los recursos de hardware disponibles en la unidad de procesamiento gráfico GPU. De esta forma fue posible evaluar distintos modelos sin modificar la lógica general del sistema.

Aunque los modelos se ejecutan de forma local, su invocación se realiza a través de un mecanismo similar al de un servicio web. En este esquema, los modelos se exponen mediante una interfaz que recibe solicitudes y devuelve respuestas, lo cual requiere el uso del protocolo HTTP. Es por ello que se utilizó la biblioteca *httpx*, la cual permitió gestionar el envío de solicitudes HTTP al servidor local encargado de ejecutar los modelos, así como configurar aspectos básicos de la conexión, como la autenticación y el manejo de certificados. Además, se utilizó la biblioteca *base64* para transformar archivos de imagen en cadenas de texto que pudieran ser enviadas junto con instrucciones textuales dentro de una misma solicitud.

Infraestructura de cómputo

El sistema se ejecuta de manera local, apoyándose en un equipo de cómputo que cuenta con una unidad de procesamiento gráfico GPU de 24 GB de memoria. Esta capacidad computacional permitió trabajar con modelos de lenguaje de gran tamaño, siendo realmente útil para las pruebas con múltiples LLMs llevadas a cabo. Influyendo de esta forma tanto en la evaluación de modelos con el propósito de seleccionar el que finalmente se utilizaría, así como también en la configuración del sistema para la generación automática del texto.

LLMs

El componente central del sistema está constituido por las interpretaciones generadas automáticamente mediante un modelo de lenguaje de gran escala (LLM), el cual, se encarga de transformar representaciones visuales cuantitativas en descripciones comprensibles en lenguaje natural.

Para ello, se priorizó el uso de modelos multimodales que pudieran ejecutarse de manera local para así poder mantener un control mayor sobre los datos analizados y reducir el tiempo de respuesta del sistema, facilitando la comparación entre distintos modelos.

Para la selección del modelo se llevó a cabo una fase experimental en la que inicialmente se evaluaron tres modelos con el fin de analizar su desempeño en tareas de generación automática de interpretaciones a partir de representaciones visuales. Se procuró que los modelos presentaran diferencias principalmente en su número de parámetros, ya que este factor incide en la capacidad de representación de patrones complejos y, en consecuencia, en la calidad y precisión de las respuestas generadas. Asimismo, se consideró la longitud de la ventana de contexto, dado que este atributo condiciona la cantidad de información que el modelo puede procesar y mantener en memoria de manera simultánea durante la generación de la salida.

Estas características condicionan tanto la cantidad de información que el modelo puede integrar en una misma entrada, como el nivel de complejidad que es capaz de representar en las respuestas generadas.

La información técnica de los modelos analizados se presenta en la Tabla 4.1. Posteriormente, en la última etapa de la evaluación se incorporó un cuarto modelo. Para la selección de éste se buscaba realizar principalmente una comparación de sus respuestas generadas con las del modelo que había mostrado mejor desempeño hasta ese momento, Pixtral-12b. Para ello, se eligió un modelo que contara con características técnicas similares, lo que permitió evaluar con mayor precisión las diferencias en la calidad de sus interpretaciones.

LLM	Parámetros	Ventana de Contexto
<i>InternVL3_5-8B-GGUF</i>	Aproximadamente 8,000 millones	32,768 tokens
<i>Pixtral-12b</i>	Aproximadamente 12,000 millones	128,000 tokens
<i>InternVL3_5-30B-A3B</i>	Aproximadamente 30,000 millones	40,960 tokens
<i>Gemma-3-12b</i>	Aproximadamente 12,000 millones	128,000 tokens

Tabla 4.1: Modelos de lenguaje de gran escala analizados durante la fase experimental

Los resultados obtenidos en esta fase de evaluación fueron determinantes para la selección del modelo empleado en la implementación final del sistema, el cual correspondió a *Pixtral-12b*.

Este modelo adopta una arquitectura multimodal compuesta por dos bloques principales (Figura 4.5). Un codificador de visión, encargado de transformar las imágenes en una secuencia de tokens visuales mediante el procedimiento descrito en el capítulo 2, y un decodificador multimodal responsable de la generación autoregresiva de texto. Dicho decodificador opera sobre una secuencia unificada que integra tanto tokens textuales como visuales, modelando conjuntamente ambas modalidades para predecir iterativamente cada token de la salida.

Asimismo, con su amplia ventana de contexto de hasta 128,000 tokens, puede incluso procesar múltiples imágenes junto con extensos segmentos de texto dentro de una misma interacción (Mistral AI, 2024).




Figura 4.5: Arquitectura de Pixtral-12b

No obstante, el comportamiento del modelo no depende únicamente de sus características internas sino también de la manera en que se organiza la información de entrada. Esta organización se realiza mediante el diseño del prompt, el cual, define el contexto de la tarea requerida, las instrucciones que debe seguir el sistema y el formato esperado de la respuesta. Por esta razón, además de presentar el desempeño de los modelos evaluados en su generación de interpretaciones, en el siguiente capítulo se muestra el proceso de diseño del prompt utilizado en el sistema.

5 Aplicación o estudio de caso

5.1. Análisis comparativo de modelos

Se realizó una evaluación de la capacidad de interpretación de imágenes en distintos modelos con el objetivo de seleccionar el modelo de lenguaje de gran escala LLM que generará las descripciones automatizadas, a modo de reporte cuantitativo, dentro del sistema. Para garantizar una comparación justa se utilizó la misma configuración de temperatura en todos los modelos y se empleó un mismo prompt. Las imágenes utilizadas en las pruebas provienen del reporte cuantitativo, lo que permitió comparar el desempeño de los distintos modelos y seleccionar aquel que mostró mayor precisión en sus respuestas.

Como sabemos, los modelos de lenguaje de gran escala LLMs son entrenados con grandes cantidades de datos textuales, lo que les permite aprender patrones estadísticos del lenguaje y generar texto mediante la predicción del siguiente token en una secuencia. La temperatura es un parámetro que controla la forma en la que se distribuye la probabilidad utilizada durante las predicciones para la generación del texto. Un aumento en la temperatura hace que la distribución se vuelva más uniforme, incrementando la probabilidad de seleccionar tokens menos probables, produciendo respuestas más variadas y creativas pero menos coherentes. Por el contrario, una temperatura baja hace que el modelo favorezca los tokens con mayor probabilidad generando respuestas deterministas. Siendo esta última la que utilizaremos en nuestro caso, con un rango entre 0.0 y 0.2.

En el análisis de los resultados se tomó en cuenta la coherencia y precisión en la interpretación de la representación visual, en especial en conocer la capacidad del modelo para describir correctamente los elementos explícitos presentes en las representaciones visuales, identificar patrones generales sin introducir interpretaciones que no estén justificadas por los datos y seguir de manera consistente las instrucciones definidas en el prompt.

Asimismo, para la selección de los LLMs a evaluar se buscó que fueran modelos multi-modales de código abierto capaces de ejecutarse localmente, ya que como se mencionó previamente, el proyecto se desarrolla en un entorno con una unidad de procesamiento gráfico GPU de 24 GB de memoria, por lo que fue indispensable seleccionar modelos compatibles con estas restricciones de hardware.

Primer Prompt

El objetivo principal en la elaboración del primer prompt fue evitar que las respuestas generadas adoptaran un formato característico de los asistentes de Inteligencia Artificial, eliminando introducciones innecesarias como *“Claro, aquí tienes la descripción de la imagen”* y conclusiones generales. Asimismo, se buscó que los modelos produjeran descripciones basadas únicamente en la información que puede inferirse directamente de la imagen, sin añadir contenido inventado y no fundamentado. Buscando favorecer este comportamiento, se solicitó que las respuestas fueran concisas.

Primer Prompt de Prueba

```
1 messages=[
2     {"role": "system",
3       "content": "Eres un científico de datos experto en
4                 cienciometría y en la interpretación de gráficos e
5                 imágenes científicas."},
6     {"role": "user", "content": [
7       {"type": "text",
8         "text": "Describe y analiza únicamente la
9               información visible en la imagen proporcionada.
10              No incluyas introducciones ni conclusiones
11              generales, entrega solo la información técnica
12              y relevante. Si un dato en la imagen no es
13              legible o no está presente, no lo inventes. No
14              inventes valores, fechas o unidades. Si es una
15              gráfica, identifica el tipo de gráfica, ejes y
16              qué representan, tendencias principales, picos
17              o valles relevantes, y cualquier anotación o
18              valor claramente legible."},
19       {"type": "image_url",
20        "image_url": {"url": image_uri}}
21     ]}
22 ]
```

Para la primer imagen de prueba se buscó una gráfica que nos permitiera evaluar la capacidad de los modelos en su interpretación de tendencias y patrones generales en los datos, variaciones anuales y cualquier información extra que puedan proporcionar a la descripción de la imagen.

La gráfica seleccionada representa el total de artículos publicados por investigador sin incluir trabajos derivados de grandes colaboraciones abarcando un periodo entre 1996 y 2024.




Figura 5.1: Producción científica institucional: total de artículos publicados

Además, en el análisis de las respuestas generadas se consideró la descripción original de la imagen, extraída del reporte correspondiente.

A continuación se presenta la descripción para la gráfica:

El número de académicos a tiempo completo asociado al ICN ha aumentado desde su fundación como entidad académica hasta la actualidad. En los últimos años, este número ha mostrado cierta estabilidad. Se muestra la producción ajustada por el número de investigadores asociados a la institución en el periodo de 1996-2024 (...). Se observa una tendencia al crecimiento. Este crecimiento pudiera asociarse no solo al crecimiento de la actividad institucional, sino también a la propia cobertura de las bases de datos, dado el aumento de la cobertura del WoS durante los últimos años.

Las respuestas generadas, con sus respectivos análisis, son las siguientes:

Modelo A

InternVL3_5-8B-GGUF

El gráfico es un histograma con una línea de tendencia superpuesta.

- ****Eje X (horizontal)**:** Representa el "Año" desde 1950 hasta 2006.
- ****Eje Y (vertical izquierdo)**:** Mide la frecuencia acumulada en porcentaje (%), que va **del 0% al 250%**.
- ****Eje Y (vertical derecho)**:** No está etiquetado claramente, pero parece representar otra variable relacionada con el tiempo.

****Tendencias principales**:**

- La línea de tendencia muestra un aumento gradual en la frecuencia acumulada hasta aproximadamente el año 1980.

- Después de este punto, hay una fluctuación con picos notables alrededor de los años 1995 y 2000.
- A partir **del** año 2000, la línea muestra una disminución gradual.

****Anotaciones claramente legibles**:**

- En el eje Y izquierdo, se pueden ver valores en porcentajes: 0%, 50%, 100%, 150%, y 200%.
- La línea de tendencia tiene un punto marcado con una flecha alrededor **del** año 2006.
- La nota "www.sitio.com" está presente en la esquina inferior derecha **del** gráfico.

****Valores relevantes**:**

- Alrededor **del** año 1980, la frecuencia acumulada alcanza un valor cercano al 150%.
- Los años 1995 y 2000 muestran picos significativos en la línea de tendencia.

El modelo no presenta el nivel esperado de precisión en su interpretación de la gráfica. En primer lugar, identifica incorrectamente el rango temporal del eje X, señalando que abarca de 1950 a 2006, cuando el rango real corresponde de 1996 a 2024. De manera similar, la información proporcionada sobre el eje Y es incorrecta, ya que el modelo no logra identificar el texto que describe qué representan los valores de los ejes verticales, tanto izquierdo como derecho.

En el apartado de tendencias principales, el modelo menciona años como 1980 y 1995, los cuales no aparecen en la gráfica, lo que evidencia que no pudo leer correctamente los años en la imagen. Asimismo, afirma que existe una disminución gradual a partir del año 2000 cuando en realidad se observa un incremento y menciona la presencia de un sitio web en la esquina inferior derecha del gráfico, información que no puede corroborarse de forma visual. En conjunto, estas imprecisiones reflejan la invención de valores y eventos que no están presentes en la imagen analizada.

Modelo B

Pixtral-12b

El gráfico es una línea con barras superpuestas que representa datos de frecuencia acumulada sobre el tiempo .

- ****Eje X (horizontal)**:** Representa el tiempo en formato "

- dd/mm/aa" desde el 31/05 hasta el 28/06.
- ****Eje Y (vertical)****: Muestra la frecuencia acumulada en valores que van de 0 a 250.

La línea principal muestra una tendencia ascendente general con algunos picos y valles. Los picos más notables ocurren alrededor **del** 14/06 y el 28/06, mientras que los valles se observan alrededor **del** 31/05 y el 07/06.

Las barras superpuestas representan frecuencias acumuladas en intervalos específicos de tiempo. Cada barra muestra un aumento en la frecuencia acumulada a medida que avanza el tiempo, con picos alineados aproximadamente con los picos de la línea principal.

El modelo presenta múltiples imprecisiones en la interpretación de la imagen. En primer lugar, inventa información al describir el eje X, asignándole un formato temporal de fechas específicas que no aparecen en la gráfica. En cuanto al eje Y, si bien menciona correctamente los valores del eje izquierdo, omite por completo la identificación y descripción del eje derecho, a diferencia del modelo anterior.

Asimismo, en su análisis de las tendencias, el modelo hace referencia a fechas como 14/06 y 28/06, las cuales no son visibles ni legibles en la imagen, lo que indica nuevamente la invención de datos.

Con este prompt, su capacidad para identificar correctamente los componentes relevantes de la gráfica es baja, particularmente en lo que respecta a la detección y descripción del eje Y derecho.

Modelo C

InternVL3_5-30B-A3B

El gráfico es un histograma superpuesto con una línea de[Trend en caracteres asiáticos].

- ****Eje X (horizontal)****: Representa el "Ano", que va desde aproximadamente 1950 hasta alrededor de 2016.
- ****Eje Y (vertical izquierdo)****: Mide la frecuencia acumulada en porcentaje, con valores que van **del** 0% al 250%.
- ****Eje Y (vertical derecho)****: No está claramente etiquetado, pero parece representar otra variable

relacionada con el tiempo.

****Tendencias principales**:**

- La línea de[Trend en caracteres asiáticos] muestra un aumento gradual en la frecuencia acumulada hasta aproximadamente el año 2005.
- Después de este punto, hay una ligera disminución seguida de un pequeño aumento y luego estabilización.

****Picos y valles relevantes**:**

- Se observan varios picos a lo largo **del** tiempo, con los más notables alrededor de los años 1980, 2000 y especialmente entre 2005 y 2010.
- Los valles corresponden a las caídas en la frecuencia acumulada justo después de estos picos.

****Anotaciones o valores claramente legibles**:**

- No hay anotaciones adicionales o valores específicos legibles dentro **del** gráfico.

Este modelo incluye en su descripción de la gráfica caracteres correspondientes a escritura asiática, los cuales no pudieron ser correctamente renderizados para mostrarse en esta tesina redactada en LaTeX. Dichos caracteres corresponden al término trend o tendencia, lo que sugiere que el modelo detectó parcialmente el texto presente en la imagen pero sin lograr una redacción consistente en idioma.

En cuanto a la interpretación de los ejes, el modelo identifica valores numéricos en el eje Y, sin embargo la explicación de lo que dichos valores representan no es correcta. En general los modelos parecen no poder leer ese texto en la imagen. Respecto al eje X, asigna rangos temporales que no existen en la imagen, mencionando años inexistentes en la gráfica como 1950 lo que evidencia nuevamente la invención de información.

El análisis de las tendencias presenta inconsistencias pues el modelo afirma que existe un aumento hasta el año 2005 cuando en realidad se observa una disminución, y posteriormente describe una ligera disminución donde visualmente se puede apreciar un incremento. De igual forma, identifica picos en cuatro momentos distintos, de los cuales únicamente dos corresponden a picos reales visibles en la gráfica, alrededor de los años 2000 y 2010. Los otros picos mencionados no están presentes en la imagen.

Aunque el modelo logró describir correctamente ciertos elementos de la gráfica en aproximadamente dos de cada cuatro ocasiones, su interpretación en general tiene varios errores y valores inventados, lo que limita su confiabilidad.

Observaciones

En síntesis, los tres modelos presentan limitaciones para generar una interpretación fiel de la representación visual que se les proporcionó, principalmente en la identificación correcta de rangos temporales y tendencias, y en la lectura del texto que se encuentra a los costados de la gráfica. El modelo A cuenta con mucha información inventada en su interpretación al igual que ocurre con el modelo B. Mientras que el modelo C contó con una precisión parcial pero sólo en ciertos elementos específicos.

Con este primer prompt se obtuvo el formato solicitado en la estructura de la respuesta, caracterizado por la ausencia de expresiones propias de asistentes de Inteligencia Artificial. Sin embargo, su confiabilidad para la interpretación automática de gráficas cuantitativas es limitada pues las respuestas generadas presentan información inventada con un bajo nivel en detalle por lo que a partir de estas observaciones se diseñó otro prompt con más especificaciones y se modificó el parámetro de temperatura de 0.2 a 0.0 con el objetivo de reducir la generación de información no fundamentada.

Segundo Prompt

Este prompt se diseñó con el objetivo de mejorar la calidad de interpretación en las descripciones generadas, pues además de mantener la restricción de no inventar información, se especificó explícitamente el formato y el nivel de detalle deseado en las respuestas.

Segundo Prompt de Prueba

```
1 messages=[
2     {"role": "system",
3       "content": "Eres un científico de datos experto en
                     cienciometría y en la interpretación de gráficos y
                     representaciones visuales científicas."},
4     {"role": "user", "content": [
5       {"type": "text",
6         "text": "Describe y analiza únicamente la
                     información visible en la imagen proporcionada.
                     No incluyas introducciones ni conclusiones
                     generales. Agrega información que puedas
                     deducir de la imagen para construir una
                     narrativa detallada y precisa para un reporte
                     cienciométrico. Si un dato en la imagen no es
                     legible o no está presente, no lo inventes. No
                     inventes valores, fechas o unidades. Identifica
                     el tipo de representación visual (gráfica,
                     tabla, etc.), ejes y qué representan,
                     tendencias principales, picos o valles
                     relevantes, y cualquier anotación o valor
                     claramente legible. Que la respuesta que
                     generes solo tenga palabras en español."},
7       {"type": "image_url",
8         "image_url": {"url": image_uri}}
9     ]}
10 ]
```

Inicialmente, se le pasó a los tres modelos la gráfica utilizada anteriormente con el fin de comparar directamente los resultados obtenidos bajo ambas configuraciones.

Las respuestas generadas acerca de la gráfica de prueba, junto con sus análisis, son los siguientes:

Modelo A

InternVL3_5-8B-GGUF

La imagen muestra un gráfico de barras superpuesto con una línea de tendencia. El eje horizontal representa el tiempo, dividido en intervalos de años desde 1980 hasta 2016. El eje vertical izquierdo mide la frecuencia de citas por artículo, que va desde 0 hasta 250. La línea de trend es amarilla y muestra una tendencia general ascendente con algunos picos notables alrededor de los años 1998, 2004, 2007, 2010 y 2013. Las barras superpuestas en color azul representan la cantidad de artículos publicados cada año. Se observa un aumento gradual en el número de artículos a lo largo del tiempo, con picos alrededor de los años 1985, 1994, 2003 y 2016. La línea amarilla intersecta con las barras azules en varios puntos, indicando años donde el número de citas por artículo fue particularmente alto en comparación con la cantidad de artículos publicados. La imagen también incluye una nota en la esquina inferior derecha que menciona "www.mendeley.com", sugiriendo que los datos podrían provenir de la plataforma Mendeley, conocida por su función de seguimiento de citas y producción científica.

Al igual que en la respuesta generada con el primer prompt, el modelo continúa identificando incorrectamente el rango temporal del eje X. En esta ocasión señala que el periodo abarca de 1980 a 2016, mientras que previamente había indicado un rango de 1950 a 2006; sin embargo, el rango correcto de la gráfica corresponde de 1996 a 2024. Evidenciando así que el modelo no logra leer correctamente los valores temporales de la imagen. Asimismo, el modelo sigue sin identificar correctamente el texto ubicado a los costados de la gráfica, el cual es importante para la interpretación del eje Y. Dicho texto indica Producción científica y número de investigadores de tiempo completo; mientras que el modelo lo interpreta erróneamente como frecuencia de citas por artículo. Aunque logra reconocer correctamente el rango numérico del eje Y (de 0 a 250), falla en su comprensión respecto a lo que éste significa.

A diferencia de su respuesta anterior, el modelo agrega detalle a la descripción de la línea de tendencia mencionando su color. Sin embargo, al describir los picos notables menciona años que no corresponden a los picos más relevantes de la gráfica. En particular, señala el año 2007 como un pico, cuando en dicho año no se observa un incremento significativo. Si bien el resto de los años mencionados presentan aumentos, estos no corresponden a los máximos. Lo que indica que no identifica los aspectos más

destacables de la gráfica.

De manera similar, el modelo identifica correctamente el color azul de las barras y asocia estas con la cantidad de artículos publicados. Sin embargo, omite por completo la mención del segundo conjunto de barras representadas con un tono de azul más oscuro, las cuales corresponden al número de investigadores; limitando la interpretación al hacer esta omisión. En su análisis de las barras azules, el modelo menciona picos en años que no aparecen en la gráfica por lo que continúa inventando información. Además, señala la existencia de intersecciones entre la línea amarilla y las barras azules en varios puntos, situación que no se observa en la imagen.

Además, continúa mencionando la presencia de sitios web que no son visibles en la imagen. Si bien su capacidad para detectar los componentes en la imagen mejoró, destacando su identificación del eje y derecho que no logró con el primer prompt, su interpretación en general sigue siendo imprecisa y poco confiable.

No entiende de qué trata la gráfica pues piensa que se indica *el número de citas por artículo en comparación con la cantidad de artículos publicados*, cuando en realidad se trata de la producción científica y el número de investigadores de tiempo completo; y pese a las mejoras introducidas en el segundo prompt, el modelo continúa presentando limitaciones para generar una interpretación correcta.

Modelo B

Pixtral-12b

La imagen muestra un gráfico de barras superpuesto a una línea de tendencia. El eje horizontal representa el tiempo en años, desde 1980 hasta 2016, con intervalos de aproximadamente dos años. El eje vertical izquierdo mide la frecuencia de citas por artículo, que va desde 0 hasta 250. La línea de tendencia es de color amarillo y parece representar el promedio o una línea de ajuste suave sobre los datos de las barras.

Las barras azules representan la cantidad de artículos publicados cada dos años. Se observa un aumento gradual en la producción de artículos a lo largo **del** tiempo, con un pico notable alrededor **del** año 2014-2016. La línea amarilla muestra una tendencia ascendente que alcanza su máximo cerca **del** final **del** período representado.

En el eje vertical derecho, se puede ver una escala que va desde 0 hasta 350, aunque no está claramente etiquetada para qué representa. Sin embargo, podría estar

relacionada con otra métrica relevante como la frecuencia de descargas o accesos a los artículos.

La línea amarilla interseca con las barras azules en varios puntos, indicando momentos donde el número de citas por artículo coincide con el promedio general de producción. Este tipo de gráfico es útil para analizar cómo la frecuencia de publicación y las citas varían con el tiempo, permitiendo identificar periodos de alta actividad o impacto científico.

Con este segundo prompt, el modelo B generó una interpretación con más detalles. Sin embargo, siguen los errores en la identificación de los componentes de la gráfica. En particular, continúa fallando en reconocer correctamente el rango temporal del eje X, afirmando que entre cada barra existen intervalos de dos años, cuando en realidad cada barra corresponde a un año individual.

En relación con el eje Y, el modelo identifica correctamente el rango numérico del lado izquierdo 0 a 250, sin embargo interpreta erróneamente su significado. En esta ocasión y a diferencia de otros modelos, sí logra detectar la existencia de un eje Y en el lado derecho, aunque falla en la identificación de su rango de valores indicando que va de 0 a 350 cuando el rango real es de 0 a 3. Sin embargo, el modelo reconoce explícitamente que no logra distinguir el significado de dicho eje, lo cual constituye un aspecto positivo, ya que se apega a la instrucción de no inventar información no legible y sugiere que en realidad cuando se equivoca no es que invente información sino que no interpreta correctamente ciertos componentes de la imagen, particularmente los valores temporales del eje X, aunque cree que los está identificando con claridad.

El modelo incorpora correctamente detalles visuales como el color de la línea de tendencia y de las barras, acertando al identificar estas últimas como representaciones de los artículos publicados pero sin detectar el otro conjunto de barras azules de tono oscuro. Asimismo, señala intersecciones que no se observan en la gráfica entre la línea de tendencia y las barras.

Modelo C

InternVL3_5-30B-A3B

La imagen muestra un gráfico de barras superpuesto con una línea de[Trend en caracteres asiáticos] que representa la evolución **del** número de citas por año para el artículo "A new method for determining the number of

scientific citations" en el período de tiempo desde 1980 hasta 2016.

Detalles del Gráfico:

- **Eje X (horizontal)**: Representa los años, numerados desde 1980 hasta 2016.
- **Eje Y (vertical)**: Muestra el número de citas, que va desde 0 hasta 250.

Características Principales:

1. **Gráfico de Barras**:
 - Cada barra representa el número total de citations recibidas en ese año específico.
 - Las barras aumentan y disminuyen a lo largo **del** tiempo, mostrando variaciones anuales en la cantidad de citas.
2. **Línea de Tendencia**:
 - La línea amarilla superpuesta sobre las barras indica una tendencia general en el número de citations.
 - Se observa un aumento gradual en el número de citas a lo largo **del** tiempo, con algunos picos notables.
3. **Picose Valles Relevantes**:
 - **Pico Notable**: Año 2014 muestra un pico considerable en el número de citas, alcanzando uno de los valores más altos.
 - **Valle Notable**: Años tempranos como 1980 y 1985 muestran valores bajos en comparación con años posteriores.

Anotaciones:

- En la esquina superior derecha, hay una anotación que dice "2", posiblemente indicando un valor relevante o una nota adicional sobre el gráfico.
- La fuente de los datos se menciona como "Web of Science".

Narrativa Detallada:

El gráfico ilustra cómo el artículo ha sido citado a lo largo de más de tres décadas. Desde 1980, donde las citas iniciales son relativamente bajas, se observa un aumento gradual en la cantidad de citations. Este

incremento sugiere que el artículo ha ganado mayor relevancia y atención con el tiempo.

Los años tempranos muestran una tendencia estable con variaciones menores, pero a partir de 1990, las citas comienzan a aumentar más rápidamente. Este aumento acelerado continúa hasta alcanzar un pico significativo en 2014, donde el artículo parece haber experimentado un incremento notable en su impacto académico.

Posteriormente, aunque hay una ligera disminución después **del** pico de 2014, las citas permanecen relativamente altas, lo que indica que el artículo sigue siendo relevante y citado en la comunidad científica. La línea de tendencia refuerza esta observación mostrando una evolución general ascendente.

Este análisis sugiere que el artículo ha mantenido su relevancia a lo largo **del** tiempo, con un momento particularmente activo de citations alrededor de 2014.

La respuesta generada por este modelo contiene más detalles, siguiendo las especificaciones del segundo prompt. Sin embargo, volvió a incluir caracteres correspondientes a escritura asiática para referirse a la línea de tendencia a pesar de que se indicó explícitamente que la respuesta debía contener únicamente palabras en español.

En su sección dedicada a los detalles de la gráfica, el modelo nuevamente tiene errores en la identificación del eje X, mencionando años que no aparecen en la imagen. En cuanto al eje Y izquierdo, identifica correctamente el rango numérico pero interpreta de forma incorrecta su significado asociándolo al número de citas, cuando esto no corresponde al contenido de la gráfica. Adicionalmente el modelo no logra identificar adecuadamente el eje Y derecho aunque detecta un valor 2 en la esquina superior derecha pero no reconoce que dicho valor forma parte del rango de este eje, el cual se abarca de 0 a 3. Siendo el único modelo que identifica de manera consistente la existencia de un eje Y derecho.

Al identificar picos relevantes de la línea de tendencia, el modelo señala el año 2014 como el valor más alto, cuando en realidad en ese periodo se observa un decremento. Cabe destacar que el modelo indica erróneamente que la gráfica finaliza en 2016 y que el valor máximo se encontraría hacia el final de la serie en 2014; por lo que, si hubiera detectado correctamente los años, su interpretación del comportamiento general podría haber sido correcta.

Finalmente, realiza una narrativa detallada que, al ser analizada sin considerar los

años específicos y con la gráfica a la mano como referencia, resulta mayormente coherente. Esto sugiere que el modelo no está inventando información de manera arbitraria sino que presenta dificultades para detectar con precisión los valores temporales del eje X y el significado semántico de la gráfica pues la interpreta como una representación de citas por artículo. Este comportamiento refuerza la hipótesis de que no se está ignorando la instrucción en el prompt de no inventar valores, sino que principalmente los errores observados se originan cuando el modelo cree que está identificando los elementos en la gráfica con claridad.

Observaciones

En conjunto los tres modelos comparten una limitación, que es llevar a cabo la lectura precisa del eje X, siendo esto uno de los motivos principales por lo que sus interpretaciones generadas son poco precisas, aunque difieren en cómo gestionan esa limitación.

Asimismo, no logran realizar una interpretación semántica correcta del contenido de la gráfica. El modelo A es el menos preciso pues no solo mantiene errores previos sino que introduce nuevas inconsistencias, siendo un aspecto a destacar que menciona elementos que no están presentes tales como intersecciones entre la línea de tendencia con las barras, por lo que es el menos confiable de los tres. El modelo B muestra una mejora respecto al modelo A, aunque sigue presentando errores su comportamiento es menos inventivo. Su principal avance es que esta vez detectó la existencia del eje Y derecho; y si bien se equivoca en el rango de valores, reconoce explícitamente que no puede identificar su significado. Esto sugiere que no ignora la instrucción de no inventar información no legible, sino que cuando se equivoca es porque no está detectando correctamente ciertos componentes de la imagen aunque cree que los está identificando con claridad.

Un aspecto clave la interpretación del modelo C es que el comportamiento general de la gráfica resulta coherente si se omiten los años específicos, lo que sugiere que el modelo es capaz de captar patrones visuales aunque tiene dificultades asociar con precisión etiquetas, valores y su significado semántico.

En consecuencia, los aciertos obtenidos por los modelos de lenguaje de gran escala LLMs con este segundo prompt no son suficientes para alcanzar el nivel de precisión y confiabilidad buscado de interpretaciones generadas automáticamente para un reporte cuantitativo. Por esta razón, diseñó un último prompt que incorpora especificaciones adicionales orientadas a acotar y disminuir los errores en las respuestas.

Tercer Prompt

Este prompt fue diseñado con el objetivo de atender directamente a las limitaciones observadas previamente para así mejorar la calidad de las interpretaciones. En particular se buscó que el modelo distinga explícitamente entre tipo de representación visual, elementos que son claramente legibles, patrones observables e inferencias; acotando de esto modo la respuesta con el fin de obtener interpretaciones más consistentes con la información de la representación visual. Al ser el último prompt de estas pruebas, se realizó un análisis más estricto para finalmente seleccionar al modelo utilizado en el sistema.

Tercer Prompt de Prueba

```
1 messages=[
2     {"role": "system",
3       "content": "Eres un científico de datos experto en
4                 cienciometría y en la interpretación de gráficos y
5                 representaciones visuales científicas. Debes
6                 priorizar la precisión y evitar cualquier suposición
7                 no respaldada visualmente."},
8   {"role": "user", "content": [
9     {"type": "text",
10      "text": "Analiza únicamente la información visible
11              en la imagen proporcionada. Redacta un párrafo
12              con un tono técnico y formal de un reporte
13              científico que contenga obligatoriamente lo
14              siguiente: Elementos explícitamente legibles en
15              la imagen, componentes visuales identificables
16              (si es una gráfica, un mapa generado con redes
17              neuronales SOM, una tabla u otro tipo de
18              representación visual; ejes, colores, símbolos)
19              , patrones visuales generales observables (
20              tendencias, aumentos o disminuciones), las
21              inferencias son permitidas pero deben ser
22              claramente marcadas como inferencias, abstente
23              de mencionar elementos no legibles, ambiguos o
24              no identificables; no menciones años específicos,
25              valores exactos, rangos temporales,
26              intersecciones o significados de ejes a menos
27              que estén claramente indicados y sean legibles
28              en la imagen; si un dato no puede leerse con
29              claridad, indícalo explícitamente como no
30              legible o no identificable; no inventes valores
31              , fechas, unidades ni significados semánticos.
32              La respuesta debe estar escrita únicamente con
33              letras del alfabeto latino. No incluyas
```

```

        introducciones ni conclusiones generales ni títulos de secciones." },
7      {"type": "image_url",
8        "image_url": {"url": image_uri}}
9    ]}
10 ]

```

Se realizaron pruebas con los modelos de lenguaje de gran escala previamente evaluados, con excepción del modelo A cuyo desempeño resultó significativamente inferior al momento en que se incrementaron las especificaciones con el segundo prompt. En su lugar, se incorporó otro LLM de prueba al que se denominó modelo D.

Esta nueva incorporación al conjunto de modelos permitió examinar no solo el impacto del diseño del tercer prompt en cuanto a la calidad y precisión de las interpretaciones generadas sino también contrastar las capacidades de otro modelo frente a la misma representación visual, correspondiente a la gráfica que se ha estado empleando en las pruebas.

A continuación las respuestas generadas acerca de la gráfica:

Modelo B

Pixtral-12b

La gráfica proporcionada ilustra la evolución temporal de diversos indicadores científicos entre los años 1996 y 2024. Se identifican dos series de datos principales: una serie en barras azules que representa el número de artículos publicados, y otra línea amarilla que muestra el número de investigadores. El eje vertical izquierdo mide la cantidad de artículos e investigadores, mientras que el eje vertical derecho indica el número de citas por artículo. Los ejes horizontales están etiquetados con años específicos, aunque no todos los valores son legibles en la imagen. Se observa una tendencia general ascendente tanto en el número de artículos publicados como en el número de investigadores a lo largo del período analizado. Específicamente, se puede inferir que hay un aumento significativo en ambos indicadores alrededor de 2015 y 2016, seguido de fluctuaciones pero manteniendo un nivel elevado hasta 2024. Los valores del impacto científico, representados por la línea amarilla, muestran picos notables alrededor de los años 2017 y 2023, lo que sugiere períodos de mayor productividad.

científica e impacto. La correlación entre el número de artículos publicados y el número de investigadores es evidente, con ambos indicadores mostrando patrones similares a lo largo del tiempo.

Lo primero que destaca en la respuesta generada a partir de este prompt es una mejoría en la capacidad del modelo para identificar correctamente el rango temporal representado por el eje X al señalar que el periodo abarca de 1996 a 2024. Sin embargo, el modelo menciona explícitamente que no puede identificar con precisión todos los años optando por declarar esta limitación en lugar de proporcionar valores temporales incorrectos en su interpretación. Esto último representa un comportamiento deseable pues sigue las especificaciones del prompt.

El modelo identifica correctamente el eje Y derecho e identifica correctamente su significado. Asimismo, nuevamente logra reconocer la presencia de un eje Y izquierdo; sin embargo, interpreta de manera errónea su significado al mencionar que corresponde al número de citas por artículo pues no logra identificar el texto *Productividad Científica Institucional* presente en la representación visual.

En cuanto a patrones generales, el modelo observa correctamente una tendencia ascendente a lo largo del periodo analizado. Además, infiere la existencia de un aumento significativo alrededor de los años 2015 y 2016, lo cual consiste con la información visual dado que hasta ese momento no se habían alcanzado valores tan altos. También identifica la presencia de fluctuaciones posteriores, lo cual es coherente con el comportamiento observado en 2017. Adicionalmente, menciona de manera correcta el intervalo temporal en el que se encuentran los picos notables de la gráfica.

Al final indica que la línea amarilla representa el impacto científico, siendo esto incorrecto pues en realidad corresponde a la productividad científica institucional. Esto sugiere que las interpretaciones del modelo podrían beneficiarse si tuviera un contexto adicional acerca de la información que encuentra en la representación visual.

Modelo C

InternVL3_5-30B-A3B

La imagen muestra un gráfico de barras superpuesto a una línea de [Trend en caracteres asiáticos], ambos representando datos en función del tiempo, medido en días desde el inicio del eje horizontal hasta aproximadamente el día 206. El eje vertical izquierdo parece indicar valores numéricos que aumentan de manera

general ascendente, mientras que el eje derecho muestra una escala que no está claramente identificada pero podría estar relacionada con otra variable métrica. La línea de [Trend en caracteres asiáticos] se destaca en color amarillo y presenta variaciones alrededor de un valor promedio, mostrando tendencias de aumento y disminución a lo largo del tiempo. Las barras superpuestas sobre la línea están coloreadas en azul claro y representan datos diarios que también muestran fluctuaciones, con una tendencia general ascendente observada hacia el final del período analizado. Se observa un punto de intersección aproximado entre la línea amarilla y las barras alrededor del día 180, donde ambas series alcanzan valores similares. Las inferencias sobre la correlación entre los datos representados por la línea y las barras deben ser realizadas con precaución debido a la falta de información detallada sobre los ejes y escalas utilizadas.

El modelo volvió a incluir caracteres correspondientes a escritura asiática para referirse a la línea de tendencia, ignorando nuevamente la instrucción explícita de utilizar únicamente el alfabeto latino.

Reconoce la presencia de ambos ejes Y aunque señala explícitamente que no logra identificar con claridad la escala del eje derecho. Asimismo, a diferencia de su interpretación con el prompt anterior en la cual identificó correctamente que cada barra de la gráfica representa un año individual, en esta ocasión afirma que el eje X corresponde a una escala diaria. Siendo este el error más grave en su interpretación, ya que posteriormente desarrolla parte de su análisis en base a dicha suposición incorrecta.

En cuanto a la línea de tendencia, menciona la existencia de un punto de intersección con las barras, lo cual no se observa en la representación visual.

La interpretación es deficiente, el modelo no logra identificar correctamente los componentes de la gráfica ni su significado en general llegando incluso a reconocer explícitamente que carece de información suficiente para realizar inferencias, a pesar de que dicha información se encuentra presente en la imagen.

Modelo D

Gemma-3-12b

La imagen presenta una gráfica combinada que visualiza la evolución temporal de dos variables principales: producción científica y número de investigadores a tiempo completo, junto con un indicador adicional de productividad científica institucional. La representación utiliza barras verticales para ilustrar la producción científica en cada periodo, mientras que una línea continua representa el número de investigadores a tiempo completo. Un segundo gráfico de líneas muestra la productividad científica institucional. El eje vertical izquierdo está etiquetado como "Producción científica y número de investigadores de tiempo completo", aunque los valores específicos no son legibles. El eje vertical derecho se identifica como "Productividad científica institucional" con una escala numérica que va hasta 3, pero los valores exactos en el eje horizontal no son identificables.

Se observa un patrón general de fluctuación a lo largo del tiempo para la producción científica, con periodos de aumento y disminución. La línea que representa el número de investigadores muestra una tendencia ascendente general, aunque también presenta variaciones. Se aprecia una correlación visual positiva entre ambas variables, sugiriendo que incrementos en el número de investigadores pueden estar asociados a un aumento en la producción científica; sin embargo, esta es una inferencia basada únicamente en la observación visual y no puede ser confirmada sin datos adicionales. El gráfico inferior muestra valores numéricos asociados a cada periodo para las tres variables (artículos, investigadores e ISP), aunque algunos valores son parcialmente ilegibles o de baja resolución. La productividad científica institucional parece fluctuar también a lo largo del tiempo, mostrando un máximo en un punto no especificado y una disminución hacia el final del periodo representado; esta es una inferencia visual.

A pesar de que el modelo logra identificar correctamente las dos variables principales de la gráfica, presenta confusiones al momento de asociarlas con sus respectivos elementos visuales. En particular, menciona que la línea continua representa el número

de investigadores de tiempo completo, cuando en realidad corresponde a la productividad científica institucional; señala que tal productividad es representada por un segundo gráfico de líneas, lo cual no es correcto. No obstante, el modelo realiza una inferencia adecuada al señalar que los incrementos en el número de investigadores podrían estar asociados con un aumento en la producción científica.

En cuanto a los ejes, identifica correctamente la escala numérica del eje vertical derecho; sin embargo reconoce explícitamente que los valores correspondientes al eje vertical izquierdo no le son visibles, al igual que los valores exactos del eje horizontal, lo que le impide determinar el rango temporal representado en la gráfica.

Un aspecto a destacar es que este modelo es el primero en mencionar la presencia del gráfico inferior con valores numéricos, además de identificar correctamente las tres variables que lo componen. A pesar de ello, se abstiene de proporcionar los valores específicos al señalar que éstos no son completamente legibles en la imagen. Al final, el modelo realiza una inferencia visual correcta, en especial, cuando señala una disminución hacia el final del periodo representado. Pero al no mencionar años ni intervalos temporales específicos, su interpretación termina por ser limitada en términos de precisión.

Segunda imagen

La segunda representación visual o imagen de prueba cuenta con una mayor resolución que la imagen anterior (Figura 5.1). Corresponde a una gráfica de líneas que representa la evolución de la producción científica del ICN en el Web of Science, abarcando el periodo de 1968 a 2024.




Figura 5.2: Evolución de la producción científica del ICN

El reporte contiene la siguiente descripción para esta gráfica:

La producción científica del ICN creció de 2 artículos en 1968, hasta llegar a más de 200 documentos por año en la actualidad. En el año 2002 se observa un pico en la gráfica, al evaluar detenidamente la producción de este año se observa que un posdoctorante (Dong, SH) asociado al ICN ese año publicó 19 artículos. Además, otros investigadores estuvieron por encima de la media como Raga, AC (9 artículos), Frank, A (8 artículos), Guven J (7 artículos) y Hirsch, JG (6 artículos).

A continuación, las respuestas generadas junto con sus respectivos análisis:

Modelo B

Pixtral-12b

La imagen proporcionada presenta una gráfica de líneas que ilustra la evolución temporal de diversas métricas científicas. En el eje horizontal se representan intervalos temporales, en conjunto abarcan desde 1968 hasta 2024. El eje vertical muestra cantidades numéricas, también no identificables con precisión. La gráfica incluye tres series de datos diferenciadas por colores: rojo para "

Total de Documentos," negro para "Artículos," y azul para "Documentos sin GC." Adicionalmente, hay una serie en color gris claro que representa "Artículos sin GC." Los componentes visuales identificables incluyen barras verticales en la sección izquierda de la gráfica, que parecen representar datos categóricos o agrupados. En el gráfico de líneas a la derecha, se observa una tendencia general ascendente para todas las series de datos, indicando un aumento en las cantidades a lo largo **del** tiempo. Específicamente, "Total de Documentos" y "Artículos" muestran incrementos más pronunciados en comparación con "Documentos sin GC" y "Artículos sin GC." Las fluctuaciones son evidentes, especialmente alrededor de los años 2015 y 2020, donde se observan picos y valles que podrían sugerir periodos de mayor o menor actividad científica. La inferencia es que la producción científica ha crecido consistentemente a lo largo **del** tiempo, con variaciones periódicas en las tasas de publicación y documentación.

Para esta segunda representación visual, el modelo B inicia su interpretación identificando correctamente que en el eje X son representados intervalos temporales, además de proporcionar correctamente el rango en conjunto que se representa en la gráfica, de 1968 a 2024. Sin embargo, señala que no logra distinguir con claridad los valores específicos del eje Y. No obstante, identifica que el eje Y representa cantidades numéricas, esto indica un reconocimiento adecuado de la estructura general de la gráfica.

Identifica correctamente los nombres de las series de datos representadas, sin embargo, presenta errores en la representación en colores en tres de ellas. Entre sus aciertos más relevantes se encuentra la observación de que las series Total de Documentos y Artículos muestran incrementos más pronunciados en comparación con Documentos sin GC y Artículos sin GC. Asimismo, reconoce correctamente la presencia de fluctuaciones notables alrededor de los años 2015 y 2020. Además de ser correcta la conjetura mencionada al final acerca de que la producción científica creció consistentemente.

Aun así su interpretación no es del todo satisfactoria. En particular, no hace mención a los textos contenidos en los recuadros de color azul, los cuales proporcionan el contexto necesario para interpretar la representación visual como un análisis de la producción científica del ICN. Sugiriendo con esto una comprensión incompleta del significado semántico de la gráfica en general con observaciones que se centran principalmente en patrones visuales aislados, sin realizar alguna explicación de aquello que la gráfica busca comunicar.

Modelo C

InternVL3_5-8B-GGUF

La imagen muestra una gráfica de línea con cuatro series de datos representadas por símbolos distintivos: Total de Documentos (línea roja), Artículos (línea azul), Documentos SG (línea verde) y Artículos SaGG (línea morada). Los ejes **del** gráfico no tienen etiquetas legibles, pero se observa que el eje horizontal parece representar un período de tiempo, mientras que el eje vertical podría indicar una cantidad o frecuencia. La gráfica presenta una tendencia general ascendente para todas las series a lo largo **del** tiempo, con variaciones menores en algunas de ellas. Se identifican tres regiones coloreadas: la primera es azul claro y se extiende desde el inicio hasta aproximadamente el 2015; la segunda es amarilla y abarca desde alrededor **del** 2015 hasta el 2018; la tercera es morada y cubre desde el 2018 hasta el final de la gráfica. Las inferencias permitidas son que todas las series muestran un aumento general a lo largo **del** tiempo, con posibles diferencias en la velocidad o magnitud de crecimiento entre ellas.

Este modelo no solo comete errores al identificar los colores asociados a tres de las cuatro series de datos representadas en la gráfica, sino que además no identifica correctamente los nombres de dos de ellas.

A diferencia del anterior, el modelo C identifica la presencia de tres intervalos diferenciados por distinto color dentro de la gráfica; sin embargo aunque acierta en los colores utilizados se equivoca en los periodos temporales que abarca cada una.

Realiza una observación acertada respecto al significado de cada uno de los ejes, lo que sugiere una comprensión parcial de la estructura básica de la representación visual. Asimismo, algo a destacar es que para esta representación visual no utilizó caracteres asiáticos en su respuesta, así como la inferencia correcta que realizó al final.

En consecuencia, aunque el modelo C logra identificar algunos elementos estructurales de la gráfica, la acumulación de sus errores semánticos y temporales limita la calidad de su interpretación en general.

Modelo D

Gemma-3-12b

La figura presenta una gráfica lineal que muestra la evolución temporal de cuatro series de datos: "Total de Documentos", "Artículos", "Documentos Sin GC" y "Artículos Sin GC". El eje horizontal representa el tiempo, discretizado en unidades individuales no especificadas; el eje vertical cuantifica un valor numérico sin unidad explícita. La gráfica se divide visualmente en tres secciones coloreadas: una sección amarilla etiquetada como "Lab. Nuclear (1967-1972)", una sección naranja denominada "Ctro. Estudios Nucleares (1972-1988)" y una sección azul identificada como "ICN (1988-2024)".

Se observa que la serie "Total de Documentos" presenta un incremento general a lo largo **del** periodo completo, con fluctuaciones notables. La serie "Artículos" muestra una tendencia ascendente más pronunciada en la sección azul ("ICN") y permanece relativamente estable en las secciones amarilla y naranja. La serie "Documentos Sin GC" exhibe un patrón de crecimiento variable, con picos y valles evidentes a lo largo **del** tiempo; se infiere que esta serie puede estar correlacionada con la serie "Total de Documentos", aunque no es posible determinar la naturaleza exacta de dicha relación sin análisis adicionales. La serie "Artículos Sin GC" presenta una tendencia ascendente similar a la serie "Artículos", pero con mayor volatilidad. Las intersecciones precisas entre las curvas con ilegibles, así como los límites de las secciones coloreadas.

Al igual que el modelo B, el modelo D identifica correctamente los nombres de todas las series de datos representadas en la gráfica. Un aspecto relevante de su interpretación es que logra identificar los distintos intervalos o secciones en las que se divide la gráfica, mencionando correctamente los nombres y los años asociados a tales periodos. Sin embargo, comete errores al mencionar los colores correspondientes a estas secciones, a diferencia del modelo C que sí acierta en este aspecto.

En cuanto al análisis de las series de datos, el modelo realiza observaciones correctas destacando, por ejemplo, que la serie Total de Documentos presenta un incremento general a lo largo de todo el periodo representado. Además, formula de manera acertada una inferencia al sugerir una posible correlación entre las series Documentos sin GC y Total de Documentos, lo cual resulta consistente con lo que puede visualizarse

en la gráfica.

Sin embargo, a pesar de estos aciertos, la interpretación resulta un tanto incompleta pues el modelo no utiliza en sus observaciones valores numéricos asociados con el eje Y ni unidades de tiempo relacionadas con el eje X. Además, reconoce explícitamente que no logra identificar con claridad las intersecciones entre las curvas ni los límites exactos de las secciones coloreadas, lo que limita la profundidad de su análisis.

Observaciones

En general, las pruebas realizadas a lo largo de este capítulo permitieron comparar el comportamiento de distintos LLMs haciendo posible observar que cada uno tiende a identificar ciertos elementos de la representación visual que otros pasan por alto pues en algunos casos un modelo logra reconocer componentes gráficos específicos que no son detectados por los demás, mientras que en otros ocurre la situación inversa.

Con este tercer prompt, el modelo D presentó un desempeño superior que el modelo C al mostrar una identificación más precisa de las series de datos y una mayor coherencia en las inferencias que realizó. Sin embargo, debido a su falta de incorporación de detalles como valores numéricos y temporales en sus interpretaciones, como sí lo hace el modelo B. A pesar de ello, este modelo no es perfecto pues si bien es capaz de extraer información relevante a partir de la representación visual para hacer observaciones con unidades de tiempo correctos, sus interpretaciones podrían beneficiarse con la incorporación de algún contexto adicional acerca del fenómeno que busca comunicar la representación visual a analizar.

Asimismo, a partir del análisis de la segunda imagen se puede destacar que aún cuando la calidad visual en las imágenes es incrementada, los errores asociados a la mención de fechas, rangos temporales o valores no explícitos persisten. Sugiriendo que tales imprecisiones no se originan a partir de limitaciones visuales sino en los procesos de inferencia de los modelos. Pues éstos tienden a completar información faltante a partir de patrones que aprendieron durante su entrenamiento.

Modelo seleccionado para el sistema

A partir del análisis comparativo realizado con el tercer prompt, las interpretaciones del modelo B destacan pues a pesar de presentar algunas limitaciones como errores en la asignación de colores o la omisión de ciertos elementos de la representación visual, sus descripciones muestran más consistencia acerca de la estructura general de las representaciones visuales, resaltando con precisión los patrones destacados que éstas comunican. De manera que, el modelo Pixtral-12b fue el LLM integrado en la implementación final del sistema, al demostrar una mayor capacidad para generar interpretaciones encaminadas con el objetivo de generar reportes cuantitativos automatizados, minimizando la introducción de información poco precisa y no verificable visualmente.

5.2. Generación automática de reportes cienciométricos del ICN y/o de la Facultad de Ciencias de la UNAM

Para la integración del modelo de lenguaje de gran escala LLM al sistema, se optó por implementar una generación automática de interpretaciones por página.

En cada página del sistema se incorporó un botón global con el que es posible activar la generación automática de interpretaciones para todas las representaciones visuales contenidas en dicha página. Con este diseño las interpretaciones serán producidas únicamente bajo la demanda del usuario, evitando llamadas innecesarias al modelo.

Al presionar el botón global de generación, el sistema recorre de manera secuencial todas las representaciones visuales definidas en la página activa y realiza una llamada al módulo encargado de la comunicación con el modelo de lenguaje, como se muestra en el siguiente fragmento de código.

```
if st.button("Generar interpretaciones"):
    with st.spinner("Generando..."):
        st.session_state.interpretaciones["img1"] =
            generator(image_one_path, image_one_caption)
        st.session_state.interpretaciones["img2"] =
            generator(image_two_path, image_two_caption)...
```

Las interpretaciones se almacenan en una estructura de tipo diccionario en donde cada entrada se asocia de manera explícita con una representación visual específica.

El sistema emplea *st.session_state* para el manejo de estado en Streamlit con el objetivo de preservar los textos interpretativos generados durante la sesión del usuario. Éste permite conservar información entre ejecuciones sucesivas del sistema, las cuales ocurren de forma automática en cualquier interacción con la interfaz, tales como el cambio de pestaña o incluso de página. Asimismo, facilita la visualización y hace posible que las interpretaciones puedan regenerarse de forma individual sin necesidad de volver a ejecutar el modelo para todas las imágenes.

Para cada imagen se manda a llamar la función *generator*, a la cual se le proporciona la ruta del archivo de imagen y el caption asociado a dicha representación visual. Dentro de esta función, la imagen es cargada desde el sistema de archivos y codificada en formato Base64, permitiendo su envío al modelo como una entrada multimodal a través de una URL. Esta representación es posteriormente integrada en un prompt para el modelo Pixtral-12b, que combina el texto con instrucciones de salida y la imagen. Adicionalmente, cuando se dispone de un caption descriptivo este se incorpora como parte del contexto textual de la solicitud; pues no todas las imágenes cuentan

con uno.

Captions como contexto

En general, los modelos de lenguaje de gran escala LLMs no realizan una lectura de las imágenes como tal en el sentido humano del término, sino que generan interpretaciones a partir de patrones visuales combinados con expectativas estadísticas y conocimientos previos. Lo que puede llevar a la generación de descripciones que no siempre son estrictamente verificables a partir de la información visual presente en la imagen, como se vio con los modelos analizados anteriormente.

Esto puede intentar mitigarse de forma parcial con la incorporación de un contexto adicional, como lo puede ser proporcionar al modelo el caption de la imagen. Permitiendo así anclar la interpretación al fenómeno general que la representación visual busca comunicar.

Dicho contexto proporcionado mediante el caption actuará como un mecanismo para hacer menos ambigua la temática de la representación visual, sin embargo no va a sustituir la lectura directa de información visual explícita. Su inclusión mejorará la coherencia en general de la interpretación sin garantizar la identificación correcta de todos los componentes gráficos pues el modelo continuará basando parte de su análisis en inferencias apoyadas en sus conocimientos previos, lo que puede resultar en seguir obteniendo interpretaciones que no serán del todo verificables a partir de la imagen.

Por lo que, se realizó una nueva versión del prompt con la incorporación del caption de la representación visual.

Prompt Utilizado en el Sistema

```
1  img_caption_text = ""
2  if img_caption:
3      img_caption_text = (
4          "La imagen cuantitativa a analizar cuenta con el
           siguiente caption descriptivo, el cual debe
           utilizarse únicamente como contexto temático
           general y no como fuente de datos numéricos o
           semánticos no visibles: " f"\n{img_caption}\n")
5
6  try:
7      completion = client.chat.completions.create(
8          model="pixtral-12b",
9          messages=[
10             {
11                 "role": "system",
12                 "content": ("Eres un científico de datos
```

```

experto en cienciometría y en la
interpretación de gráficos y
representaciones visuales científicas.
Debes priorizar la precisión y evitar
cualquier suposición no respaldada
visualmente.")
13     },
14     {
15         "role": "user",
16         "content": [
17             {
18                 "type": "text",
19                 "text": ("Analiza únicamente la
información visible en la imagen
proporcionada. Redacta un pá
rrafo con un tono técnico y
formal de un reporte científico
que contenga obligatoriamente lo
siguiente: Elementos explí
citamente legibles en la imagen,
componentes visuales
identificables (si es una grá
fica, un mapa generado con redes
neuronales SOM, una tabla u
otro tipo de representación
visual; ejes, colores, símbolos)
, patrones visuales generales
observables (tendencias,
aumentos o disminuciones), las
inferencias son permitidas pero
deben ser claramente marcadas
como inferencias, abstente de
mencionar elementos no legibles,
ambiguos o no identificables;
no menciones años específicos,
valores exactos, rangos
temporales, intersecciones o
significados de ejes a menos que
estén claramente indicados y
sean legibles en la imagen; si
un dato no puede leerse con
claridad, indícalo explí
citamente como no legible o no
identificable; no inventes
valores, fechas, unidades ni
significados semánticos. Evita

```

```

frases meta-discursivas (ej. no
uses 'la imagen proporcionada es
'). La respuesta debe estar
escrita únicamente con letras
del alfabeto latino. No incluyas
introducciones ni conclusiones
generales ni títulos de
secciones.")
20         },
21         {
22             "type": "image_url",
23             "image_url": {"url": image_uri}
24         }
25     ],
26 }
27 ],
28 )

```

El diseño de prompt incorpora las estrategias descritas en el capítulo 2 para mejorar la calidad de la salida de los modelos. La entrada es específica en cuanto a la precisión la tarea, el formato de la respuesta, el tono de redacción y un conjunto explícito acerca del tipo de información que puede incluir en sus interpretaciones. A la vez que incorpora mecanismos orientados al control de alucinaciones al limitar el análisis exclusivamente a los elementos visuales verificables y exigir que cualquier dato no legible sea señalado explícitamente como tal.

Por su parte, la organización del prompt no es arbitraria. Con la adición del caption, la entrada comienza la interacción proporcionando al modelo la instrucción principal de la tarea *La imagen cuantitativa a analizar...*, seguido de la definición de un mensaje con rol system en el que se establece tanto el perfil del modelo *Eres un científico de datos experto en cuantimetría...* así como también el criterio general que debe seguir su comportamiento. Posteriormente, se encuentra la asignación a un rol user, donde el mensaje comienza por presentar de forma directa la instrucción principal *Analiza únicamente la información visible en la imagen proporcionada...*, incrementando así la probabilidad de que el modelo la considere como el objetivo dominante frente a las demás especificaciones a seguir. De esta forma, las indicaciones principales son situadas en posiciones de relevancia al inicio de cada componente contenido en la entrada, así se establece un marco interpretativo global que condiciona la lectura de todas las instrucciones posteriores y orienta el comportamiento del modelo durante toda la generación.

Asimismo, el esquema de interacción con el modelo corresponde a un enfoque de *instruction-based prompting* en modalidad *zero-shot*, ya que recibe una instrucción

explícita que define la tarea, las restricciones y el formato de la respuesta, sin proporcionarle ejemplos previos de salida. El comportamiento del modelo se guía únicamente por el conocimiento aprendido durante el entrenamiento y por la información contenida en el prompt.

A continuación se muestra un ejemplo de una interpretación generada automáticamente en base a la primer gráfica de prueba (Figura 5.1), utilizando este prompt, con el objetivo de ilustrar el estilo, nivel de detalle y limitaciones de las interpretaciones generadas por el modelo bajo esta configuración.

Pixtral-12b

La gráfica presenta datos sobre la producción científica y el número de investigadores en un contexto competitivo a lo largo de los años, desde 1996 hasta una fecha proyectada en 2024. El eje vertical izquierdo mide la "Producción científica y número de investigadores" y el número de investigadores, mientras que el eje vertical derecho representa la "productividad científica institucional". Los ejes horizontales están etiquetados con años específicos, comenzando en 1996 y proyectándose hasta 2024. El gráfico incluye dos series de datos: una serie de barras azules que representan los investigadores y otra línea amarilla que representa la producción científica. Se observa un aumento general en el número de investigadores a lo largo **del** tiempo, con fluctuaciones periódicas. La producción científica también muestra una tendencia al alza, aunque presenta variaciones más pronunciadas. Las etiquetas legibles bajo el gráfico indican los números exactos de artículos (investigadores) y otros parámetros (ISP, Productividad científica institucional) para cada año. Por ejemplo, en 1996, se registran 53 artículos e investigadores, mientras que en 2024 se proyecta un número significativamente mayor. Se observan picos notables en la producción científica alrededor de los años 2017 y 2021, coincidiendo con aumentos significativos en el número de investigadores. La línea amarilla muestra una tendencia ascendente general con fluctuaciones, indicando períodos de alta productividad científica seguidos de disminuciones relativas. En resumen, la imagen ilustra un crecimiento significativo tanto en el número de investigadores como en la producción científica a lo largo **del** período.

En este ejemplo se observa una mejora considerable en la interpretación generada por el modelo en comparación con su desempeño utilizando el tercer prompt de prueba. Desde el inicio, la respuesta adopta un formato más cercano al de un reporte científico, al seguir la indicación de evitar frases meta-discursivas.

A diferencia de interpretaciones previas, el modelo logra identificar correctamente el significado tanto del eje vertical derecho como del izquierdo. Asimismo, reconoce la presencia de las tres variables indicadas debajo de la gráfica y menciona adecuadamente sus denominaciones. Sin embargo, aunque identifica correctamente el valor correspondiente al número de artículos registrados en 1996, presenta un error al reportar el número de investigadores para ese mismo año. En relación con los picos señalados en su análisis, acierta al destacar uno correspondiente a 2021 pero identifica incorrectamente como pico el año 2017, en el que en realidad se observa un decremento en la serie.

Estos resultados muestran que la incorporación de información adicional como lo es el caption de la imagen, contribuye a una mayor coherencia general entre la interpretación generada y la representación visual analizada. Aunque también ponen en evidencia que persisten limitaciones en la identificación precisa de ciertos elementos gráficos. Esto refuerza lo indicado anteriormente, el modelo continuará apoyándose parcialmente en inferencias derivadas de sus conocimientos previos más que exclusivamente en información visual verificable a partir de la imagen.

Regeneración de interpretaciones

Durante la implementación del sistema, se planteó la idea de que una vez generadas todas las interpretaciones, el sistema ofreciera además al usuario la posibilidad de regenerar de manera individual el texto asociado a cada representación visual por medio de un botón ubicado debajo de la interpretación correspondiente. Esta acción llama nuevamente al modelo pero únicamente para la imagen seleccionada, actualizando el contenido almacenado en el estado de la sesión. De esta forma se le da al usuario la posibilidad de explorar variaciones en la interpretación de una imagen sin afectar el resto de las interpretaciones presentadas en la página.

Mediante la función *display_interpretacion* se gestiona la visualización y regeneración de las interpretaciones generadas por el modelo de lenguaje para cada una de las representaciones visuales. Comienza por verificar si existe una interpretación previamente generada y almacenada en el estado de sesión del sistema. En caso de que sí, el texto se presenta al usuario junto con un botón que permite regenerar la interpretación. Mientras que si no existe una interpretación previa, la función no muestra el contenido textual ni el botón de regeneración. Evitando así llamadas innecesarias al modelo.

Cuando el usuario solicita una regeneración, el sistema elimina previamente la interpretación almacenada para dicha representación visual, muestra al usuario un indi-

cador de que está en marcha el proceso de regeneración y vuelve a invocar el modelo para la imagen correspondiente. La nueva interpretación sustituye a la anterior y se actualiza la interfaz para mostrar el nuevo contenido generado, como se observa en el siguiente fragmento de código.

```
if st.button("Regenerar", key=f"regen_{img_key}"):
    st.session_state.interpretaciones[img_key] = st.
        empty()
    with st.spinner("Regenerando..."):
        st.session_state.interpretaciones[img_key] =
            generator(img_path, img_caption)
    st.rerun()
```

Asimismo, durante las pruebas de este botón de regeneración se observó que al estar utilizando una temperatura configurada en cero, la funcionalidad de regeneración producía exactamente la misma interpretación. Este comportamiento es consistente con lo descrito al inicio del capítulo anterior, donde se explicó que una temperatura baja induce la generación de respuestas determinista, en la cual el modelo selecciona la secuencia de tokens con mayor probabilidad dada una misma entrada.

Considerando que en el proceso de regeneración no se modifica ni la imagen, ni el prompt, ni el contexto proporcionado al modelo, es decir, la secuencia de entrada permanece idéntica, el contenido en la respuesta generada no tendrá variaciones. Por lo que, para permitir que el usuario explore interpretaciones alternativas sin modificar el contenido visual ni el prompt, fue necesario incrementar el valor de la temperatura a uno mayor a cero. A partir de este ajuste, la funcionalidad de regeneración comenzó a producir variaciones en el texto generado pero manteniendo coherencia en el contenido general.

6 Conclusiones y trabajo a futuro

6.1. Utilidad en la práctica profesional

Los modelos de lenguaje de gran escala LLMs han sido incorporados progresivamente en distintos ámbitos profesionales, donde se utilizan como herramientas de apoyo para el análisis de información, la generación automática de texto, la interpretación de datos y la automatización de tareas que requieren procesamiento de lenguaje natural. Su integración con modelos multimodales ha ampliado aún más sus aplicaciones, permitiendo no solo procesar texto, sino también interpretar imágenes, gráficos, diagramas y otros tipos de representaciones visuales.

El uso de estos modelos en entornos profesionales no debe entenderse como un reemplazo del especialista humano sino como una herramienta de apoyo que puede facilitar la interpretación de información, la generación de reportes y la síntesis de datos complejos. Sin embargo, para su uso adecuado resulta fundamental que los profesionales comprendan tanto sus capacidades como sus limitaciones, así como los contextos en los que su aplicación puede aportar valor sin comprometer la precisión o la confiabilidad de la información generada.

El sistema desarrollado en este proyecto está dirigido principalmente para su uso en la práctica profesional de especialistas relacionados al análisis cuantitativo, la evaluación científica y la gestión de la información académica; siendo en particular, la capacidad de generar interpretaciones automáticas de representaciones visuales lo que permite apoyar en tareas que requieren de un análisis manual detallado como lo es la elaboración de reportes científicos. La integración de un modelo de lenguaje de gran escala LLM para interpretar gráficas y tablas facilita tanto el análisis de la información que estas representaciones visuales contienen así como también la comprensión rápida y estructurada de indicadores cuantitativos, sintetizando de esta forma los resultados del reporte original de manera clara y consistente para distintos públicos.

El enfoque interactivo del sistema que permite tanto la generación global de interpretaciones como la regeneración individual de resultados, ofrece al usuario profesional flexibilidad de explorar diferentes narrativas sin necesidad de tener que modificar manualmente las representaciones visualizadas. Esta característica permite evaluar la estabilidad de las interpretaciones generadas y seleccionar aquellas que se ajusten mejor al contexto comunicativo del análisis que se busca obtener. De igual forma, el uso de un estado de sesión para almacenar las interpretaciones generadas facilita la persistencia de los resultados durante la interacción del usuario, permitiéndole navegar entre secciones, comparar interpretaciones y retomar el análisis sin necesidad de repetir llamadas al modelo.

En conjunto, estas características enriquecen el sistema posicionándose como una herramienta de apoyo que complementa el trabajo de un analista humano, contribuyendo a mejorar la eficiencia, estructura y accesibilidad de datos cuantitativos y su análisis en la práctica profesional sin sustituir el juicio experto.

6.2. Potencial para investigación y gestión científica

Más allá de su utilidad inmediata para la práctica profesional, el sistema desarrollado en este proyecto presenta un gran potencial como herramienta de apoyo para la investigación y la gestión científica. Bajo este contexto, la capacidad de generar interpretaciones automáticas y consistentes de representaciones visuales cuantitativas abre la posibilidad de incorporar modelos de lenguaje de gran escala como un recurso complementario dentro de procesos de evaluación de tendencias científicas a mediano y largo plazo.

El enfoque multimodal del sistema sienta las bases para su posible integración con otros flujos de trabajo de investigación, como la incorporación de nuevas fuentes de datos, la ampliación del conjunto de indicadores analizados o la comparación entre distintos estudios cuantitativos. Este potencial de extensión posiciona al sistema no solo como una herramienta aplicada sino también como una plataforma flexible para la exploración y el desarrollo de soluciones basadas en modelos de lenguaje de gran escala dentro del campo de la cuantimetría y la gestión del conocimiento científico, pues el sistema puede contribuir a apoyar la toma de decisiones informadas al facilitar una lectura más accesible y estructurada de grandes volúmenes de información.

Asimismo, el sistema puede funcionar como un intermediario entre los datos y los procesos de análisis estratégico mediante la generación automática de interpretaciones, pues permite sintetizar datos complejos y comunicar resultados de manera homogénea, con potencial para ayudar a los involucrados en la planeación institucional y la evaluación del desempeño científico.

6.3. Limitaciones y retos futuros

A pesar de la versatilidad y del potencial de los modelos de lenguaje de gran escala LLMs para su aplicación en diversos ámbitos, como la generación de reportes clínicos en medicina o la interpretación automática de representaciones visuales en cuantimetría, su comportamiento aún no se comprende completamente pues puede dar lugar a resultados inexactos.

En el contexto específico de este proyecto, los resultados obtenidos evidencian ciertas limitaciones incluso empleando el prompt final del sistema. Destacando la falta de precisión consistente en la identificación de elementos específicos de las representaciones visuales, particularmente en lo referente a las etiquetas temporales y al significado

semántico de los ejes. Siendo una problemática que persistió a pesar de la incorporación progresiva de prompts con cada vez más especificaciones y restricciones, los cuales, si bien contribuyeron a reducir la frecuencia de errores en las respuestas generadas, también implicaron una disminución en el nivel de detalle de las interpretaciones.

Asimismo, durante el análisis comparativo entre modelos se identificó una tendencia a asumir como legibles ciertos elementos que desde el punto de vista visual, no lo son. Este comportamiento puede derivar en la inclusión de afirmaciones no respaldadas directamente por la información observable en la representación visual, comprometiéndose así la confiabilidad en las interpretaciones generadas.

No obstante, es importante señalar que estas limitaciones pueden estar influenciadas por las características específicas de los modelos evaluados, particularmente en términos de su tamaño. En este sentido, es posible que modelos de mayor escala o con un entrenamiento más especializado en tareas de visión y lenguaje presenten un desempeño superior, reduciendo algunas de las dificultades observadas en este proyecto.

Con el objetivo de mitigar parcialmente estas limitaciones, se incorporó el caption extraído del reporte original de cada representación visual como parte de la entrada al modelo de lenguaje de gran escala LLM, junto con la imagen y las restricciones textuales definidas en el prompt. Este elemento adicional se utiliza exclusivamente como contexto temático general, sin utilizarse como fuente de datos numéricos ni semánticos no presentes de forma explícita en la representación visual. De esta manera, se busca proporcionar al modelo una referencia contextual que favorezca interpretaciones más coherentes, sin comprometer la indicación de basarse únicamente en la información visual disponible.

Siguiendo esta línea de proporcionar contexto al modelo, como trabajo futuro se propone la incorporación de la modalidad de *one-shot prompting* en la formulación del prompt del sistema. Como se mencionó en el capítulo 2, ésta consiste en proporcionar al modelo un único ejemplo explícito de una entrada junto con la salida esperada antes de solicitar la generación de la interpretación, con el propósito de guiar de manera más precisa tanto el formato de la respuesta como el nivel de detalle e inferencias permitidas. Esta integración podría contribuir en generar narrativas automáticas más detalladas, reduciendo la ambigüedad en las interpretaciones, y confiables.

Como parte del trabajo futuro se plantea analizar esta estrategia en distintos modelos de lenguaje y diferentes representaciones visuales, así como contrastar sus resultados con los obtenidos de los prompts diseñados en este proyecto. Esto con el fin de evaluar y comparar el impacto de utilizar *one-shot prompting* en la precisión, el nivel de detalle y la confiabilidad de las interpretaciones generadas automáticamente. Estas mejoras permitirían avanzar hacia un sistema más robusto y adecuado para su aplicación en entornos académicos y de apoyo a la toma de decisiones basadas en análisis cuantitativos.

Bibliografía

- Alammar, Jay Grootendorst, M. (2024). *Hands-on Large Language Models*. O'Reilly Media.
- De Solla Price, D. J. (1963). *Little Science, Big Science*. Columbia University Press, New York.
- Hirsch, J. E. (2005). An index to quantify an individual's scientific research output. *Proceedings of the National Academy of Sciences*, 102(46):16569–16572.
- Jurafsky, Daniel Martin, J. H. (2026). *Speech and Language Processing*. 3 edition. Draft version.
- Kohonen, T. (2013). Essentials of the self-organizing map. *Neural Networks*, 37:52–65. Twenty-fifth Anniversary Commemorative Issue.
- Mistral AI (2024). Announcing pixtral 12b. <https://mistral.ai/news/pixtral-12b/>. Accessed: 2026.
- Oshin, M. Campos, N. (2024). *Learning LangChain*. O'Reilly Media.
- Sotolongo-Aguilar, G., Guzmán-Sánchez, M. V., Saavedra-Fernández, O., and Carrillo-Calvet, H. A. (2001). Mining informetrics data with self-organizing maps. In *Proceedings of the 8th International Conference of the International Society for Scientometrics and Informetrics*, pages 665–673, Sydney, Australia. International Society for Scientometrics and Informetrics.
- Tufte, E. R. (2001). *The Visual Display of Quantitative Information*. Graphics Press. Originally published in 1983.